

CS229 – Verständnisfragen

Strukturiert nach Thematik

Stand: 20. September 2026

Inhaltsverzeichnis

1	Logistic Regression – Loss-Funktion und Gradient	2
2	Lineare Trennbarkeit und Konvergenz	3
3	SVM und Hinge Loss	4
4	Mathematische Notation	5
5	Model Calibration (PS2-2)	6
6	Kursstruktur	7

1 Logistic Regression – Loss-Funktion und Gradient

Frage

Warum gilt die Umrechnung zwischen Gradient und Loss-Funktion?

▷ PS2-1 »Training Stability«, Notebook-Abschnitt zur Herleitung der Loss-Funktion aus dem Gradienten

Der Gradient der logistischen Regression lautet:

$$\nabla_{\theta} J(\theta) = -\frac{1}{m} \sum_{i=1}^m \frac{y^{(i)} x^{(i)}}{1 + \exp(y^{(i)} \theta^{\top} x^{(i)})}$$

Behauptung: Dieser Gradient gehört zur Loss-Funktion

$$\ell(\theta) = \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-y^{(i)} \theta^{\top} x^{(i)})).$$

Nachrechnen durch Ableiten:

Schritt 1 – Einen Term ableiten:

$$\frac{\partial}{\partial \theta} \log(1 + \exp(-y \theta^{\top} x)) = \frac{1}{1 + e^{-y \theta^{\top} x}} \cdot e^{-y \theta^{\top} x} \cdot (-y x)$$

Schritt 2 – Vorfaktor vereinfachen (mit $a := y \theta^{\top} x$):

$$\frac{e^{-a}}{1 + e^{-a}} = \frac{e^{-a}}{1 + e^{-a}} \cdot \frac{e^a}{e^a} = \frac{1}{e^a + 1} = \frac{1}{1 + e^a}$$

Schritt 3 – Einsetzen:

$$\frac{\partial}{\partial \theta} \log(1 + e^{-y \theta^{\top} x}) = \frac{-y x}{1 + e^{y \theta^{\top} x}}$$

Schritt 4 – Gesamt:

$$\nabla_{\theta} \ell(\theta) = \frac{1}{m} \sum_{i=1}^m \frac{-y^{(i)} x^{(i)}}{1 + \exp(y^{(i)} \theta^{\top} x^{(i)})} = -\frac{1}{m} \sum_{i=1}^m \frac{y^{(i)} x^{(i)}}{1 + \exp(y^{(i)} \theta^{\top} x^{(i)})}$$

Das stimmt mit dem angegebenen Gradienten überein. Die entscheidende Vereinfachung ist $e^{-a}/(1 + e^{-a}) = 1/(1 + e^a)$.

Frage

Was bedeutet ℓ (“ell”)?

▷ Allgemeine CS229-Notation; tritt in PS2-1 Notebook und allen Loss-Herleitungen auf

ℓ ist der Name für die **Loss-Funktion**, abgeleitet vom Buchstaben l (kleines L, kursiv), der in der Mathematik häufig für “Loss” oder “Likelihood” steht.

In diesem Kontext bezeichnet $\ell(\theta)$ die **negative Log-Likelihood** der logistischen Regres-

sion:

$$\ell(\theta) = \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-y^{(i)} \theta^\top x^{(i)})),$$

die minimiert werden soll.

2 Lineare Trennbarkeit und Konvergenz

Frage

Warum gilt: Dataset ist linear trennbar $\Leftrightarrow y^{(i)} \theta^\top x^{(i)} > 0$ für alle i ?

▷ PS2-1 »Training Stability«, Teil (b) – Ursache der Divergenz; Grundlage in `main_notes.pdf`, Kap. 6.3 (Funktionaler Margin, S. 61)

Die Entscheidungsgrenze ist die Hyperebene $\{x : \theta^\top x = 0\}$. Ein Punkt liegt auf einer der zwei Seiten je nach Vorzeichen von $\theta^\top x$:

$y^{(i)}$	$\theta^\top x^{(i)}$	$y^{(i)} \cdot \theta^\top x^{(i)}$	Klassifikation
+1	> 0	> 0	korrekt
-1	< 0	> 0	korrekt
+1	< 0	< 0	falsch
-1	> 0	< 0	falsch

$y^{(i)} \theta^\top x^{(i)} > 0$ bedeutet also genau: Punkt i liegt auf der richtigen Seite der Trennhyperebene. Gilt das für alle i , trennt θ alle Punkte korrekt – das ist die Definition von **linearer Trennbarkeit**.

Im Skript: `main_notes.pdf`, Kap. 6.3, S. 61:

“if $y^{(i)}(w^\top x + b) > 0$, then our prediction on this example is correct.”

Dies ist der sogenannte **funktionale Margin** $\hat{\gamma}^{(i)} = y^{(i)}(w^\top x + b)$.

Frage

Warum konvergiert Gradient Descent nicht für linear trennbare Datasets?

▷ PS2-1 »Training Stability«, Teil (b) – Erklärung des Divergenzverhaltens von Dataset B

Schritt 1: Die Loss-Funktion hat kein Minimum.

Sei das Dataset trennbar, d. h. es gibt θ^* mit $y^{(i)} \theta^{*\top} x^{(i)} > 0$ für alle i . Betrachte $c \theta^*$ für wachsendes $c > 0$:

$$\ell(c \theta^*) = \frac{1}{m} \sum_{i=1}^m \underbrace{\log(1 + \exp(-c \cdot \underbrace{y^{(i)} \theta^{*\top} x^{(i)}}_{> 0}))}_{\rightarrow 0 \text{ für } c \rightarrow \infty}$$

Da der Exponent $-c \cdot$ (positiv) immer negativer wird:

$$\begin{aligned}c = 1 : \quad & \log(1 + e^{-1}) \approx 0,31 \\c = 10 : \quad & \log(1 + e^{-10}) \approx 0,000045 \\c \rightarrow \infty : \quad & \rightarrow 0, \text{ aber nie } = 0\end{aligned}$$

Der Loss sinkt unbegrenzt, erreicht aber sein Infimum 0 nie. Es gibt also **kein echtes Minimum** – der Gradient wird nie exakt 0.

Schritt 2: Konsequenz für Gradient Descent.

Da kein endliches Minimum existiert, gilt $\|\theta\| \rightarrow \infty$. Das Abbruchkriterium $\|\theta_{t+1} - \theta_t\| < \varepsilon$ wird nie erfüllt.

Schritt 3: Nicht-trennbarer Fall zum Vergleich.

Wenn es mindestens einen falsch klassifizierten Punkt gibt, hilft Skalieren nicht: der Loss dieses Punktes wird durch größeres c *größer*, nicht kleiner. Der Loss hat daher ein echtes Minimum bei endlichem θ , und Gradient Descent konvergiert dorthin.

Frage

Ist das Divergenzproblem generell bei Logistic Regression?

▷ Folge aus PS2-1 »Training Stability«, Teil (c) – Gegenmassnahmen; allgemeine Frage zur Methode

Ja, aber nur wenn das Dataset **linear trennbar** ist. Das ist kein Implementierungsfehler, sondern ein mathematisches Problem: die Log-Likelihood hat kein endliches Maximum.

Lösungen in der Praxis:

(1) **L2-Regularisierung** (häufigstes Vorgehen):

$$\ell_{\text{reg}}(\theta) = \ell(\theta) + \lambda \|\theta\|^2$$

Für $\|\theta\| \rightarrow \infty$ gilt $\lambda \|\theta\|^2 \rightarrow \infty$, also gibt es ein endliches Minimum.

(2) **Early Stopping** – Training abbrechen bevor θ zu groß wird.

(3) **Abnehmende Lernrate** – Schritte werden mit der Zeit kleiner.

In `scikit-learn` ist L2-Regularisierung standardmäßig aktiv (`C=1.0`), weshalb das Problem dort normalerweise nicht auftritt.

3 SVM und Hinge Loss

Frage

Was ist Hinge Loss?


▷ PS2-1 »Training Stability«, Teil (d) – Vergleich LR mit SVM als Alternative bei linear trennbaren Daten; Theorie in `main_notes.pdf`, Kap. 6

Hinge Loss ist die Loss-Funktion der SVMs. Definition für einen Punkt:

$$L(\theta, x^{(i)}, y^{(i)}) = \max(0, 1 - y^{(i)} \theta^\top x^{(i)})$$

Verhalten:

$y \theta^\top x$	Hinge Loss	Interpretation
≥ 1	0	korrekt, mit ausreichend Abstand (Margin ≥ 1)
$= 0$	1	Punkt liegt auf der Entscheidungsgrenze
$= -1$	2	falsch klassifiziert



Vergleich mit logistischem Loss:

Logistic Loss: $\log(1 + e^{-z}) > 0$ immer

Hinge Loss: $\max(0, 1 - z) = 0$ für $z \geq 1$

Deshalb hat das SVM das Konvergenzproblem bei trennbaren Datasets *nicht*: Sobald alle Punkte $y^{(i)} \theta^\top x^{(i)} \geq 1$ erfüllen, ist der Loss exakt 0 – kein weiterer Gradient, kein Wachstum von θ .

4 Mathematische Notation

Frage

Was bedeutet $|\{i \in I_{a,b}\}|$?

▷ PS2-2 »Model Calibration«, Kalibrierungsdefinition – $I_{a,b}$ bezeichnet den Bucket von Beispielen mit Vorhersage in $[a, b]$

Das ist die **Kardinalität** (Anzahl der Elemente) einer Menge:

$$|\{i \in I_{a,b}\}| = \text{Anzahl der Indizes } i, \text{ die in der Menge } I_{a,b} \text{ enthalten sind.}$$

Beispiel: Wenn $I_{a,b} = \{2, 5, 7, 9\}$, dann $|I_{a,b}| = 4$.

Allgemein: $|S|$ bedeutet "wie viele Elemente hat Menge S ".

Frage

Was bedeutet $\mathbb{I}\{y^{(i)} = 1\}$?

▷ PS2-2 »Model Calibration«, Kalibrierungsformel – allgemeine CS229-Notation für Indikatorfunktionen

Das ist die **Indikatorfunktion**:

$$\mathbb{I}\{y^{(i)} = 1\} = \begin{cases} 1 & \text{falls } y^{(i)} = 1 \\ 0 & \text{sonst} \end{cases}$$

Sie gibt 1 zurück wenn die Bedingung wahr ist, sonst 0.

Beispiel mit $m = 4$ Datenpunkten, $y = (1, 0, 1, 1)$:

$$\mathbb{I}\{y^{(1)} = 1\} = 1$$

$$\mathbb{I}\{y^{(2)} = 1\} = 0$$

$$\mathbb{I}\{y^{(3)} = 1\} = 1$$

$$\mathbb{I}\{y^{(4)} = 1\} = 1$$

In Python entspricht das `(y == 1).astype(int)` bzw. direkt `y == 1` in einem booleschen Ausdruck.

5 Model Calibration (PS2-2)

Frage

Impliziert perfekte Kalibrierung perfekte Genauigkeit – und umgekehrt?

▷ PS2-2 »Model Calibration«, Teil (b) – Beweis der Unabhängigkeit beider Eigenschaften

Antwort: Nein, in beide Richtungen.

Richtung 1: Kalibrierung impliziert *nicht* Genauigkeit.

Gegenbeispiel: Alle $y^{(i)} = 1$ (nur positive Klasse).

Für den Bucket $(a, b) = (0, 5, 1)$ muss bei perfekter Kalibrierung gelten:

$$\frac{\sum_{i \in I_{a,b}} \mathbb{I}\{y^{(i)} = 1\}}{|\{i \in I_{a,b}\}|} = \frac{\sum_{i \in I_{a,b}} P(y^{(i)} = 1 \mid x^{(i)}; \theta)}{|\{i \in I_{a,b}\}|}$$

Die linke Seite ist 1 (alle Punkte haben $y = 1$). Da $h(x) = \sigma(\theta^\top x) < 1$ immer gilt, muss die rechte Seite < 1 sein – das Modell sagt für manche Punkte $h(x) < 0,5$ vorher: also **falsch klassifiziert**.

Richtung 2: Genauigkeit impliziert *nicht* Kalibrierung.

Perfekte Genauigkeit bedeutet alle Punkte korrekt klassifiziert, also Anteil $y = 1$ im Bucket $= 1$. Aber das Modell könnte trotzdem $h(x) = 0,6$ vorhersagen:

$$\underbrace{\frac{\sum_{i \in I_{a,b}} \mathbb{I}\{y^{(i)} = 1\}}{|\{i \in I_{a,b}\}|}}_{=1} \neq \underbrace{\frac{\sum_{i \in I_{a,b}} P(y^{(i)} = 1 \mid x^{(i)}; \theta)}{|\{i \in I_{a,b}\}|}}_{<1}$$

Kalibrierung verletzt, obwohl alle Entscheidungen korrekt sind.

Kernaussage: Kalibrierung prüft ob Wahrscheinlichkeiten realistisch sind. Genauigkeit prüft nur ob die Entscheidung ($> 0,5$ oder nicht) stimmt. Beides ist voneinander unabhängig.

6 Kursstruktur

Frage

Greifen die PS2-Aufgaben auf Wissen aus späteren Kapiteln vor?

▷ *Übergreifende Frage zur Kursstruktur – entstanden beim Durcharbeiten aller PS2-Aufgaben*

Ja. Mehrere PS2-Aufgaben setzen Konzepte voraus, die im Kursverlauf erst später behandelt werden:

Problem	Erwartete Notes	Tatsächlich benötigt	Hinweis
PS2-1	Kap. 2 (LR)	Kap. 6 (Hinge Loss/SVM) für Teil (d); Kap. 9 (Regularisierung) für Teil (c)	Teil (d) setzt SVM-Konzepte voraus
PS2-2	Kap. 2 (LR, MLE)	–	vollständig in Kap. 2
PS2-3	Kap. 2/9	Kap. 9.4 (Bayesian Statistics) als Hauptquelle	Kap. 9.4 kommt später im Kurs
PS2-4	–	Kap. 5+6 (Kernels, Mercer) vollständig	komplett aus Kap. 5+6
PS2-5	–	Kap. 5+6 (Kernel Trick, Representer Theorem)	komplett aus Kap. 5+6
PS2-6	Kap. 4.2 (NB)	Kap. 6 (SVM) für Teil (d)	Hybrid-Problem

Fazit: PS2-4 und PS2-5 sind komplett aus Kap. 5+6 (SVMs/Kernels), das nach PS1 kommt. PS2-3 erfordert Kap. 9.4 (Bayesian Statistics) als primäre Quelle – ein deutlicher Vorgriff auf spätere Kursinhalte.