




CS229

MACHINE

LEARNING

HANDNOTES



Die komplette Vorlesung als Lernzusammenfassung



40 Kapitelseiten

+ 24 Vertiefungen



Herleitungen

Schritt für Schritt



Code

getestet & ausgeführt



Selbsttests

drei Fragen pro Seite

Andrew Ng & Tengyu Ma

Vorlesungsnotizen & Ergänzungsmaterial (notes, extra-notes, materials, section)

Lernen. Verstehen. Umsetzen. Wachsen.



Alles auf einen Blick: Übersichtsseiten (Nummern) und dahinter Vertiefungen (+) -- alle Einträge sind anklickbar. ♥

Inhalt & Übersicht

Grundlagen, Überwachtes Lernen, Deep Learning, Praxis

Merke:
Erst Grundlagen, dann Modelle, dann Praxis, dann Herleitungen

0 Grundlagen	
01 Wahrscheinlichkeit & Statistik	4
02 Lineare Algebra	5
I Überwachtes Lernen	
1 Lineare Regression	7
+ Vertiefung: Lineare Regression	8
2 Logistische Regression	9
3 Generalisierte Lineare Modelle	10
+ Vertiefung: Logistische Regression & GLM	11
4 Generative Modelle (GDA, NB)	12
+ Vertiefung: Generative Modelle	13
5 Kernel-Methoden	14
6 Support Vector Machines	15
+ Vertiefung: Support Vector Machines	16
+ Vertiefung: SVM in der Praxis (SMO, Code)	17
7 Perceptron & Online Learning	18
8 k-Nearest Neighbors	19
9 Decision Trees	20
10 Ensemble-Methoden	21
+ Vertiefung: k-NN, Bäume & Ensembles	22
11 Verlustfunktionen	23
II Deep Learning	
12 Neuronale Netze	24
13 Backpropagation	25
+ Vertiefung: Backpropagation	26
+ Vertiefung: Backpropagation in der Praxis	27
14 DL-Praxis: Training	28
15 CNN & RNN / LSTM	29
+ Vertiefung: DL-Praxis, CNN & RNN	30
+ Vertiefung: LSTM & Parameterzahlen	31
16 Foundation Models	32
III Generalisierung & Praxis	
17 Bias & Varianz	33
18 Lerntheorie	34
+ Vertiefung: Generalisierung & Lerntheorie	35
19 Regularisierung	36
+ Vertiefung: Regularisierung	37
20 Validierung & Tuning	38
21 Gaussian Processes	39
22 Fehleranalyse	40
23 Klassifikationsmetriken	41
24 Regressionsmetriken	42
+ Vertiefung: Klassifikations- & Regressionsmetriken	43
25 Feature Importance & SHAP	44
+ Vertiefung: SHAP-Herleitung	45
+ Vertiefung: SHAP in der Praxis	46
26 Fairness-Analyse	47
+ Vertiefung: Fairness	48
+ Vertiefung: Fairness in der Praxis	49
27 Feature Engineering	50
28 ML-Workflow	51
+ Vertiefung: Feature Engineering, Tuning & Workflow	52

Inhalt & Landkarte

Weiter: unüberwachtes und bestärkendes Lernen, Spickzettel und die Landkarte des Kurses. 

Teil IV--V, Anhang, roter Faden

Merke:
Modell wählen → Verlust → optimieren → prüfen!

IV Unüberwachtes Lernen

29	K-Means	53	34	PCA	60
30	Hierarchisches Clustering	54	35	ICA	61
+	Vertiefung: K-Means & Clustering	55	+	Vertiefung: PCA & ICA	62
31	EM-Algorithmus	56	36	Generative Modelle: VAE, GAN	63
+	Vertiefung: EM-Algorithmus	57	+	Vertiefung: VAE & GAN	64
32	Faktorenanalyse	58	37	Kritische Perspektiven	65
33	Hidden Markov Models	59			

V Bestärkendes Lernen

38	MDPs & Value Iteration	66
39	LQR, DDP & LQG	67
40	Policy Gradient	68
+	Vertiefung: Bestärkendes Lernen	69
+	Vertiefung: LQR-Riccati & Tricks	70

A Anhang: Spickzettel

81	Algorithmen-Tabelle	71
82	Formel-Spickzettel	72

* Der ML-Workflow (roter Faden)



* Drei Lernparadigmen

- **Überwacht** (x, y) : Vorhersage lernen (Regression, Klassifikation).
- **Unüberwacht** x : Struktur finden (Cluster, Dimensionsreduktion, Sequenzen, Generative Modelle).
- **Bestärkend**: Aktionen wählen, um Belohnung zu maximieren.

* So liest du diese Notizen

- **Beispiel** mit Rechnung & **Lösung** (alle Zahlen maschinell geprüft)
- **Pseudo-Code**, **Merke-Zettel**, Key Takeaways, **Selbsttest**
- **+ Vertiefung**: Herleitung Schritt für Schritt und getesteter Code direkt hinter dem Thema
- **Zusatzinfo (Internet)** = nicht aus den Notes; Quelle: unter jedem Titel

Σ Notation: was die Symbole überall bedeuten

n Anzahl Beispiele, d Anzahl Merkmale, $x^{(i)} \in \mathbb{R}^d$ Merkmalsvektor, $y^{(i)}$ Label des i -ten Beispiels, $X \in \mathbb{R}^{n \times d}$ Design-Matrix (eine Zeile pro Beispiel), θ Modellparameter, $h_\theta(x)$ bzw. $\hat{y}$ Vorhersage, $J(\theta)$ Kosten (zu minimieren), $\ell(\theta)$ Log-Likelihood (zu maximieren), α Lernrate, λ Regularisierungsstärke, ∇ Gradient (Vektor der Ableitungen), $\mathbb{E}$ Erwartungswert, $\mathcal{N}(\mu, \Sigma)$ Normalverteilung, $\mathbf{1}\{\cdot\}$ Indikator (1, wenn wahr), σ Sigmoid bzw. Standardabweichung (je nach Kontext), $A^\top$ transponiert, $\|\cdot\|$ Länge (Norm), $\odot$ elementweises Produkt, $\mathcal{H}$ Hypothesenraum, K Anzahl Klassen bzw. Cluster. Wird ein Symbol lokal anders benutzt, steht eine Legende direkt im Panel.

„Modell, Verlust, Optimierung – die drei Fragen hinter jedem Algorithmus dieser Vorlesung.“

Fast jeder ML-Algorithmus ist angewandte Wahrscheinlichkeitsrechnung. ❤️

Grundlagen: Wahrscheinlichkeit

Bayes, Erwartungswerte, MLE & MAP, Entropie

Merke:
ML = Wahrscheinlichkeit + Optimierung

Quelle: Vorwissen zu CS229; angelehnt an section/cs229-prob.pdf, section/gaussians.pdf sowie hand-notes/ (Conditional Probability)

1 Grundregeln

Summenregel: $P(A) = \sum_b P(A, B=b)$
(Marginalisieren)

Produktregel: $P(A, B) = P(A|B)P(B)$

Bedingt: $P(A|B) = \frac{P(A \cap B)}{P(B)}$, $P(B) > 0$

Bayes: $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$

2 Unabhängigkeit

$A \perp B \iff P(A, B) =$


$P(A)P(B) \iff P(A|B) = P(A).$

Bedingt unabhängig: $A \perp B | C \iff$

$P(A, B|C) = P(A|C)P(B|C)$ -

Grundannahme von **Naive Bayes**
(Features unabhängig gegeben die Klasse).

3 Skizze: Venn-Diagramm



$P(A|B) = \text{Anteil von } A \cap B \text{ in } B$

4 Erwartungswert, Varianz, Kovarianz

$\mathbb{E}[X] = \sum_x xP(x)$ bzw. $\int xp(x)dx$

$\mathbb{E}[aX + bY] = a\mathbb{E}X + b\mathbb{E}Y$

Linearität

$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}X)^2] = \mathbb{E}[X^2] - (\mathbb{E}X)^2$

$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)]$, $\rho = \frac{\text{Cov}}{\sigma_X \sigma_Y}$

Unabhängig $\Rightarrow \text{Cov} = 0$ (umgekehrt nicht!). Mittelwert von n iid: $\text{Var}(\bar{X}) = \sigma^2/n$.

5 Wichtige Verteilungen

Name	Träger / Dichte	$\mathbb{E}$, Var	Einsatz
Bernoulli(ϕ)	$\phi^y(1-\phi)^{1-y}$	ϕ , $\phi(1-\phi)$	LogReg
Multinomial	K Klassen		Softmax
Poisson(λ)	$\lambda^y e^{-\lambda} / y!$	λ , λ	Zählraten
Gauß	$\frac{e^{-(y-\mu)^2/2\sigma^2}}{\sqrt{2\pi}\sigma}$	μ , σ^2	Rauschen
$\mathcal{N}(\mu, \sigma^2)$			
Mehrdim. Gauß	$\mathcal{N}(\mu, \Sigma)$	μ , Σ	GDA, GP

Beispiel: Bayes beim Medizintest

Prävalenz 1%, Sensitivität 95%, Spezifität 90%. Wie wahrscheinlich ist man krank bei positivem Test?

Lösung $P(+) = 0.95 \cdot 0.01 + 0.10 \cdot 0.99 = 0.1085$.

$P(\text{krank}|+) = \frac{0.95 \cdot 0.01}{0.1085} \approx 8.8\%$ - trotz gutem Test klein, weil die Krankheit selten ist (Base-Rate-Fehler). Genau das passiert bei Klassenungleichgewicht.

6 Maximum Likelihood (MLE)

Wähle θ , das die Daten am wahrscheinlichsten macht:

$$\hat{\theta} = \arg \max_{\theta} \sum_{i=1}^n \log p(x^{(i)}; \theta)$$

(Log: Produkt $\rightarrow$ Summe, gleiches Maximum.) Beispiel Bernoulli, k Erfolge in n : $\ell = k \log \phi + (n-k) \log(1-\phi)$,

$\ell' = \frac{k}{\phi} - \frac{n-k}{1-\phi} = 0 \Rightarrow \hat{\phi} = \frac{k}{n}$.

Gauß: $\hat{\mu} = \frac{1}{n} \sum x_i$, $\hat{\sigma}^2 = \frac{1}{n} \sum (x_i - \hat{\mu})^2$.

7 MAP & Bayes

$$p(\theta|D) \propto p(D|\theta)p(\theta)$$

MAP: $\arg \max [\log p(D|\theta) + \log p(\theta)] =$
MLE + Regularisierer (Gauß-Prior $\rightarrow$ L2, Laplace $\rightarrow$ L1).

8 Entropie, KL, Cross-Entropy

$H(p) = -\sum p \log p$,

$H(p, q) = -\sum p \log q$

$\text{KL}(p||q) = H(p, q) - H(p) \geq 0$

Cross-Entropy-Verlust = MLE: minimiert
KL zwischen Daten und Modell.

9 LLN & CLT

Gesetz der großen Zahlen: $\bar{X}_n \rightarrow \mathbb{E}X$.

Zentraler Grenzwertsatz:

$\sqrt{n}(\bar{X}_n - \mu) \rightarrow \mathcal{N}(0, \sigma^2)$ - warum
Rauschen oft gaußsch ist und
Hoeffding/Konzentration wirkt.

? Selbsttest: kannst du das erklären?

F1 Was besagt der Satz von Bayes?

A: Posterior = Likelihood $\times$ Prior /
Evidenz.

F2 Wie lautet der MLE-Schätzer für ϕ
bei k Erfolgen in n Versuchen?

A: $\hat{\phi} = k/n$.

F3 Was ist der Zusammenhang MAP $\leftrightarrow$
Regularisierung?

A: Log-Prior wirkt als Strafterm: Gauß
 $\rightarrow$ L2, Laplace $\rightarrow$ L1.

„Alles Lernen ist Schließen unter Unsicherheit -- Wahrscheinlichkeit ist die Sprache dafür.“

Daten sind Matrizen, Modelle sind Abbildungen: die Sprache hinter allen Formeln.



Grundlagen: Lineare Algebra

Vektoren, Matrizen, Eigenwerte & Matrixableitungen

Merke:
Kein Gradient ohne
Matrixableitung!

Quelle: Vorwissen zu CS229; angelehnt an section/cs229-linalg.pdf sowie main_notes.pdf (Normalgleichung, PCA)

1 Vektoren & Normen

Skalarprodukt

$$x^T y = \sum_i x_i y_i = \|x\| \|y\| \cos \varphi.$$

$$\|x\|_2 = \sqrt{x^T x}, \quad \|x\|_1 = \sum |x_i|.$$

$x \perp y \iff x^T y = 0$. Projektion von y auf u ($\|u\|=1$): $(u^T y) u$.


2 Matrizen: Rechenregeln

$$(AB)^T = B^T A^T, \quad (AB)^{-1} = B^{-1} A^{-1}$$

$$\text{tr}(AB) = \text{tr}(BA), \quad \text{tr}(A) = \sum \lambda_i$$

Design-Matrix $X \in \mathbb{R}^{n \times d}$: eine Zeile pro Beispiel; $X\theta$ liefert alle Vorhersagen auf einmal.

3 Skizze: Least Squares = Projektion



4 Eigenwerte, PSD, SVD

$Av = \lambda v$. Für symmetrische A : reelle λ , orthonormale

Eigenvektoren, $A = U \Lambda U^T$.

Positiv semidefinit (PSD): $x^T A x \geq 0 \forall x \iff \lambda_i \geq 0$

(Kovarianzmatrizen, Gram-Matrizen, konvexe Hesse-Matrizen).

SVD: $X = U \Sigma V^T$; Singulärwerte² = Eigenwerte von $X^T X \Rightarrow$ PCA.

5 Matrixableitungen (Gradient nach x)

Funktion	Gradient
$a^T x$	a
$x^T A x$	$(A + A^T)x$, symmetrisch: $2Ax$
$\ Xx - y\ ^2$	$2X^T(Xx - y)$
$\log \det A$	A^{-T}
$\ x\ _2^2$	$2x$

Beispiel: Eigenwerte von $A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$

Lösung $\det(A - \lambda I) = (2 - \lambda)^2 - 1 = 0 \Rightarrow \lambda_1 = 3, \lambda_2 = 1$.

Eigenvektoren $v_1 = \frac{1}{\sqrt{2}}(1, 1)$, $v_2 = \frac{1}{\sqrt{2}}(1, -1)$ (orthogonal). Beide $\lambda > 0 \Rightarrow A$ ist PSD, ja sogar positiv definit.

Als Kovarianzmatrix: Ellipse mit Achsen v_1 (Länge $\propto \sqrt{3}$) und v_2 ($\propto 1$) – genau die Hauptkomponenten.

6 Kovarianz & Gauß-Ellipsen

$\Sigma = \mathbb{E}[(x - \mu)(x - \mu)^T]$ ist symmetrisch PSD. Die Höhenlinien von $\mathcal{N}(\mu, \Sigma)$ sind Ellipsen: Richtungen = Eigenvektoren, Streuung $\propto \sqrt{\lambda_i}$. Mahalanobis-Abstand: $(x - \mu)^T \Sigma^{-1} (x - \mu)$. Σ singulär $\iff$ ein $\lambda = 0$ (Daten liegen im Unterraum $\rightarrow$ Faktorenanalyse).

7 Numerik

- `solve(A,b)` statt `inv(A)@b`
- Konditionszahl $\lambda_{\max}/\lambda_{\min}$ groß $\rightarrow$ instabil (Features skalieren)
- Regularisierung: $X^T X + \lambda I$

8 Typische Fehler

- × Dimensionen vertauschen ($X^T X$ vs. XX^T)
- × $(AB)^T = A^T B^T$ (falsch!)
- × Inverse ohne Rangprüfung

9 Wo es gebraucht wird

- Normalgleichung, GDA, Kernel-Gram-Matrix
- PCA, Faktorenanalyse, GP
- Backprop (Jacobi-Matrizen)

? Selbsttest: kannst du das erklären?

F1 Was ist der Gradient von $\|X\theta - y\|^2$?

A: $2X^T(X\theta - y)$.

F2 Woran erkennt man eine PSD-Matrix?

A: Alle Eigenwerte ≥ 0 , äquivalent $x^T A x \geq 0$.

F3 Warum ist $X^T X$ immer PSD?

A: $v^T X^T X v = \|Xv\|^2 \geq 0$.

„Wer Matrixableitungen beherrscht, sieht in jedem Lernalgorithmus dieselbe Gleichung.“

Grundlagen: Optimierung

Konvexität, Gradient Descent, Newton & Lagrange

Merke:
Konvexes Problem: jedes lokale Minimum ist global!

Quelle: Vorwissen zu CS229; angelehnt an section/cs229-cvopt.pdf, section/cs229-cvopt2.pdf und hand-notes/ML Notes.pdf (Gradient Descent)

1 Konvexität

f konvex:

$$f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y).$$

Äquivalent: Hesse $\nabla^2 f \succeq 0$.

Lokales Minimum = globales Minimum.

Konvex: Least Squares, logistische Verluste, SVM. Nicht konvex: neuronale Netze, K-Means, EM.


2 Gradient Descent

Bergab entlang des negativen Gradienten:

$$\theta_{t+1} = \theta_t - \alpha \nabla J(\theta_t)$$

α = Lernrate. Der Gradient zeigt in Richtung des steilsten Anstiegs.

3 Skizze: Lernrate



4 Varianten & Algorithmus

`</>` Gradient Descent (Batch / SGD / Mini-Batch)

init θ ; **repeat** bis Konvergenz:

wähle Datenmenge B :

Batch: alle n ; SGD: 1 Beispiel; Mini-Batch: B

$$g \leftarrow \frac{1}{|B|} \sum_{i \in B} \nabla J^{(i)}(\theta)$$

$$\theta \leftarrow \theta - \alpha g$$

Batch: stabil, teuer. SGD: billig, verrauscht (entkommt flachen Stellen). Mini-Batch: Standard im Deep Learning.

5 Konvergenz & Praxis

Für $J(\theta) = \frac{1}{2} \theta^T H \theta$ konvergiert GD, wenn $\alpha < 2/\lambda_{\max}(H)$; Geschwindigkeit hängt an der Konditionszahl $\lambda_{\max}/\lambda_{\min}$.

Features standardisieren $\Rightarrow$ rundere Höhenlinien $\Rightarrow$ schnellere Konvergenz. Lernrate wählen: erst groß, dann abklingen lassen (Schedules); Verlust über die Iterationen plotten.

Beispiel: GD auf $f(x) = x^2, x_0 = 4$

Gradient $f'(x) = 2x$, Update $x \leftarrow x - 2\alpha x = (1 - 2\alpha)x$.

Lösung $\alpha = 0.1$: $x_k = 4 \cdot 0.8^k$: 3.2, 2.56, 2.05, $\dots \rightarrow 0$

konvergiert.

$\alpha = 1.1$: Faktor -1.2 : $x_1 = -4.8, x_2 = 5.76, \dots$ **divergiert** ($|1 - 2\alpha| > 1$).

$\alpha = 0.5$: $x_1 = 0$ - in einem Schritt am Ziel (nur bei diesem Quadrat).

6 Newton-Verfahren

Zweite Ordnung: $\theta \leftarrow \theta - H^{-1} \nabla J$ (H = Hesse). Für quadratische J in einem Schritt am Ziel; sonst quadratische Konvergenz nahe dem Optimum. Kosten $O(d^3)$ pro Schritt. Beispiel $f = x^2 - 4x$: $f' = 2x - 4, f'' = 2, x_1 = x_0 - \frac{2x_0 - 4}{2} = 2$ (Minimum) für jedes x_0 .

7 Lagrange & KKT (Nebenbedingungen)

$\min f(x)$ s.t. $g(x) \leq 0$: $\mathcal{L} = f + \alpha g, \alpha \geq 0$. KKT: Zulässigkeit, $\alpha \geq 0$, Complementary Slackness $\alpha g = 0, \nabla_x \mathcal{L} = 0$.

Beispiel $\min x^2$ s.t. $1 - x \leq 0$: $\mathcal{L} = x^2 + \alpha(1 - x), x = \alpha/2$, Dual $g(\alpha) = \alpha - \alpha^2/4$, max bei $\alpha^* = 2, x^* = 1$, Wert 1 (Primal = Dual).

8 Nicht konvex

- lokale Minima, Sattelpunkte
- SGD-Rauschen + gute Initialisierung helfen
- Neustarts (K-Means, EM)

9 Nicht differenzierbar

- $|x|$ (L1), Hinge, ReLU: Subgradient
- $\partial|x| = \{-1\}, [-1, 1], \{1\}$

10 Wo es gebraucht wird

- alle Trainingsverfahren
- SVM-Dual (KKT), EM (ELBO)
- Regularisierung, Backprop

? Selbsttest: kannst du das erklären?

F1 Wann ist ein lokales Minimum global?

A: Wenn die Zielfunktion konvex ist.

F2 Warum standardisiert man Features vor Gradient Descent?

A: Rundere Höhenlinien, kleinere Konditionszahl, schnellere und stabilere Konvergenz.

F3 Was sagt Complementary Slackness?

A: $\alpha_i g_i = 0$: entweder Nebenbedingung aktiv oder Multiplikator 0.

„Bergab gehen ist einfach -- die Kunst ist, die richtige Schrittweite zu wählen.“

Lineare Regression

Die Grundlage aller Vorhersagemodelle

Ziel: eine Gerade so durch die Datenwolke legen, dass sie y möglichst gut vorhersagt.



Merke:

Least Squares = Maximum Likelihood bei Gauß-Rauschen!

1 Idee & Modell

Gegeben: Daten $\{(x^{(i)}, y^{(i)})\}_{i=1}^n$ mit $x \in \mathbb{R}^d, y \in \mathbb{R}$.

Gesucht: Hypothese $h_\theta(x) \approx y$.

$$h_\theta(x) = \theta^\top x = \sum_{j=0}^d \theta_j x_j, \quad x_0 := 1$$

$x_0 = 1$ ist der **Bias-Term**

(Achsenabschnitt).

Design-Matrix $X \in \mathbb{R}^{n \times d}$: eine Zeile pro Beispiel, $y \in \mathbb{R}^n$.


2 Kostenfunktion (MSE)

Wie schlecht ist θ ? Summe der quadrierten Fehler:

$$J(\theta) = \frac{1}{2n} \sum_{i=1}^n (h_\theta(x^{(i)}) - y^{(i)})^2 = \frac{1}{2n} \|X\theta - y\|^2$$

Konvex (Schüssel-Form): genau ein globales Minimum, keine lokalen Fallen.

3 Skizze: Residuen



4 Gradient Descent

Ableiten und bergab laufen (Lernrate α):

$$\theta_j \leftarrow \theta_j + \frac{\alpha}{n} \sum_{i=1}^n (y^{(i)} - h_\theta(x^{(i)})) x_j^{(i)}$$

Batch: alle n Punkte pro Schritt. **SGD**: 1 Punkt (oder Mini-Batch) pro Schritt – billiger, verrauschter.

`</> Batch-Gradient-Descent`

`init` $\theta \leftarrow 0$

`repeat` bis Konvergenz:

`g` $\leftarrow \frac{1}{n} X^\top (X\theta - y)$

$\theta \leftarrow \theta - \alpha g$

SGD: für jedes i in zufälliger Reihenfolge

$\theta \leftarrow \theta + \alpha (y_i - \theta^\top x_i) x_i$

Tipp: Features skalieren; α zu groß $\Rightarrow$ Divergenz, zu klein $\Rightarrow$ langsam.

5 Normalgleichung (geschlossene Lösung)

$\nabla_\theta J = 0$ setzen ergibt in einem Schritt:

$$\hat{\theta} = (X^\top X)^{-1} X^\top y$$

Gut für kleines/mittleres d (Inversion kostet $O(d^3)$). Bei sehr großem d oder singulärem $X^\top X$: Gradient Descent oder Regularisierung.

`</> Numpy-Einzeiler`

`theta = solve(X.T @ X, X.T @ y)`

besser als explizite Inverse (stabiler)

6 Probabilistische Sicht

Annahme: $y = \theta^\top x + \varepsilon, \varepsilon \sim \mathcal{N}(0, \sigma^2)$ iid. Dann ist

$$\log L(\theta) = \text{const} - \frac{1}{2\sigma^2} \sum_i (y^{(i)} - \theta^\top x^{(i)})^2$$

$\Rightarrow$ **MLE = Least Squares.**

7 Lokal gewichtete Regression

Nichtparametrisch: für jede Anfrage x neu fitten, nahe Punkte zählen mehr:

$$w^{(i)} = \exp\left(-\frac{\|x^{(i)} - x\|^2}{2\tau^2}\right)$$

Minimiere $\sum_i w^{(i)} (y^{(i)} - \theta^\top x^{(i)})^2$.

Bandbreite τ : klein $\rightarrow$ wackelig, groß $\rightarrow$ glatt.

Beispiel: 3 Punkte per Hand

Aufgabe Punkte $(1, 1), (2, 2), (3, 2)$. Finde $\hat{\theta}$ und sage $x = 4$ vorher.

Lösung $X^\top X = \begin{pmatrix} 3 & 6 \\ 6 & 14 \end{pmatrix}, X^\top y = \begin{pmatrix} 5 \\ 11 \end{pmatrix}$,

$\det = 6$

$$\hat{\theta} = \frac{1}{6} \begin{pmatrix} 14 & -6 \\ -6 & 3 \end{pmatrix} \begin{pmatrix} 5 \\ 11 \end{pmatrix} = \begin{pmatrix} 2/3 \\ 1/2 \end{pmatrix}$$

$$h(4) = \frac{2}{3} + \frac{1}{2} \cdot 4 \approx \mathbf{2.67}$$

8 Vorteile

- ✓ einfach, schnell, gut interpretierbar
- ✓ geschlossene Lösung existiert
- ✓ konvexes Problem: keine lokalen Minima
- ✓ solide Baseline für jedes Regressionsproblem

9 Grenzen

- ✗ nur lineare Zusammenhänge (Abhilfe: Feature-Maps, Kernel)
- ✗ empfindlich gegen Ausreißer (quadr. Fehler)
- ✗ $X^\top X$ evtl. singulär (kollineare Features)
- ✗ Overfitting bei sehr vielen Features

10 Key Takeaways

- ✓ $h_\theta(x) = \theta^\top x$, Kosten = MSE
- ✓ Lösung: Normalgleichung oder (S)GD
- ✓ MLE unter Gauß-Rauschen
- ✓ LWLR: nichtparametrische Erweiterung

11 Polynom-Features & Anwendungen

Auch Kurven sind „linear“: $\phi(x) = (1, x, x^2, \dots, x^k)$, $h_\theta(x) = \theta^\top \phi(x)$. Linear in θ , nichtlinear in x . Der Grad k steuert die

Modellkomplexität $\rightarrow$ Bias/Varianz. Anwendungen:

Preis-/Umsatzprognose, Trends, Baseline für komplexere Modelle.

12 Annahmen (aus den ML Notes)

Linearität, Unabhängigkeit, Homoskedastizität (konstante Fehlervarianz), normalverteilte Fehler (Basis der MLE-Sicht), keine starke Multikollinearität. Residuenplot: Muster $\Rightarrow$ nichtlinear, Trichter $\Rightarrow$ Heteroskedastizität. Metriken: Kapitel Regressionsmetriken.

? Selbsttest: kannst du das erklären?

F1 Warum ist $J(\theta)$ konvex?

A: Quadratisch in θ (Hesse $X^\top X/n \succeq 0$): nur ein globales Minimum.

F2 Wann versagt die Normalgleichung?

A: Bei sehr großem d ($O(d^3)$) oder singulärem $X^\top X$: dann GD oder Regularisierung.

F3 Wirkung von τ bei LWLR?

A: Bandbreite: klein $\rightarrow$ sehr lokal/wackelig, groß $\rightarrow$ glatt (globale lineare Regression).

„Ein einfaches Modell, das man wirklich verstanden hat, schlägt ein kompliziertes, das man nur benutzt.“

Warum ist die Normalgleichung optimal -- und warum ist Least Squares der MLE?



Lineare Regression: Vertiefung

Herleitung, Rechenbeispiel und Code

Merke:
Kein Gradient ohne
Herleitung: Produktregel,
Konvexität, Log-Likelihood

Quelle: main_notes.pdf Kap. 1 (LMS, Normalgleichung, probabilistische Interpretation); Herleitung ausformuliert; Code: code/np_gd.py, code/sk_linreg.py (real ausgeführt)

1 Normalgleichung

Ziel $J(\theta) = \frac{1}{2} \|X\theta - y\|^2 = \frac{1}{2} (X\theta - y)^\top (X\theta - y)$.

Legende: $X \in \mathbb{R}^{n \times d}$ Design-Matrix (Zeile i ist $x^{(i)\top}$), $y \in \mathbb{R}^n$ Zielwerte, $\theta \in \mathbb{R}^d$ Parameter, J Kosten, ∇_θ Vektor der partiellen Ableitungen nach θ , $\succeq 0$ positiv semidefinit (Eigenwerte ≥ 0).

In Worten: $X\theta - y$ ist der Fehlervektor aller n Beispiele, J die halbe Summe seiner Quadrate (die $\frac{1}{2}$ kürzt die 2 beim Ableiten).

$$\begin{aligned} J &= \frac{1}{2} X^\top X \theta - \theta^\top X^\top y + \frac{1}{2} y^\top y && \text{ausmultiplizieren} \\ \nabla_\theta J &= X^\top X \theta - X^\top y && \nabla x^\top A x = 2Ax, \nabla a^\top x = a \\ \nabla_\theta J &= 0 \Rightarrow X^\top X \theta = X^\top y && \text{Normalgleichungen} \\ \hat{\theta} &= (X^\top X)^{-1} X^\top y && \text{falls } X^\top X \text{ invertierbar} \end{aligned}$$

J ist konvex ($\nabla^2 J = X^\top X \succeq 0$) $\Rightarrow$ das stationäre $\hat{\theta}$ ist das globale Minimum.

In Worten: Am Boden der Schüssel ist die Steigung null.
 $X^\top (X\theta - y) = 0$ heißt: der Fehler steht senkrecht auf allen Spalten von X (orthogonale Projektion von y).

2 Warum Least Squares? (MLE)

Modell $y^{(i)} = \theta^\top x^{(i)} + \varepsilon^{(i)}$, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ iid, also
 $p(y|x; \theta) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(y - \theta^\top x)^2 / 2\sigma^2}$.

Legende: ε Rauschen, σ^2 dessen Varianz, $\mathcal{N}(0, \sigma^2)$ Normalverteilung, iid unabhängig und gleich verteilt, $p(y|x; \theta)$ Dichte von y bei gegebenem x und Parameter θ , ℓ Log-Likelihood.

$$\begin{aligned} \ell(\theta) &= \sum_i \log p(y^{(i)} | x^{(i)}; \theta) && \text{Log-Likelihood} \\ &= n \log \frac{1}{\sqrt{2\pi}\sigma} - \frac{1}{2\sigma^2} \sum_i (y^{(i)} - \theta^\top x^{(i)})^2 && \text{Logarithmus von } e^{-} \end{aligned}$$

Erster Term unabhängig von $\theta \Rightarrow$

$\max \ell \iff \min \sum_i (y^{(i)} - \theta^\top x^{(i)})^2$. **MLE = Least Squares.**

In Worten: Wähle θ so, dass die beobachteten Daten am wahrscheinlichsten werden; der Logarithmus macht aus dem Produkt eine Summe. Gauß-Rauschen bestraft große Fehler quadratisch.

Gradient Descent in NumPy vs. Normalgleichung

```
import numpy as np
X = np.array([[1, 1], [1, 2], [1, 3], [1, 4]], dtype=float) # 1. Spalte: Bias
y = np.array([1, 2, 3, 4], dtype=float)
theta, alpha = np.zeros(2), 0.1
for _ in range(1000):
    grad = X.T @ (X @ theta - y) / len(y) # (1/n) X^T (X theta - y)
    theta -= alpha * grad
print("theta GD : ", theta.round(3))
print("theta Normal:", np.linalg.solve(X.T @ X, X.T @ y).round(3))
```

Ausgabe (real ausgeführt)

```
theta GD : [0. 1.]
theta Normal: [0. 1.]
```

Lineare Regression und Ridge in scikit-learn

```
import numpy as np
from sklearn.linear_model import LinearRegression, Ridge
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error, r2_score
rng = np.random.default_rng(0)
X = rng.uniform(0, 10, (200, 1))
y = 3 * X[:, 0] + 2 + rng.normal(0, 1, 200)
Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.2, random_state=42)
for m in (LinearRegression(), Ridge(alpha=10.0)):
    m.fit(Xtr, ytr)
    p = m.predict(Xte)
    print(type(m).__name__, m.coef_.round(2), round(m.intercept_, 2),
          "MSE", round(mean_squared_error(yte, p), 2), "R2", round(r2_score(yte, p), 3))
```

Ausgabe (real ausgeführt)

```
LinearRegression [2.97] 2.04 MSE 0.7 R2 0.991
Ridge [2.95] 2.15 MSE 0.71 R2 0.991
```

? Selbsttest: kannst du das herleiten?

F1 Warum ist der stationäre Punkt der globale Minimierer?

A: J ist konvex: $\nabla^2 J = X^\top X \succeq 0$.

F2 Warum ist Least Squares der MLE?

A: Bei Gauß-Rauschen ist die Log-Likelihood const $-\frac{1}{2\sigma^2} \sum (y - \theta^\top x)^2$.

F3 Wann GD statt Normalgleichung?

A: Sehr großes d (Inversion $O(d^3)$) oder singuläres $X^\top X$.

„Erst ableiten, dann verstehen, warum die Formel stimmt.“

Logistische Regression

Von Zahlen zu Wahrscheinlichkeiten

Klassifikation: die Ausgabe ist eine Wahrscheinlichkeit zwischen 0 und 1. ♥

Merke: Die update-Regel sieht aus wie LMS -- ist aber ein anderes Modell!

1 Idee

Binäre Klassifikation, $y \in \{0, 1\}$. Ein lineares Modell taugt nicht ($\theta^\top x \notin [0, 1]$).

Lösung: **Sigmoid** quetscht alles in $(0, 1)$:

$$g(z) = \frac{1}{1 + e^{-z}}$$

$$h_\theta(x) = g(\theta^\top x) = P(y=1 | x; \theta)$$

2 Likelihood

$$P(y=1|x) = h_\theta(x),$$

$$P(y=0|x) = 1 - h_\theta(x). \text{ Kompakt:}$$


$$P(y|x) = h^y (1 - h)^{1-y}.$$

$$\ell(\theta) = \sum_i [y^{(i)} \log h^{(i)} + (1 - y^{(i)}) \log(1 - h^{(i)})]$$

Maximiere ℓ (Maximum Likelihood) = minimiere die **Cross-Entropy**.

Legende: n Beispiele, $h^{(i)} = h_\theta(x^{(i)})$
Vorhersage für Beispiel i , ℓ Log-Likelihood.

3 Skizze: Sigmoid



4 Gradient Ascent

Ableiten liefert (mit $g' = g(1 - g)$) die einfache Regel

$$\theta_j \leftarrow \theta_j + \alpha (y^{(i)} - h_\theta(x^{(i)})) x_j^{(i)}$$

Legende: α Lernrate, $x_j^{(i)}$ Merkmal j von Beispiel i , $y^{(i)} - h$ Fehler der Vorhersage.

Form identisch zur LMS-Regel, aber h ist nichtlinear. (Grund: GLM-Struktur.)

`</> Logistische Regression (SGD)`

init $\theta \leftarrow 0$

repeat bis Konvergenz:

for i in zufälliger Reihenfolge:

$$h \leftarrow 1/(1 + e^{-\theta^\top x_i})$$

$$\theta \leftarrow \theta + \alpha (y_i - h) x_i$$

predict: Klasse 1 falls $\theta^\top x \geq 0$

5 Newton-Verfahren (Fisher Scoring)

Nutzt Krümmung, konvergiert **quadratisch**:

$$\theta \leftarrow \theta - H^{-1} \nabla_\theta \ell, \quad H = -X^\top S X, \quad S = \text{diag}(h_i(1 - h_i))$$

Legende: H Hesse-Matrix (Krümmung), $\nabla_\theta \ell$ Gradient, S Gewichtsmatrix, d Anzahl Merkmale.

Wenige Iterationen (oft < 10), aber jeder Schritt kostet $O(d^3)$.

`</> Newton / IRLS`

repeat bis Konvergenz:

$$h \leftarrow \sigma(X\theta)$$

$$S \leftarrow \text{diag}(h \odot (1 - h))$$

$$\theta \leftarrow \theta + (X^\top S X)^{-1} X^\top (y - h)$$

6 Softmax (Mehrklassen)

K Klassen, je ein Parametervektor θ_k (j läuft über alle Klassen):

$$P(y=k|x) = \frac{e^{\theta_k^\top x}}{\sum_{j=1}^K e^{\theta_j^\top x}}$$

Verlust: $-\log P(y|x)$ (Cross-Entropy). Für $K = 2$: wieder Sigmoid.

7 Entscheidungsgrenze

$\{x : \theta^\top x = 0\}$ ist eine **Hyperebene** $\Rightarrow$

lineares Modell. Schwelle 0.5 ist nur Konvention: höhere Schwelle $\rightarrow$ mehr Precision, niedrigere $\rightarrow$ mehr Recall.

Beispiel: Vorhersage + 1 Update

$$\theta = (-3, 1, 1), x = (1, 2, 3), y = 1.$$

$$z = -3 + 2 + 3 = 2 \Rightarrow h = \sigma(2) \approx 0.88:$$

Klasse 1.

$$\text{Update } (\alpha = 0.5): (y - h) = 0.12$$

$$\Delta\theta = 0.5 \cdot 0.12 \cdot (1, 2, 3) = (0.06, 0.12, 0.18)$$

8 Vorteile

- ✓ liefert Wahrscheinlichkeiten
- ✓ konvex: kein lokales Minimum
- ✓ schnell, robust, gut interpretierbar
- ✓ Baseline für Klassifikation

9 Grenzen

- ✗ nur lineare Grenzen (sonst Features/Kernel)
- ✗ bei perfekt trennbaren Daten $\|\theta\| \rightarrow \infty$ (Regularisieren!)
- ✗ empfindlich bei starkem Klassen-Ungleichgewicht

10 Key Takeaways

- ✓ $h = \sigma(\theta^\top x)$, MLE = Cross-Entropy
- ✓ SGD-Regel: $\theta \leftarrow \theta + \alpha(y - h)x$
- ✓ Newton: wenige, teure Schritte
- ✓ Softmax = Mehrklassen-Verallgemeinerung

11 Praxis, Anwendungen & Querverweise

Tipps: Features skalieren, L2-Regularisierung gegen $\|\theta\| \rightarrow \infty$, bei Klassen-Ungleichgewicht Gewichte oder Schwelle anpassen, Wahrscheinlichkeiten auf Kalibrierung prüfen. **Anwendungen:** Spam- und Betrugserkennung, Risikoscores, Klickvorhersage, Kreditausfall. **Siehe auch:** GLMs (warum die Regel wie LMS aussieht), SVM (anderer Verlust), Neuronale Netze (letzte Schicht = Softmax).

? Selbsttest: kannst du das erklären?

F1 Warum hat die SGD-Regel die Form $(y - h)x$?

A: Gradient der Log-Likelihood;
 $g' = g(1 - g)$ kürzt sich heraus.

F2 Was passiert bei perfekt trennbaren Daten?

A: Likelihood wächst weiter, $\|\theta\| \rightarrow \infty \Rightarrow$ Regularisierung nötig.

F3 Vorteil von Newton gegenüber GD?

A: Quadratische Konvergenz, wenige Iterationen; Nachteil: $O(d^3)$ pro Schritt.

„Logistische Regression ist ein lineares Modell mit einem Wahrscheinlichkeits-Filter davor.“

Ein Rezept für viele Modelle:
Verteilung wählen, Modell
folgt automatisch. ❤️

Generalisierte Lineare Modelle

Regression und Klassifikation unter einem Dach

Merke:
Lineare, logistische und
Poisson-Regression sind alle
GLMs!

1 Idee

Statt für jedes Problem ein neues
Modell zu erfinden:


Wähle die zu y passende Verteilung

(Zahl, Ja/Nein, Zähldaten...), der Rest
ergibt sich. Das erklärt, warum die
Update-Regeln so ähnlich aussehen.

2 Exponentialfamilie

$p(y; \eta) = b(y) \exp(\eta^\top T(y) - a(\eta))$
 η : natürlicher Parameter, $T(y)$:
hinreichende Statistik, $a(\eta)$:
Log-Partitionsfunktion, $b(y)$: Basismaß.
Gauß, Bernoulli, Poisson, Multinomial
u. v. m. gehören dazu.

3 Skizze: Pipeline



4 Die drei GLM-Annahmen

1. $y | x; \theta \sim \text{ExpFam}(\eta)$
2. Hypothese: $h(x) = \mathbb{E}[T(y) | x; \theta]$
3. Linearer Zusammenhang: $\eta = \theta^\top x$

Die **Responsefunktion** $g(\eta) = \mathbb{E}[T(y); \eta]$ verbindet η mit dem
Mittelwert; ihre Inverse heißt **Linkfunktion**. Das Lernen
(Maximum Likelihood) ergibt für alle GLMs dieselbe Form (α
Lernrate, $h_\theta(x) = \mathbb{E}[y|x]$ Vorhersage):

$$\theta \leftarrow \theta + \alpha(y - h_\theta(x))x$$

6 Rezept: GLM bauen

GLM in 4 Schritten

1. Verteilung passend zu y wählen
(reell $\rightarrow$ Gauß, 0/1 $\rightarrow$ Bernoulli,
Zählwert $\rightarrow$ Poisson, K Klassen $\rightarrow$ Multinomial)
2. In Exponentialform bringen: η, T, a, b ablesen
3. $h(x) = g(\eta)$ mit $\eta = \theta^\top x$
4. Log-Likelihood maximieren (SGD):
 $\theta \leftarrow \theta + \alpha(y - h(x))x$

5 Bekannte Vertreter

Verteilung	Response	Modell
Gauß	Identität	Lineare Regression
Bernoulli	Sigmoid	Logistische Regression
Multinomial	Softmax	Softmax-Regression
Poisson	e^η	Poisson-Regression (Zählda- ten)

Beispiel: Poisson-Regression (Zähldaten)

Aufgabe Besucher pro Stunde. Modell $\theta = (0.5, 0.4)$, Feature
 $x = (1, 2)$ (z. B. Temperatur-Score). Wie viele Besucher
erwartet man?

Lösung $\eta = \theta^\top x = 0.5 + 0.8 = 1.3$, Response

$$h = e^\eta = e^{1.3} \approx 3.67.$$

Warum e^η ? Poisson: $p(y; \lambda) = \lambda^y e^{-\lambda} / y!$ mit $\eta = \log \lambda \Rightarrow$
 $\lambda = e^\eta > 0$ (Zählwerte sind nie negativ).

7 Vorteile

- ✓ einheitliche Theorie & Update-Regel
- ✓ passende Verteilung $\Rightarrow$ bessere
Modelle
- ✓ Ausgaben immer im gültigen Bereich

8 Grenzen

- ✗ Verteilung muss zur
Exponentialfamilie gehören
- ✗ η bleibt linear in x
- ✗ Wahl der Verteilung ist
Modellannahme

9 Key Takeaways

- ✓ Erst Verteilung, dann Modell
- ✓ $\eta = \theta^\top x$, $h = g(\eta)$
- ✓ Alle: $\theta \leftarrow \theta + \alpha(y - h)x$

10 Herleitung: Bernoulli $\rightarrow$ Sigmoid

$$p(y; \phi) = \phi^y (1 - \phi)^{1-y} = \exp(y \log \frac{\phi}{1-\phi} + \log(1 - \phi))$$

$$\text{Ablesen: } \eta = \log \frac{\phi}{1-\phi}, T(y) = y, a(\eta) = \log(1 + e^\eta), b(y) = 1.$$

$$\text{Umstellen: } \phi = \frac{1}{1 + e^{-\eta}} \Rightarrow$$

das ist genau die Sigmoid-Funktion.

Gauß ($\sigma^2=1$): $\eta = \mu$, $T(y) = y$, $a(\eta) = \eta^2/2 \Rightarrow h = \eta$
(Identität).

11 Praktische Eigenschaften

Für $T(y) = y$ gilt: $\mathbb{E}[y; \eta] = a'(\eta)$ und $\text{Var}(y; \eta) = a''(\eta)$.
Die log-Likelihood ist in θ **konkav** $\Rightarrow$ keine lokalen Maxima;
Gradient Ascent oder Newton finden das globale Optimum.
Anwendungen: Zähldaten (Poisson), Wartezeiten (Exponential),
Anteile (Bernoulli/Binomial).

? Selbsttest: kannst du das erklären?

F1 Welche drei Annahmen definieren ein
GLM?

A: $y|x \sim \text{ExpFam}(\eta)$; $h = \mathbb{E}[T(y)|x]$;
 $\eta = \theta^\top x$.

F2 Response bei Poisson-Regression?

A: $h = e^\eta$ (Erwartungswert $\lambda > 0$).

F3 Warum haben alle GLMs dieselbe
Update-Regel?

A: Gradient der Log-Likelihood ist
 $(y - h)x$ bei kanonischer Response.

„Wähle die Verteilung, die zu deinen Daten passt -- den Rest erledigt das GLM.“

Logistische Regression & GLM: Vertiefung

Warum sieht der Gradient so einfach aus? Herleitung für logistische Regression, Softmax und alle GLMs. ❤️

Merke:
Ein Gradient, viele Modelle:
(Vorhersage - Wahrheit) × Eingabe

Herleitung, Newton, Softmax und Code

Quelle: main_notes.pdf Kap. 2-3; Schritte ausformuliert und ergänzt; Code: code/sk_logreg.py (real ausgeführt)

1 Gradient der logistischen Regression

$h = g(\theta^\top x)$, $g(z) = \frac{1}{1+e^{-z}}$, $g' = g(1-g)$. Für ein Beispiel:

Legende: $x \in \mathbb{R}^d$ Merkmale (x_j : j -te Komponente), $y \in \{0, 1\}$ Label, θ Parameter, g Sigmoid, $h = P(y=1|x)$ vorhergesagte Wahrscheinlichkeit, ℓ Log-Likelihood des Beispiels.

In Worten: ℓ ist die Log-Wahrscheinlichkeit des tatsächlichen Labels: für $y=1$ bleibt $\log h$, für $y=0$ bleibt $\log(1-h)$.

$$\ell = y \log h + (1-y) \log(1-h)$$

$$\begin{aligned} \frac{\partial \ell}{\partial \theta_j} &= \left(\frac{y}{h} - \frac{1-y}{1-h} \right) \frac{\partial h}{\partial \theta_j} && \text{Kettenregel} \\ &= \left(\frac{y}{h} - \frac{1-y}{1-h} \right) h(1-h) x_j && g' = g(1-g) \\ &= (y(1-h) - (1-y)h) x_j = (y-h) x_j && \text{Bruch kürzen} \end{aligned}$$

Ergebnis: Fehler $(y-h)$ mal Eingabe x_j - je falscher die Vorhersage, desto größer die Korrektur.

2 Hesse-Matrix & Newton

Ableiten von $\sum_i (y_i - h_i) x_i$ nochmals nach θ_k (mit $\partial_{\theta_k} h_i = h_i(1-h_i)x_{ik}$):

Legende: H Hesse-Matrix (alle zweiten Ableitungen), S Diagonalmatrix mit $h_i(1-h_i)$, δ Schritt, ℓ_t aktueller Wert, $\nabla \ell$ Gradient.

$$H_{jk} = \frac{\partial^2 \ell}{\partial \theta_j \partial \theta_k} = - \sum_i h_i(1-h_i) x_{ij} x_{ik}$$

$H = -X^\top S X$, $S = \text{diag}(h_i(1-h_i))$
 $v^\top H v = - \sum_i h_i(1-h_i) (x_i^\top v)^2 \leq 0 \Rightarrow \ell$ ist konkav (kein lokales Maximum außer dem globalen). Newton folgt aus der Taylor-Näherung $\ell(\theta) \approx \ell_t + \nabla \ell^\top \delta + \frac{1}{2} \delta^\top H \delta$: Ableiten nach δ und Null setzen gibt $\delta = -H^{-1} \nabla \ell$, also $\theta \leftarrow \theta + (X^\top S X)^{-1} X^\top (y-h)$.

In Worten: Newton ersetzt ℓ lokal durch eine Parabel und springt direkt zu deren Gipfel; die Krümmung H bestimmt die Schrittweite.

3 Softmax: Gradient

$$p_k = \frac{e^{\theta_k^\top x}}{\sum_j e^{\theta_j^\top x}}, \text{ Verlust } L = -\log p_y = -\theta_y^\top x + \log \sum_j e^{\theta_j^\top x}.$$

Legende: k, j Klassenindizes, θ_k Parameter der Klasse k , p_k Wahrscheinlichkeit der Klasse k , y wahre Klasse, $\mathbf{1}\{\cdot\}$ Indikator (1, wenn wahr), L Verlust.

In Worten: Softmax macht Scores zu Wahrscheinlichkeiten; L ist groß, wenn die wahre Klasse wenig Wahrscheinlichkeit bekommt.

$$\begin{aligned} \nabla_{\theta_k} L &= -\mathbf{1}\{k=y\} x + \frac{e^{\theta_k^\top x}}{\sum_j e^{\theta_j^\top x}} x && \text{Ableitung von } \log \sum e^\cdot \\ &= (p_k - \mathbf{1}\{k=y\}) x \end{aligned}$$

Genau wie im binären Fall: (Vorhersage - Wahrheit) × Eingabe.

4 Warum alle GLMs $(y-h)x$ liefern

$$p(y|x; \theta) = b(y) \exp(\eta y - a(\eta)), \quad \eta = \theta^\top x \quad (T(y) = y).$$

Legende: η natürlicher Parameter, $b(y)$ Basisfunktion, $a(\eta)$ Log-Partition (normiert p auf 1), $h = \mathbb{E}[y|x]$ Vorhersage.

In Worten: Bernoulli, Gauß, Poisson usw. haben diese Form (Exponentialfamilie); darum ist der Gradient stets gleich.

$$\begin{aligned} \log p &= \eta y - a(\eta) + \log b(y) \\ \frac{\partial \log p}{\partial \theta_j} &= (y - a'(\eta)) x_j && \text{Kettenregel, } \partial_{\theta_j} \eta = x_j \\ &= (y - h) x_j && a'(\eta) = \mathbb{E}[y; \eta] = h \\ a'(\eta) &= \mathbb{E}[y]: \text{Ableitung von } \int p = 1 \text{ nach } \eta \text{ liefert } \int (y - a') p dy = 0. \end{aligned}$$

Beispiel: Gradient numerisch prüfen (Merkschema: Modell → Log-Likelihood → ableiten → Null setzen → Krümmung prüfen)

$\theta = (0, 0)$, $x = (1, 2)$, $y = 1$. Dann $h = \sigma(0) = 0.5$ (σ : Sigmoid, e_2 : Einheitsvektor der 2. Komponente).

Lösung Formel: $(y-h)x = 0.5 \cdot (1, 2) = (0.5, 1.0)$.

Differenzenquotient ($\varepsilon = 10^{-5}$): $\frac{\ell(\theta + \varepsilon e_2) - \ell(\theta - \varepsilon e_2)}{2\varepsilon} = 1.0$ stimmt (Gradient-Check, Kapitel Backpropagation). In Worten: Steigung numerisch messen, indem θ_2 minimal nach oben und unten verschoben wird.

Logistische Regression mit Skalierung in einer Pipeline

```
from sklearn.datasets import load_breast_cancer
from sklearn.linear_model import LogisticRegression
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
X, y = load_breast_cancer(return_X_y=True)
Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.3, random_state=0, stratify=y)
clf = make_pipeline(StandardScaler(), LogisticRegression(C=1.0, max_iter=1000))
clf.fit(Xtr, ytr) # C = 1/lambda (L2)
print("Accuracy:", round(clf.score(Xte, yte), 3))
print("P(y=1|x) der ersten 3:", clf.predict_proba(Xte[:3])[:, 1].round(3))
```

Ausgabe (real ausgeführt)

Accuracy: 0.959
P(y=1|x) der ersten 3: [0. 0.872 0.001]

? Selbsttest: kannst du das herleiten?

F1 Wo taucht in $\nabla \ell = (y-h)x$ die Ableitung $g' = g(1-g)$ auf?

A: Sie kürzt sich mit den Nennern h und $1-h$ der log-Ableitung heraus.

F2 Warum ist die Log-Likelihood der LogReg konkav?

A: $H = -X^\top S X$ ist negativ semidefinit ($S \succeq 0$).

F3 Wie sieht der Softmax-Gradient aus?

A: $(p_k - \mathbf{1}\{k=y\})x$ für jede Klasse k .

„Ein Gradient, viele Modelle: (Vorhersage - Wahrheit) × Eingabe.“

Generative Modelle

Statt $p(y|x)$ direkt zu lernen: modelliere, wie die Daten jeder Klasse aussehen. ♥

Gaussian Discriminant Analysis & Naive Bayes

Merke:
Bayes: $p(y|x) \propto p(x|y)p(y)$

1 Diskriminativ vs. generativ

Diskriminativ (LogReg): lernt $p(y|x)$ direkt.
Generativ: lernt $p(x|y)$ und $p(y)$, klassifiziert per Bayes:

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)}$$

$$p(x) = \sum_y p(x|y)p(y)$$

2 GDA-Modell


$x|y$ ist multivariat normalverteilt, gemeinsame Kovarianz Σ :

$$y \sim \text{Bernoulli}(\phi)$$

$$x|y=k \sim \mathcal{N}(\mu_k, \Sigma)$$

$$\text{Dichte: } \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} e^{-\frac{1}{2} (x-\mu)^T \Sigma^{-1} (x-\mu)}$$

3 Skizze: zwei Gauß-Wolken



4 GDA: Schätzer (MLE) & Ablauf

Legende: $\mathbf{1}\{\cdot\}$ Indikator (1, wenn wahr), n Anzahl Beispiele, $\hat{\phi}$ Anteil der Klasse 1, $\hat{\mu}_k$ Klassenmittel, $\hat{\Sigma}$ gemeinsame Kovarianz.

$$\hat{\phi} = \frac{1}{n} \sum_i \mathbf{1}\{y^{(i)}=1\}, \quad \hat{\mu}_k = \frac{\sum_i \mathbf{1}\{y^{(i)}=k\} x^{(i)}}{\sum_i \mathbf{1}\{y^{(i)}=k\}}$$

$$\hat{\Sigma} = \frac{1}{n} \sum_i (x^{(i)} - \hat{\mu}_{y^{(i)}})(x^{(i)} - \hat{\mu}_{y^{(i)}})^T$$

Code:

```
</> GDA
train:  $\hat{\phi}, \hat{\mu}_0, \hat{\mu}_1, \hat{\Sigma}$  aus den Daten zählen/mitteln
predict(x):
     $s_k \leftarrow \log \mathcal{N}(x; \hat{\mu}_k, \hat{\Sigma}) + \log p(y=k)$ 
    return argmax_k s_k
```

5 Naive Bayes

Naive Annahme: Features sind gegeben y unabhängig:

$$p(x|y) = \prod_{j=1}^d p(x_j|y)$$

Spam-Filter ($x_j \in \{0,1\}$: Wort j vorhanden?, d Wörter, $\hat{\phi}_{j|k} = P(x_j=1|y=k)$) mit **Laplace-Glättung** gegen Nullwahrscheinlichkeiten:

$$\hat{\phi}_{j|k} = \frac{1 + \sum_i \mathbf{1}\{x_j^{(i)}=1, y^{(i)}=k\}}{2 + \sum_i \mathbf{1}\{y^{(i)}=k\}}$$

6 Naive Bayes: Ablauf

Code:

```
</> Naive Bayes (binäre Features)
train: für jede Klasse k, Feature j:
     $\hat{\phi}_{j|k} \leftarrow (1 + \#\{x_j=1, y=k\}) / (2 + \#\{y=k\})$ 
     $\hat{p}(k) \leftarrow \#\{y=k\} / n$ 
predict(x): return argmax_k
     $\log \hat{p}(k) + \sum_j \log \hat{\phi}_{j|k}$ 
# Summe der Logs statt Produkt: numerisch stabil
```

Beispiel: Spam-Filter mit einem Wort

Aufgabe 10 Trainingsmails: 4 Spam (davon 3 mit „Gratis“), 6 Ham (davon 1 mit „Gratis“). Neue Mail enthält „Gratis“.

Lösung $p(\text{Spam}) = 0.4$; mit Laplace: $P(\text{Gratis}|\text{Spam}) = \frac{3+1}{4+2} = 0.67$,

$P(\text{Gratis}|\text{Ham}) = \frac{1+1}{6+2} = 0.25$.

Spam: $0.67 \cdot 0.4 = 0.267$, Ham: $0.25 \cdot 0.6 = 0.150$.

Normiert: $P(\text{Spam}|x) = 0.267 / 0.417 \approx 0.64 \Rightarrow \text{Spam}$.

7 GDA vs. LogReg

Ist $p(x|y)$ wirklich Gauß, hat der Posterior immer die logistische Form $1/(1+e^{-\theta^T x})$.
GDA: stärkere Annahmen $\Rightarrow$ bei wenig Daten und richtiger Annahme besser.
LogReg: schwächere Annahmen $\Rightarrow$ robuster, wenn die Gauß-Annahme verletzt ist.

8 Vorteile

- ✓ sehr schnell, kein Iterieren
- ✓ wenig Daten reichen
- ✓ skaliert (Naive Bayes)

9 Grenzen

- ✗ starke Verteilungsannahmen
- ✗ „naiv“: korrelierte Features
- ✗ Wahrscheinlichkeiten oft schlecht kalibriert

10 Key Takeaways & Anwendungen

- ✓ Generativ: $p(x|y)p(y)$ + Bayes
- ✓ GDA: Gauß, gleiches $\Sigma \Rightarrow$ lineare Grenze
- ✓ Naive Bayes: Unabhängigkeit + Laplace-Glättung
- ✓ Rechnen mit Log-Wahrscheinlichkeiten (stabil)

* Naive-Bayes-Varianten & allgemeine Glättung (aus den ML Notes)

Gaussian NB: stetige Features, $x_j|y \sim \mathcal{N}$. **Multinomial NB:** Wortzähler (Text). **Bernoulli NB:** Wort vorhanden ja/nein. Allgemeine Glättung:

$$P(x_i|C) = \frac{\text{count}(x_i, C) + \alpha}{\text{count}(C) + \alpha V} \quad (V \text{ Vokabulargröße, } \alpha=1 \text{ Laplace; für Bernoulli } V=2).$$

Beispiel (Vokabular win, cash, prize, offer): $P(\text{Spam}) = 0.6$, $P(\text{win}|S) = 0.4$, $P(\text{cash}|S) = 0.3$, $P(\text{prize}|S) = 0.2$; Ham: 0.4, 0.1, 0.1, 0.05. Mail "win cash prize": Spam $0.6 \cdot 0.4 \cdot 0.3 \cdot 0.2 = 0.0144$ vs. Ham $0.4 \cdot 0.1 \cdot 0.1 \cdot 0.05 = 0.0002 \Rightarrow \text{Spam}$.

? Selbsttest: kannst du das erklären?

F1 Was modelliert GDA (vs. LogReg)?

A: $p(x|y)$ und $p(y)$ (Gauß, gleiches Σ); Klassifikation per Bayes.

F2 Wozu Laplace-Glättung?

A: Verhindert $P=0$ bei ungesesehenen Kombinationen (Zähler +1, Nenner +2).

F3 Wann schlägt LogReg GDA?

A: Wenn die Gauß-Annahme verletzt ist (schwächere Annahmen, robuster).

„Generative Modelle können neue Daten erzeugen – diskriminative nur sortieren.“

MLE-Schätzer von Naive Bayes und GDA – und warum GDA auf eine logistische Form führt. ❤️

Generative Modelle: Vertiefung

Herleitung und Code

Merke:
Der quadratische Term kürzt sich, weil beide Klassen dasselbe Σ haben

Quelle: main_notes.pdf Kap. 4 (GDA, Naive Bayes); Herleitungen ausformuliert; Code: code/sk_nb.py (real ausgeführt)

1 MLE für Naive Bayes & GDA

Legende: $\phi_{j|k} = P(x_j=1|y=k)$, x_{ij} Merkmal j von Beispiel i , $1\{\cdot\}$ Indikator, μ_k Klassenmittel, Σ Kovarianzmatrix, $\#\{\cdot\}$ Anzahl.

Bernoulli-NB:

$$\ell = \sum_i [1\{y_i=k, x_{ij}=1\} \log \phi_{j|k} + 1\{y_i=k, x_{ij}=0\} \log(1 - \phi_{j|k})];$$

Ableiten und Nullsetzen wie bei der Bernoulli-MLE ($\hat{\phi} = k/n$):

$$\hat{\phi}_{j|k} = \frac{\#\{x_j=1, y=k\}}{\#\{y=k\}}.$$

$$\text{GDA: } \nabla_{\mu_k} \sum_{i: y_i=k} -\frac{1}{2} (x_i - \mu_k)^\top \Sigma^{-1} (x_i - \mu_k) = 0 \Rightarrow \hat{\mu}_k =$$

Klassenmittel; $\hat{\Sigma}$ = gemittelte Streumatrix über alle Klassen.

In Worten: MLE heißt hier einfach zählen und mitteln: Anteil der Klasse- k -Beispiele mit Merkmal j , bzw. Klassenmittel und mittlere Streuung.

2 GDA $\Rightarrow$ logistische Form

Gleiches Σ , Prior $\phi = P(y=1)$. Log-Odds per Bayes und Gauß-Dichten:

Legende: $p(y=1|x)$ Posterior, $p(x|k)$ Gauß-Dichte der Klasse k , ϕ Prior, σ Sigmoid, Σ^{-1} inverse Kovarianz, θ_0 Achsenabschnitt.

$$\log \frac{p(y=1|x)}{p(y=0|x)} = \log \frac{p(x|1)}{p(x|0)} + \log \frac{\phi}{1-\phi}$$

$$\begin{aligned} \log \frac{p(x|1)}{p(x|0)} &= -\frac{1}{2} (x - \mu_1)^\top \Sigma^{-1} (x - \mu_1) + \frac{1}{2} (x - \mu_0)^\top \Sigma^{-1} (x - \mu_0) \\ &= (\mu_1 - \mu_0)^\top \Sigma^{-1} x - \frac{1}{2} (\mu_1^\top \Sigma^{-1} \mu_1 - \mu_0^\top \Sigma^{-1} \mu_0) \end{aligned}$$

Der quadratische Term $x^\top \Sigma^{-1} x$ kürzt sich (gleiches Σ). Also $p(y=1|x) = \sigma(\theta^\top x + \theta_0)$ mit $\theta = \Sigma^{-1}(\mu_1 - \mu_0)$.

In Worten: Log-Odds = Dichteverhältnis + Prior-Verhältnis (Bayes). Setzt man die Gauß-Dichten ein, fällt der Quadratterm heraus, übrig bleibt eine lineare Funktion.

Beispiel: GDA-Posterior nachgerechnet

$$\mu_0 = (0, 0), \mu_1 = (2, 1), \Sigma = \begin{pmatrix} 1 & 0.3 \\ 0.3 & 1 \end{pmatrix}, \phi = 0.4, x = (1.5, 1).$$

Lösung $\theta = \Sigma^{-1}(\mu_1 - \mu_0) = (1.868, 0.440)$, $\theta_0 = -2.493$.

$$z = \theta^\top x + \theta_0 = 0.748 \Rightarrow p(y=1|x) = \sigma(0.748) = 0.679 \quad (\text{maschinell geprüft: direkte Bayes-Rechnung liefert dasselbe}).$$

⚡ Multinomial Naive Bayes für Text mit Laplace-Glättung

```
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.naive_bayes import MultinomialNB
docs = ["win cash prize", "win prize now", "cash offer win",
        "meeting tomorrow", "project meeting notes", "lunch tomorrow"]
y = ["spam", "spam", "spam", "ham", "ham", "ham"]
vec = CountVectorizer()
X = vec.fit_transform(docs)
nb = MultinomialNB(alpha=1.0).fit(X, y) # alpha = Laplace-Glättung
print(nb.predict(vec.transform(["win cash now", "meeting notes"])))
print(nb.predict_proba(vec.transform(["win cash now"]))).round(3)
```

Ausgabe (real ausgeführt)

```
['spam' 'ham']
[[0.055 0.945]]
```

? Selbsttest: kannst du das herleiten?

F1 Wie lautet der MLE-Schätzer bei Bernoulli-Naive-Bayes?

A: $\hat{\phi}_{j|k} = \frac{\#\{x_j=1, y=k\}}{\#\{y=k\}}$ (Bernoulli-MLE k/n je Klasse).

F2 Warum ist der GDA-Posterior logistisch?

A: Bei gleichem Σ kürzt sich $x^\top \Sigma^{-1} x$; die Log-Odds sind linear in x .

F3 Wozu die Laplace-Glättung?

A: Verhindert $P = 0$ bei ungesesehenen Kombinationen (+1 im Zähler, +2 im Nenner).

„Generativ modelliert, diskriminativ entschieden: bei Gauß-Klassen führen beide zur selben Grenze.“

Kernel-Methoden

Der Kernel-Trick

Nichtlinear lernen, ohne den hochdimensionalen Feature-Raum je zu berechnen. ❤️

Merke:
Nur Skalarprodukte zählen:
 $K(x, z) = \phi(x)^\top \phi(z)$

1 Feature-Maps

Eine Abbildung $\phi: \mathbb{R}^d \rightarrow \mathbb{R}^p$ macht ein lineares Modell nichtlinear:
 $h(x) = \theta^\top \phi(x)$. Problem: p kann riesig (sogar unendlich) sein $\Rightarrow \phi(x)$ explizit auszurechnen ist zu teuer.

2 Der Kernel-Trick


Legende: ϕ Feature-Map, K Kernel, β_i Gewicht von Trainingspunkt i , n Anzahl Trainingspunkte.

Die Lösung ist stets $\theta = \sum_i \beta_i \phi(x^{(i)})$.
Damit

$$h(x) = \sum_{i=1}^n \beta_i \underbrace{\phi(x^{(i)})^\top \phi(x)}_{K(x^{(i)}, x)}$$

$K(x, z)$ oft in $O(d)$ berechenbar, obwohl ϕ riesig ist.

3 Skizze: Anheben in 2D



4 Wichtige Kernels

Kernel	$K(x, z)$	Feature-Raum
Linear	$x^\top z$	$\mathbb{R}^d$
Polynom	$(x^\top z + c)^k$	$O(d^k)$ -dim.
Gauß (RBF)	$\exp(-\frac{\ x-z\ ^2}{2\sigma^2})$	∞ -dim.

RBF: σ klein $\rightarrow$ sehr lokal (Overfitting), σ groß $\rightarrow$ fast linear.

5 Mercers Satz: wann ist K gültig?

K ist genau dann ein Kernel, wenn für beliebige Punkte die **Gram-Matrix** $[K]_{ij} = K(x^{(i)}, x^{(j)})$ **symmetrisch und positiv semidefinit** ist.

Bausteine: Summe, positive Skalierung und Produkt gültiger Kernels sind wieder Kernels.

6 Representer-Theorem

Legende: L Verlustfunktion, λ Regularisierungsstärke, α_i Gewicht von Punkt i , L' Ableitung von L .

Für $J_\lambda(\theta) = \frac{1}{n} \sum_i L(\theta^\top x^{(i)}, y^{(i)}) + \frac{\lambda}{2} \|\theta\|^2$ mit konvexem L gibt es ein Optimum

$$\theta = \sum_{i=1}^n \alpha_i x^{(i)}$$

Beweisidee:

$$\nabla J = \frac{1}{n} \sum_i L'(\cdot) x^{(i)} + \lambda \theta = 0 \Rightarrow \theta = -\frac{1}{n\lambda} \sum_i L'(\cdot) x^{(i)}.$$

Rechtfertigt den Kernel-Trick.

7 Kernelisierte Regression

Kernel-LMS

```

init  $\beta \leftarrow 0$ 
repeat bis Konvergenz, for  $i = 1..n$ :
   $r \leftarrow y_i - \sum_j \beta_j K(x_j, x_i)$ 
   $\beta_i \leftarrow \beta_i + \alpha r$ 
predict( $x$ ):  $\sum_i \beta_i K(x_i, x)$ 
# Gram-Matrix  $K$  vorher berechnen:  $O(n^2)$ 
```

Beispiel: Polynom-Kernel $K(x, z) = (x^\top z)^2$

$x = (1, 2)$, $z = (3, 1)$. **Lösung**

Kernel: $x^\top z = 3 + 2 = 5 \Rightarrow K = 25$.

Explizit: $\phi(x) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$: $\phi(x) = (1, 2.83, 4)$, $\phi(z) = (9, 4.24, 1)$

$\phi(x)^\top \phi(z) = 9 + 12 + 4 = 25$ **gleiches Ergebnis, viel billiger**

8 Vorteile

- ✓ nichtlinear ohne Feature-Design
- ✓ konvexe Optimierung bleibt
- ✓ Kernel für Text, Graphen, Strings

9 Grenzen

- × Gram-Matrix: $O(n^2)$ Speicher/Zeit
- × Wahl von Kernel & Parametern
- × schlecht skalierbar bei großem n

10 Key Takeaways

- ✓ $K(x, z) = \phi(x)^\top \phi(z)$
- ✓ $\theta = \sum \beta_i \phi(x_i)$ (Representer)
- ✓ Gültig $\Leftrightarrow$ Gram-Matrix PSD

11 Wo Kernels vorkommen

- SVM (nächstes Kapitel)
- Kernel-Ridge/Gauß-Prozesse
- Kernel-PCA, Kernel- k -Means

? Selbsttest: kannst du das erklären?

F1 Wann ist K ein gültiger Kernel?

A: Gram-Matrix symmetrisch und positiv semidefinit (Mercer).

F2 Was sagt das Representer-Theorem?

A: Es gibt ein Optimum $\theta = \sum \alpha_i x^{(i)} \Rightarrow$ Kernel-Trick anwendbar.

F3 Wirkung von σ beim RBF-Kernel?

A: Klein: sehr lokal (Overfitting); groß: fast linear.

„Nichtlinearität zum Preis eines Skalarprodukts.“

Support Vector Machines

Maximaler Margin, Dualität & Kernel

Finde die Trennlinie mit dem größten Abstand zu beiden Klassen. ♥

Merke:
Nur die Support Vectors ($\alpha_i > 0$) bestimmen die Grenze!

Quelle: main_notes.pdf (Kap. SVM), notes/cs229-notes3.pdf, materials/smo.pdf, section/cs229-ovxopt2.pdf

1 Idee: Margin

Labels $y \in \{-1, +1\}$, Klassifikator $\text{sign}(w^\top x + b)$.

Funktionaler Margin:

$$\hat{\gamma}^{(i)} = y^{(i)}(w^\top x^{(i)} + b)$$

Geometrischer Margin: $\gamma^{(i)} = \hat{\gamma}^{(i)} / \|w\|$ (echter Abstand).

Ziel: den **kleinsten** geometrischen Margin maximieren.


2 Primal (trennbar)

Normierung $\min_i \hat{\gamma}^{(i)} = 1$ liefert ein konvexes quadratisches Programm:

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y^{(i)}(w^\top x^{(i)} + b) \geq 1$$

Margin-Breite = $2/\|w\|$.

3 Skizze



4 Dual-Form & Kernel

Lagrange: $w = \sum_i \alpha_i y^{(i)} x^{(i)}$. Dual-Problem:

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y^{(i)} y^{(j)} \langle x^{(i)}, x^{(j)} \rangle$$

s.t. $\alpha_i \geq 0$, $\sum_i \alpha_i y^{(i)} = 0$. **Nur Skalarprodukte** $\Rightarrow$ ersetze durch $K(x^{(i)}, x^{(j)})$:

$$f(x) = \sum_i \alpha_i y^{(i)} K(x^{(i)}, x) + b$$

5 Soft-Margin (nicht trennbar)

Schlupfvariablen $\xi_i \geq 0$ erlauben Verletzungen:

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_i \xi_i \quad \text{s.t.} \quad y^{(i)}(w^\top x^{(i)} + b) \geq 1 - \xi_i$$

Dual: nur $0 \leq \alpha_i \leq C$. Gleichbedeutend mit **Hinge-Verlust**

$$\xi_i = \max(0, 1 - y^{(i)} f(x^{(i)})).$$

C groß $\rightarrow$ wenige Fehler (Overfitting), C klein $\rightarrow$ großer Margin.

6 KKT-Bedingungen

Allgemein: Primal-/Dual-Zulässigkeit, Complementary Slackness $\alpha_i g_i = 0$, Stationarität. Für die SVM:

- $\alpha_i = 0 \Rightarrow y_i f_i \geq 1$
- $0 < \alpha_i < C \Rightarrow y_i f_i = 1$
- $\alpha_i = C \Rightarrow y_i f_i \leq 1$

7 SMO-Algorithmus (vereinfacht)

Aktualisiert immer zwei α gleichzeitig (wegen $\sum \alpha_i y_i = 0$). Grenzen: $y_i \neq y_j$: $L = \max(0, \alpha_j - \alpha_i)$, $H = \min(C, C + \alpha_j - \alpha_i)$; sonst $L = \max(0, \alpha_i + \alpha_j - C)$, $H = \min(C, \alpha_i + \alpha_j)$.

`</> Simplified SMO`

$\alpha \leftarrow 0, b \leftarrow 0$

repeat bis sich kein α mehr ändert:

for $i = 1..n$: **if** α_i verletzt KKT (Toleranz):

wähle $j \neq i$ zufällig; $E_k \leftarrow f(x_k) - y_k$

$\eta \leftarrow 2K_{ij} - K_{ii} - K_{jj}$; **if** $\eta = 0$: **continue**

$\alpha_j \leftarrow \text{clip}_{[L,H]}(\alpha_j - y_j(E_i - E_j)/\eta)$

$\alpha_i \leftarrow \alpha_i + y_i y_j (\alpha_j^{\text{alt}} - \alpha_j)$

$b \leftarrow$ so, dass KKT für i, j gilt (Mittel von b_1, b_2)

Beispiel: 1D-SVM von Hand

Aufgabe $x = -1, 0$ mit $y = -1$; $x = 2, 3$ mit $y = +1$. Finde w, b, α und klassifiziere $x = 1.4$.

Lösung Support Vectors: $x = 0$ ($y = -1$) und $x = 2$ ($y = +1$): $b = -1, 2w + b = 1 \Rightarrow w = 1$.

Margin-Breite $2/\|w\| = 2$, Grenze bei $x = 1$. Kontrolle: $x = 3$: $f = 2 \geq 1 \checkmark$, $x = -1$: $yf = 2 \geq 1 \checkmark$.

Dual: $w = 2\alpha_{(2)} = 1 \Rightarrow \alpha_{(2)} = 0.5$, $\sum \alpha y = 0 \Rightarrow \alpha_{(0)} = 0.5$; alle anderen $\alpha = 0$.

$f(1.4) = 1.4 - 1 = 0.4 > 0 \Rightarrow$ Klasse **+1**.

11 Varianten, Kernels & Praxis (aus den ML Notes)

Linear, nichtlinear (Kernel), SVR (Regression, ϵ -Schlauch). Kernels: linear, Polynom $(\gamma x^\top z + r)^d$, RBF $e^{-\gamma \|x-z\|^2}$, Sigmoid. γ klein: glatt; groß: lokal, Overfitting. Praxis: C, γ per CV, Features skalieren, Multiklasse one-vs-rest, erst linear, dann RBF.

8 Vorteile

- ✓ konvex, globales Optimum
- ✓ Kernel $\Rightarrow$ nichtlinear
- ✓ sparse: nur Support Vectors zählen
- ✓ gut bei hoher Dimension

9 Grenzen

- ✗ Training teuer bei großem n
- ✗ liefert keine Wahrscheinlichkeiten
- ✗ Wahl von C und Kernel-Parametern

10 Key Takeaways

- ✓ Max. Margin: $\min \frac{1}{2} \|w\|^2$
- ✓ Dual + Kernel: $f = \sum \alpha_i y_i K + b$
- ✓ Soft-Margin: C steuert Trade-off
- ✓ SMO: 2 α pro Schritt

? Selbsttest: kannst du das erklären?

F1 Was sind Support Vectors?

A: Punkte mit $\alpha_i > 0$; nur sie bestimmen die Grenze.

F2 Rolle von C ?

A: Klein: großer Margin, mehr Fehler; groß: wenige Fehler, Overfitting-Risiko.

F3 Warum sind SVMs kernelfähig?

A: Das Dual enthält nur $\langle x_i, x_j \rangle \rightarrow K(x_i, x_j)$.

„Nicht die Masse der Daten entscheidet, sondern die wenigen Punkte am Rand.“

Support Vector Machines: Vertiefung

Vom Margin zum Dual:
Lagrange-Funktion, Stationarität und der Kernel-Trick.



Herleitung: Margin, Dual, Soft-Margin

Merke:

Nur Skalarprodukte tauchen im Dual auf -- deshalb Kernels!

Quelle: main_notes.pdf Kap. 6 (Margins, Lagrange duality, dual form, SMO), materials/smo.pdf, section/cv229-cvxo2.pdf; Schritte ergänzt; Code: code/sk_svm.py (real ausgeführt)

1 Der Margin ist $2/\|w\|$

Legende: $w \in \mathbb{R}^d$ Normalenvektor der Trennebene, b Offset, x_i Trainingspunkt, $y_i \in \{-1, +1\}$ Klasse, γ Margin (Abstand), $\|w\|$ Länge von w .

Abstand eines Punkts x zur Ebene $w^\top x + b = 0$: $\frac{|w^\top x + b|}{\|w\|}$
(Projektion auf den Normalenvektor). Mit Normierung $\min_i y_i(w^\top x_i + b) = 1$ liegen die nächsten Punkte bei $w^\top x + b = \pm 1$:

$$\gamma = \frac{1}{\|w\|} \text{ je Seite, } \text{Breite} = \frac{2}{\|w\|}$$

Margin maximieren = $\|w\|$ minimieren: $\min \frac{1}{2}\|w\|^2$ s.t.

$y_i(w^\top x_i + b) \geq 1$ (konvexes QP).

In Worten: Der Score $w^\top x + b$ geteilt durch $\|w\|$ ist der echte Abstand. Legt man den nächsten Punkt auf Score 1, ist der Streifen $2/\|w\|$ breit: großer Margin heißt kleines $\|w\|$.

2 Lagrange-Funktion

Nebenbedingung $g_i = 1 - y_i(w^\top x_i + b) \leq 0$, Multiplikatoren $\alpha_i \geq 0$:

Legende: $\mathcal{L}$ Lagrange-Funktion, α_i Multiplikator (Gewicht) je Nebenbedingung, g_i Nebenbedingung (≤ 0 heißt erfüllt).

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2}\|w\|^2 - \sum_i \alpha_i [y_i(w^\top x_i + b) - 1]$$

Primal = $\min_{w,b} \max_{\alpha \geq 0} \mathcal{L}$. Duales Problem: $\max_{\alpha \geq 0} \min_{w,b} \mathcal{L}$. (Konvex + Slater $\Rightarrow$ starke Dualität, beide gleich.)

In Worten: Die Nebenbedingungen werden mit Strafgewichten α_i in die Zielfunktion gezogen; $\max_{\alpha}$ bestraft jede Verletzung beliebig hart, sodass nur zulässige w, b übrig bleiben.

3 Stationarität: $\min_{w,b} \mathcal{L}$

$$\nabla_w \mathcal{L} = w - \sum_i \alpha_i y_i x_i = 0 \Rightarrow w = \sum_i \alpha_i y_i x_i$$

$$\frac{\partial \mathcal{L}}{\partial b} = -\sum_i \alpha_i y_i = 0 \Rightarrow \sum_i \alpha_i y_i = 0$$

w ist eine Linearkombination der Trainingspunkte – nur Punkte mit $\alpha_i > 0$ (Support Vectors) zählen.

In Worten: Gradient null setzen: w ist die mit $\alpha_i y_i$ gewichtete Summe der Punkte. Punkte mit $\alpha_i = 0$ fallen heraus.

4 Einsetzen ergibt das Dual

$$\begin{aligned} \mathcal{L} &= \frac{1}{2}\|w\|^2 - w^\top \underbrace{\sum_i \alpha_i y_i x_i}_{=w} - b \underbrace{\sum_i \alpha_i y_i}_{=0} + \sum_i \alpha_i \\ &= \sum_i \alpha_i - \frac{1}{2}\|w\|^2 \\ &= \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle \end{aligned}$$

Legende: $\langle x_i, x_j \rangle = x_i^\top x_j$ Skalarprodukt; underbrace zeigt, welcher Term durch die Stationarität ersetzt wird.

In Worten: Rückeinsetzen eliminiert w und b ; das Problem hängt nur noch von α ab, und die Daten treten nur als Skalarprodukte auf.

5 Dual-Problem & Kernel

$$\max_{\alpha} W(\alpha) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$

Legende: $W(\alpha)$ duale Zielfunktion, $K(x_i, x_j)$ Kernel (Skalarprodukt im Feature-Raum), f Entscheidungsfunktion.

s.t. $\alpha_i \geq 0$, $\sum_i \alpha_i y_i = 0$. Vorhersage $f(x) = \sum_i \alpha_i y_i K(x_i, x) + b$. Ersetzt man $\langle x_i, x_j \rangle$ durch K , arbeitet die SVM implizit im (ggf. unendlichdimensionalen) Feature-Raum.

6 Soft-Margin & KKT

Legende: C Strafparameter, $\xi_i \geq 0$ Schlupf (wie stark Punkt i den Margin verletzt), $f_i = f(x_i)$, μ_i Multiplikator zu $\xi_i \geq 0$.

$\min \frac{1}{2}\|w\|^2 + C \sum \xi_i$ s.t. $y_i f_i \geq 1 - \xi_i$, $\xi_i \geq 0$. Ableiten der Lagrange-Funktion nach ξ_i : $C - \alpha_i - \mu_i = 0$ mit $\mu_i \geq 0 \Rightarrow 0 \leq \alpha_i \leq C$ (sonst dasselbe Dual).

Complementary Slackness $\alpha_i [y_i f_i - 1 + \xi_i] = 0$ liefert $\alpha_i = 0 \Rightarrow y_i f_i \geq 1$; $0 < \alpha_i < C \Rightarrow y_i f_i = 1$; $\alpha_i = C \Rightarrow y_i f_i \leq 1$.

In Worten: Ist eine Nebenbedingung nicht aktiv (Punkt weit genug innen), muss ihr Gewicht α_i null sein; nur Punkte am oder im Margin tragen bei.

SVM: Praxis

Wie wird das Dual in der Praxis gelöst? SMO, ein Rechenbeispiel und getesteter Code. 

SMO, Beispiel und Code mit sklearn

Merke:
Zwei α auf einmal: eine Parabel statt eines großen QP

Quelle: main_notes.pdf Kap. 6 (Margins, Lagrange duality, dual form, SMO), materials/smo.pdf, section/cs229-cvxo2.pdf; Schritte ergänzt; Code: code/sk_svm.py (real ausgeführt)

7 SMO: zwei α gleichzeitig

Legende: ζ Konstante, $E_k = f(x_k) - y_k$ Fehler von Punkt k , η Krümmung der Parabel (nicht der GLM-Parameter), $[L, H]$ erlaubtes Intervall für α_j .

Wegen $\sum \alpha_i y_i = 0$ kann ein einzelnes α nicht allein geändert werden. Wähle α_i, α_j : $\alpha_i = \zeta - y_i y_j \alpha_j$ (Konstante ζ).
Eingesetzt wird W eine quadratische Funktion von α_j ; Nullsetzen der Ableitung liefert

$$\alpha_j \leftarrow \alpha_j - \frac{y_j (E_i - E_j)}{\eta}, \quad \eta = 2K_{ij} - K_{ii} - K_{jj}, \quad E_k = f(x_k) - y_k$$

und anschließendes Clipping auf $[L, H]$ (aus $0 \leq \alpha \leq C$), dann α_i aus der Gleichheit.

In Worten: Mit zwei freien α bleibt nur eine Parabel in einer Variablen: sie lässt sich exakt lösen, ohne ein großes QP zu rechnen.

Beispiel: Dual in 1D lösen

Punkte $x = 0$ ($y = -1$, Gewicht α_a) und $x = 2$ ($y = +1$, Gewicht α_b); W ist die duale Zielfunktion.

Lösung Nebenbedingung: $\alpha_a = \alpha_b =: \alpha$. Nur der Term (b, b) ist $\neq 0$ (wegen $x_a = 0$):

$$W = 2\alpha - \frac{1}{2}\alpha^2 \cdot (2 \cdot 2) = 2\alpha - 2\alpha^2, \quad W' = 2 - 4\alpha = 0 \Rightarrow \alpha = \mathbf{0.5}, \quad W = 0.5.$$

$$w = \sum \alpha_i y_i x_i = 0.5 \cdot 2 = 1 \Rightarrow \frac{1}{2} \|w\|^2 = 0.5 = W$$

(Primal = Dual) .

(/) SVM mit RBF-Kernel und Gitter-Suche für C, γ

```
from sklearn.datasets import make_moons
from sklearn.svm import SVC
from sklearn.model_selection import GridSearchCV, train_test_split
X, y = make_moons(300, noise=0.25, random_state=0)
Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.3, random_state=0)
grid = {'C': [0.1, 1, 10], 'gamma': [0.1, 1, 10]}
gs = GridSearchCV(SVC(kernel='rbf'), grid, cv=5).fit(Xtr, ytr)
print("beste Parameter:", gs.best_params_)
print("Test-Accuracy :", round(gs.score(Xte, yte), 3))
print("Support Vectors:", gs.best_estimator_.n_support_)
```

Ausgabe (real ausgeführt)

```
beste Parameter: {'C': 1, 'gamma': 10}
Test-Accuracy : 0.989
Support Vectors: [45 49]
```

? Selbsttest: kannst du das herleiten?

F1 Warum ist $\sum_i \alpha_i y_i = 0$?

A: Ableitung der Lagrange-Funktion nach b gleich Null.

F2 Woher kommt die Schranke $\alpha_i \leq C$?

A: Aus $C - \alpha_i - \mu_i = 0$ mit $\mu_i \geq 0$ (Multiplikator der Bedingung $\xi_i \geq 0$).

F3 Warum ändert SMO zwei α ?

A: Die Gleichheitsbedingung $\sum \alpha_i y_i = 0$ verbietet ein einzelnes Update.

„Primal in w , Dual in α -- und im Dual stecken nur noch Skalarprodukte.“

Online-Lernen: erst vorher-sagen, dann das wahre Label sehen. Gezählt werden die Fehler. ❤️

Perceptron & Online Learning

Lernen aus einem Strom von Beispielen

Merke:
Fehlerschranke $(D/\gamma)^2$ --
unabhängig von n und d !

Quelle: notes/cs229-notes6.pdf (Perceptron and large margin classifiers)

1 Online vs. Batch


Batch: Trainingsdaten vorab, danach Test.
Online: Beispiele kommen nacheinander;
für jedes $x^{(i)}$ wird zuerst vorhergesagt,
dann $y^{(i)}$ enthüllt. Bewertung:

Gesamtzahl der Fehler .

2 Perceptron-Regel

$y \in \{-1, +1\}$, $h_\theta(x) = g(\theta^\top x)$ mit
 $g(z) = +1$ für $z \geq 0$, sonst -1 .
Update nur bei Fehler (θ Gewichte, x
Merkmale, y wahres Label):
 $\theta \leftarrow \theta + yx$
Lernrate egal (skaliert nur θ).

3 Skizze: ein Update



4 Algorithmus

```
</> Perceptron (online)
theta ← 0
for t = 1, 2, ... (Strom von Beispielen):
    y_hat ← sign(theta^T x_t) # Vorhersage
    if y_hat ≠ y_t: # Label enthüllt
        theta ← theta + y_t x_t
    mistakes ← mistakes + 1
```

Nicht-probabilistisch; passt sich bei jedem Fehler an. Trennbare
Daten $\Rightarrow$ nach endlich vielen Fehlern fehlerfrei.

5 Satz von Block & Novikoff (1962)

Gilt $\|x^{(i)}\| \leq D$ und trennt ein Einheitsvektor u die Daten mit
Margin γ ($y^{(i)} u^\top x^{(i)} \geq \gamma$), macht der Perceptron höchstens
 $(D/\gamma)^2$ Fehler.

Beweisidee ($\theta^{(k)}$ = Parameter beim k -ten Fehler):

- $\theta^{(k+1)\top} u \geq k\gamma$ (wächst linear)
- $\|\theta^{(k+1)}\|^2 \leq kD^2$ (wächst höchstens linear)
- Cauchy-Schwarz: $k\gamma \leq \sqrt{k}D \Rightarrow k \leq (D/\gamma)^2$

Beispiel: 2 Fehler, dann fertig

Folge: $(x_1=(1,2), y=-1)$, $(x_2=(2,1), y=+1)$, wiederholt. Start
 $\theta = (0,0)$.

Lösung (1) $\theta^\top x_1 = 0 \Rightarrow \hat{y} = +1 \neq -1$: Fehler, $\theta = (-1, -2)$.

(2) $\theta^\top x_2 = -4 \Rightarrow \hat{y} = -1 \neq +1$: Fehler,
 $\theta = (-1, -2) + (2, 1) = (1, -1)$.

(3) $x_1: -1 \Rightarrow -1$ ✓ (4) $x_2: +1 \Rightarrow +1$ ✓

Kontrolle: $D = \sqrt{5}$, $\gamma = 1/\sqrt{2} \Rightarrow (D/\gamma)^2 = 10 \geq 2$

Schranke erfüllt .

6 Verbindung zu anderen Kapiteln

- SVM:** gleiche Margin-Sprache, die Schranke wächst mit $1/\gamma^2$.
- Kernel-Perceptron:** $\theta = \sum \beta_i \phi(x_i)$, Vorhersage über K
(Aufgabenblatt 2).
- Logistische Regression:** ähnliche Regel, aber mit weichem h .

7 Vorteile

- ✓ extrem einfach & schnell
- ✓ speichert nur θ
- ✓ Fehlerschranke ohne n, d

8 Grenzen

- ✗ nur bei Trennbarkeit sinnvoll
- ✗ kein Wahrscheinlichkeitsmodell
- ✗ Ergebnis hängt von Reihenfolge ab

9 Key Takeaways

- ✓ Update nur bei Fehler: $\theta \leftarrow \theta + yx$
- ✓ Mistake Bound $(D/\gamma)^2$
- ✓ Bindeglied zu SVM & Kernels

? Selbsttest: kannst du das erklären?

F1 Wie lautet die Fehlerschranke?

A: $\leq (D/\gamma)^2$, unabhängig von n und d .

F2 Wann ändert sich θ ?

A: Nur bei Fehlklassifikation: $\theta \leftarrow \theta + yx$.

F3 Nicht trennbare Daten?

A: Keine Konvergenz: es treten immer
wieder Fehler auf.

„Lerne nur aus deinen Fehlern -- und beweise, dass es nur endlich viele sind.“

k-Nearest Neighbors

Lazy Learning: kein Training – vorhergesagt wird über die nächsten Nachbarn.



Merke:
Abstände zählen: Features vorher skalieren!

Nichtparametrisch, einfach, überraschend stark

Quelle: hand-notes/ML Notes.pdf (KNN); Ergänzungen (Fluch der Dimension, Bezug zu Bias/Varianz) aus dem Kursstoff


1 Idee

Für einen neuen Punkt x : suche die k ähnlichsten Trainingspunkte und übernimm ihre **Mehrheitsklasse** (Klassifikation) oder ihren **Mittelwert** (Regression). Nichtparametrisch: die Daten sind das Modell.

2 Algorithmus

```
</> k-NN-Vorhersage
for jedes  $x_i$ :  $d_i \leftarrow \text{dist}(x, x_i)$ 
 $\mathcal{N} \leftarrow$  Indizes der  $k$  kleinsten  $d_i$ 
classify:  $\arg \max_c \sum_{i \in \mathcal{N}} \mathbf{1}[y_i = c]$ 
regress:  $\frac{1}{k} \sum_{i \in \mathcal{N}} y_i$ 
```

3 Skizze: $k = 3$



4 Abstandsmaße

Euklid: $d(x, z) = \sqrt{\sum_j (x_j - z_j)^2}$
 Manhattan: $d(x, z) = \sum_j |x_j - z_j|$
 Minkowski: $d(x, z) = (\sum_j |x_j - z_j|^p)^{1/p}$
 Kosinus: $d(x, z) = 1 - \frac{x^\top z}{\|x\| \|z\|}$

Legende: x, z zwei Punkte, j Merkmalsindex, p Exponent (Minkowski).

$p = 2$ Euklid, $p = 1$ Manhattan. Kosinus für Text (Richtung statt Länge).

5 Wahl von k (Bias-Varianz)

k klein $\rightarrow$ flexible Grenze, hohe Varianz (Overfitting, $k=1$: Trainingsfehler 0). k groß $\rightarrow$ glatt, hoher Bias (Underfitting).
 Faustregel: ungerades k bei 2 Klassen; k per **Kreuzvalidierung** wählen.
sklearn: `n_neighbors`, `weights='uniform'/'distance'`, `metric`, `p`.

Beispiel: die Vorhersage hängt von k ab

Anfrage (0, 0); Trainingspunkte:

Punkt	(1, 0)	(0, 2)	(1, 2)	(3, 0)	(0, 4)
Abstand	1	2	2.24	3	4
Klasse	A	B	B	A	A

Lösung $k = 1$: A. $k = 3$: A, B, B $\Rightarrow$ B. $k = 5$: A, B, B, A, A $\Rightarrow$ A (3:2).

Regression mit $y = (3, 5, 4, 8, 9)$, $k = 3$: $\frac{3+5+4}{3} = 4$.

6 Fluch der Dimension

In hohen Dimensionen sind alle Punkte etwa gleich weit entfernt: "nächste" Nachbarn sind nicht mehr nah. Abhilfe: Features auswählen, PCA, mehr Daten. Aufwand naiv $O(nd)$ pro Anfrage; Beschleunigung mit k-d-Baum/Ball-Tree (nur niedrige d).

7 Vorteile

- ✓ kein Training, sehr einfach
- ✓ nichtlineare Grenzen
- ✓ Klassifikation und Regression

8 Grenzen

- ✗ langsame Vorhersage bei großem n
- ✗ empfindlich bei Skalierung/Ausreißern
- ✗ leidet unter hoher Dimension

9 Key Takeaways

- ✓ Mehrheit/Mittel der k Nachbarn
- ✓ k steuert Bias-Varianz
- ✓ skalieren + Abstand wählen

? Selbsttest: kannst du das erklären?

F1 Warum ist $k=1$ overfittet?

A: Jeder Trainingspunkt ist sein eigener Nachbar $\Rightarrow$ Trainingsfehler 0, sehr wackelige Grenze (hohe Varianz).

F2 Warum skalieren?

A: Ein Feature mit großer Skala dominiert den Abstand.

F3 Warum leidet k-NN in hohen Dimensionen?

A: Abstände konzentrieren sich; "nächste" Nachbarn sind kaum näher als andere Punkte.

„Sage mir, wer deine Nachbarn sind, und ich sage dir, wer du bist.“

Decision Trees

Nichtlinear, interpretierbar, aber instabil

Ja/Nein-Fragen zerlegen den Raum in Rechtecke, jedes mit eigener Vorhersage. ❤️

Merke:
Zum Splitten Cross-Entropy nehmen -- nicht die Fehlerrate!

Quelle: notes/cs229-notes-dt.pdf (Decision Trees, R. Townshend)

1 Idee

Zerlege $\mathcal{X}$ in disjunkte Regionen $R_1, \dots, R_m$ und sage pro Region konstant voraus: Mehrheitsklasse (Klassifikation) bzw. Mittelwert (Regression). Erstes

genuin nichtlineares Verfahren im Kurs.

2 Greedy-Split

Optimale Regionen zu finden ist inaktuell $\Rightarrow$ gierig, top-down:

$$R_1 = \{x \in R_p : x_j < t\},$$


$$R_2 = \{x \in R_p : x_j \geq t\}.$$

Legende: R_p Eltern-Region, R_1, R_2 Kinder, j Feature, t Schwelle, L Unreinheit einer Region, $|R|$ Anzahl Beispiele.

Wähle (R_p, j, t) mit maximalem Rückgang:

$$L(R_p) - \frac{|R_1|L(R_1) + |R_2|L(R_2)}{|R_1| + |R_2|}$$

3 Skizze: Baum & Regionen



4 Split-Verluste

$$L_{\text{misclass}} = 1 - \max_c \hat{p}_c$$

$$L_{\text{cross}} = - \sum_c \hat{p}_c \log_2 \hat{p}_c \quad (\text{Information Gain})$$

$$L_{\text{Gini}} = 1 - \sum_c \hat{p}_c^2$$

$$L_{\text{squared}} = \frac{1}{|R|} \sum_{i \in R} (y_i - \hat{y})^2 \quad (\text{Regression})$$

Legende: $\hat{p}_c$ Anteil der Klasse c in der Region, $\hat{y}$ Mittelwert der Region, R Region.

Cross-Entropy/Gini sind **strikt konkav**: jeder informative Split senkt den Verlust; die Fehlerrate nicht.

5 Algorithmus

grow(R):

```

if Stopp(R): return Blatt(Mehrheit/Mittel)
(j, t) ← argmax Gain über alle Features/Schwellen
R1 ← {x ∈ R: xj < t}, R2 ← {x ∈ R: xj ≥ t}
return Knoten(j, t, grow(R1), grow(R2))
prune: erst voll wachsen, dann Knoten entfernen,
die den Validierungsfehler am wenigsten erhöhen
    
```

Beispiel: warum Cross-Entropy?

Eltern: 400+/100- ($p = 0.8$). Split A: 150+/100- & 250+/0-. Split B: 300+/100- & 100+/0-.

Fehlerrate: Eltern 0.2; A: $\frac{250 \cdot 0.4 + 0}{500} = 0.2$; B: $\frac{400 \cdot 0.25 + 0}{500} = 0.2 \Rightarrow$

kein Unterschied!

Cross-Entropy: Eltern 0.722; A: $0.5 \cdot 0.971 = 0.485$ (Gain 0.237); B: $0.8 \cdot 0.811 = 0.649$ (Gain 0.073) $\Rightarrow$ A ist besser.

6 Regularisierung & Praxis

Voll ausgewachsen (1 Punkt/Blatt) $\Rightarrow$ niedriger Bias, hohe Varianz. Stopp-Regeln: Mindest-Blattgröße, max. Tiefe, max. Blattzahl – oder Pruning.

Kategoriale Features: direkt per Teilmengen-Frage ($x_j \in S$); Vorsicht bei vielen Kategorien ($2^{|S|}$ Fragen).

Laufzeit: Vorhersage $O(\text{Tiefe})$, Training $O(nf \cdot \text{Tiefe})$.

7 Vorteile

- ✓ leicht erklärbar
- ✓ kategoriale Daten nativ
- ✓ schnell, keine Skalierung nötig

8 Grenzen

- ✗ hohe Varianz (instabil)
- ✗ additive Struktur ($x_1 + x_2$) nur mit vielen Splits
- ✗ einzeln oft geringe Genauigkeit

9 Key Takeaways

- ✓ Greedy, rekursive Splits
- ✓ Cross-Entropy/Gini statt Fehlerrate
- ✓ Pruning gegen Overfitting
- ✓ Lösung der Instabilität: Ensembles

* Information Gain & Hyperparameter (aus den ML Notes)

Entropy(S) = $-\sum_i p_i \log_2 p_i$, IG(S, A) = Entropy(S) - $\sum_v \frac{|S_v|}{|S|} \text{Entropy}(S_v)$ (Teilmengen S_v je Wert v von Feature A). Algorithmen:

ID3 (IG), **C4.5** (Gain Ratio, korrigiert Bias zu vielwertigen Features), **CART** (Gini, auch Regression via Varianzreduktion).

Stoppkriterien: max. Tiefe, Mindestzahl Beispiele pro Knoten/Blatt, kein Gain mehr. sklearn: criterion, max_depth, min_samples_split, min_samples_leaf, max_features. Pruning: Pre (früh stoppen) oder Post (Cost-Complexity, danach zurückschneiden).

? Selbsttest: kannst du das erklären?

F1 Warum Cross-Entropy statt Fehlerrate?

A: Strikt konkav: informative Splits senken den Verlust immer; die Fehlerrate kann gleich bleiben.

F2 Wie regularisiert man Bäume?

A: Max. Tiefe, Mindest-Blattgröße, Pruning per Validierungsfehler.

F3 Schwäche bei $x_1 + x_2$?

A: Additive Struktur braucht viele achsenparallele Splits.

„Ein Baum erklärt sich selbst -- ein Wald wird genauer.“

Ensemble-Methoden

Viele Modelle schlagen eins:
Bagging senkt die Varianz,
Boosting den Bias. ❤️

Bagging, Random Forests & Boosting

Merke:
 $\text{Var}(\bar{X}) = \rho\sigma^2 + \frac{1-\rho}{n}\sigma^2$

Quelle: notes/cs229-notes-ensemble.pdf (R. Townshend), extra-notes/boosting.pdf (J. Duchi); Web-Zusatz zu XGBoost markiert

1 Warum Ensembles?

Mittel von n Modellfehlern (Varianz σ^2 , Korrelation ρ):


$$\text{Var} = \rho\sigma^2 + \frac{1-\rho}{n}\sigma^2$$

Mehr Modelle ($n \uparrow$) und
weniger Korrelation ($\rho \downarrow$) senken die Varianz.

2 Bagging

Bootstrap: (M Modelle, n Daten) M Stichproben mit Zurücklegen (Größe n), je ein Modell G_m , dann $G(x) = \frac{1}{M} \sum_m G_m(x)$. Senkt Varianz, Bias steigt leicht.
Out-of-Bag: je $\approx \frac{1}{3}$ der Daten ungenutzt $\Rightarrow$ gratis Validierung.

3 Skizze: parallel vs. sequentiell



4 Random Forest

Bagging von Decision Trees plus zufällige Feature-Teilmenge pro Split $\Rightarrow$ Bäume dekorrelieren ($\rho \downarrow$).

```
</> Random Forest
for m = 1..M:
    Z_m ← Bootstrap-Stichprobe von S
    Baum G_m auf Z_m; bei jedem Split nur
    zufällige Teilmenge der Features testen
predict: Mehrheit (bzw. Mittel) über alle G_m
```

5 AdaBoost

Schwache Lerner (z. B. Stümpfe) nacheinander, falsch klassifizierte Punkte bekommen mehr Gewicht.

Legende: w_i Gewicht von Beispiel i , G_m Lerner m , err_m gewichtete Fehlerrate, α_m Stimmgewicht, N Beispiele.

```
</> AdaBoost
w_i ← 1/N
for m = 1..M:
    G_m ← Lerner auf gewichteten Daten
    err_m ← ∑ w_i 1[y_i ≠ G_m(x_i)] / ∑ w_i
    α_m ← log(1/err_m)
    w_i ← w_i e^{α_m 1[y_i ≠ G_m(x_i)]}
return sign ∑ α_m G_m(x)
```

6 Forward Stagewise & Gradient Boosting

$f_m = f_{m-1} + \beta_m G(x; \gamma_m)$ mit
 $(\beta_m, \gamma_m) = \arg \min \sum_i L(y_i, f_{m-1}(x_i) + \beta G(x_i; \gamma))$.

Legende: f_m Ensemble nach m Schritten, G schwacher Lerner mit Parametern γ_m , β_m Gewicht, L Verlust, g_i negativer Gradient (Residuum).

Quadr. Verlust $\Rightarrow$ Residuen fiten; $e^{-y\hat{y}} \Rightarrow$ AdaBoost.

```
</> Gradient Boosting
f ← 0
for m = 1..M:
    g_i ← -∂L(y_i, f(x_i))/∂f(x_i)
    G ← Regressor auf (x_i, g_i) (Least Squares)
    f ← f + β G
```

Beispiel: eine AdaBoost-Runde

5 Punkte, Gewichte je 0.2. Stumpf 1 klassifiziert einen falsch.

Lösung $\text{err} = 0.2$, $\alpha = \log \frac{0.8}{0.2} = \log 4 \approx 1.39$.

Update: falscher Punkt $0.2 \cdot e^{1.39} = 0.8$, die anderen bleiben 0.2. Summe = 1.6.

Normiert: falscher Punkt 0.5, die vier richtigen je 0.125 $\Rightarrow$

Runde 2 muss den schwierigen Punkt lösen.

7 Bagging vs. Boosting

	Bagging	Boosting
Ziel	Varianz senken	Bias senken
Lerner	stark, tief (hohe Var.)	schwach (hoher Bias)
Aufbau	parallel, unabhängig	sequentiell, abhängig
Mehr Modelle	kein Overfitting	Overfitting möglich
Extra	Out-of-Bag, RF	additive Modelle

8 Key Takeaways

- ✓ $\text{Var} = \rho\sigma^2 + \frac{1-\rho}{n}\sigma^2$
- ✓ Bagging: Bootstrap + Mittel
- ✓ RF: + Feature-Subsampling
- ✓ Boosting: sequentiell, gewichtet

9 Voting, Stacking & Praxis (ML Notes; Internet: XGBoost)

Voting: Mehrheit (hart) bzw. Mittel der Wahrscheinlichkeiten (weich). **Stacking:** ein Meta-Modell kombiniert die Vorhersagen der Basis-Modelle; diese müssen out-of-fold sein (sonst Leakage). Wahl: hohe Varianz $\rightarrow$ Bagging, hoher Bias $\rightarrow$ Boosting, beste Leistung $\rightarrow$ Stacking. **Internet-Zusatz** (nicht aus den Notes): XGBoost, LightGBM und CatBoost sind moderne Gradient-Boosting-Bibliotheken und dominieren tabellarische Daten; Random Forests: Breiman (2001). Feature Importance und Code: Vertiefungs- und SHAP-Seiten.

? Selbsttest: kannst du das erklären?

F1 Wie senkt Bagging die Varianz?

A: Bootstrap dekorreliert die Modelle:
 $\rho\sigma^2 + \frac{1-\rho}{n}\sigma^2$.

F2 Ziel von Bagging vs. Boosting?

A: Bagging: Varianz; Boosting: Bias (schwache Lerner, sequentiell).

F3 Was ist der Out-of-Bag-Fehler?

A: Fehler auf den $\approx \frac{1}{3}$ nicht gezogenen Punkten: gratis Validierung.

„Viele schwache Meinungen, klug kombiniert, ergeben ein starkes Urteil.“

Warum Entropie-Splits nie schaden und warum Mittelung die Varianz senkt -- plus Code für k-NN, Baum und Ensembles. ❤️

k-NN, Bäume & Ensembles: Vertiefung

Herleitung und Code

Merke:
Konkavität + Jensen erklärt Information Gain

Quelle: notes/cs229-notes-dt.pdf, notes/cs229-notes-ensemble.pdf (R. Townshend); hand-notes/ML Notes.pdf (k-NN, Random Forest, Ensemble); Herleitungen ausformuliert; Code: code/sk_knn.py, sk_trees.py, sk_ensemble.py (real ausgeführt)

1 Information Gain ≥ 0 (Jensen)

Legende: p Klassenverteilung im Knoten, $H(p) = -\sum_c p_c \log p_c$ Entropie (Unordnung), R Knoten, R_k Kind-Knoten, $w_k = |R_k|/|R|$ Anteil der Beispiele im Kind, IG Information Gain.

Elternverteilung $p = \sum_k w_k p_k$ ist der gewichtete Mittelwert der Kinderverteilungen ($w_k = |R_k|/|R|$). Entropie H ist konkav, also

$$H(p) = H\left(\sum_k w_k p_k\right) \geq \sum_k w_k H(p_k)$$

$\Rightarrow$ IG = $H(p) - \sum_k w_k H(p_k) \geq 0$; strikt > 0 , wenn die Kinder verschieden sind (H strikt konkav). Die Fehlerrate $1 - \max_p$ ist konkav, aber nicht strikt: Gleichheit möglich, IG = 0 (Beispiel Kapitel Decision Trees).

In Worten: Die Mischung zweier Verteilungen ist unordentlicher als der Durchschnitt ihrer Einzelunordnungen (Jensen). Ein Split macht die Kinder im Mittel also nie unreiner.

2 Varianz eines Ensembles

X_i identisch verteilt, $\text{Var}(X_i) = \sigma^2$, $\text{Corr} = \rho$:

Legende: X_i Vorhersage des i -ten Modells, n Anzahl Modelle, $\bar{X} = \frac{1}{n} \sum X_i$ Ensemble-Mittel, σ^2 Varianz eines Modells, ρ Korrelation zweier Modelle, Cov Kovarianz.

$$\begin{aligned} \text{Var}(\bar{X}) &= \frac{1}{n^2} \sum_{i,j} \text{Cov}(X_i, X_j) && \text{Bilinearität} \\ &= \frac{1}{n^2} (n\sigma^2 + n(n-1)\rho\sigma^2) && n \text{ Diagonal-, } n(n-1) \text{ Nebenterme} \\ &= \rho\sigma^2 + \frac{1-\rho}{n}\sigma^2 \end{aligned}$$

$n \rightarrow \infty$: bleibt $\rho\sigma^2 \Rightarrow$ Korrelation senken (Bagging, Random Forest).

In Worten: Unabhängige Fehler mitteln sich weg (σ^2/n), gemeinsame nicht ($\rho\sigma^2$).

(/) k-Nearest Neighbors: Einfluss von k

```
from sklearn.datasets import load_iris
from sklearn.neighbors import KNeighborsClassifier
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import cross_val_score
X, y = load_iris(return_X_y=True)
for k in (1, 5, 15, 45):
    m = make_pipeline(StandardScaler(), KNeighborsClassifier(n_neighbors=k))
    print("k =", k, " CV-Acc:", cross_val_score(m, X, y, cv=5).mean().round(3))
```

Ausgabe (real ausgeführt)

```
k = 1  CV-Acc: 0.947
k = 5  CV-Acc: 0.96
k = 15 CV-Acc: 0.94
k = 45 CV-Acc: 0.873
```

(/) Entscheidungsbaum vs. Random Forest, Feature-Importance

```
from sklearn.datasets import load_wine
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import cross_val_score
X, y = load_wine(return_X_y=True)
dt = DecisionTreeClassifier(criterion="entropy", max_depth=3, random_state=0)
rf = RandomForestClassifier(n_estimators=200, max_features="sqrt", random_state=0)
print("Baum CV-Acc:", cross_val_score(dt, X, y, cv=5).mean().round(3))
print("Wald CV-Acc:", cross_val_score(rf, X, y, cv=5).mean().round(3))
rf.fit(X, y)
print("Top-3 Feature-Importance:", rf.feature_importances_.argsort()[::-1][:3])
```

Ausgabe (real ausgeführt)

```
Baum CV-Acc: 0.91
Wald CV-Acc: 0.972
Top-3 Feature-Importance: [12 6 9]
```

(/) AdaBoost, Voting und Stacking

```
from sklearn.datasets import load_breast_cancer
from sklearn.ensemble import (AdaBoostClassifier, GradientBoostingClassifier,
                              StackingClassifier, VotingClassifier, RandomForestClassifier)
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import cross_val_score
X, y = load_breast_cancer(return_X_y=True)
base = [{"rf", RandomForestClassifier(100, random_state=0)},
        {"gb", GradientBoostingClassifier(random_state=0)}]
models = {"AdaBoost": AdaBoostClassifier(random_state=0),
          "Voting": VotingClassifier(base, voting="soft"),
          "Stacking": StackingClassifier(base, final_estimator=LogisticRegression(max_iter=2000))}
for name, m in models.items():
    print(f"{name:9s} CV-Acc:", cross_val_score(m, X, y, cv=5).mean().round(3))
```

Ausgabe (real ausgeführt)

```
AdaBoost CV-Acc: 0.967
Voting CV-Acc: 0.963
Stacking CV-Acc: 0.965
```

? Selbsttest: kannst du das herleiten?

F1 Warum ist der Information Gain nie negativ?

A: Entropie ist konkav:

$$H\left(\sum w_k p_k\right) \geq \sum w_k H(p_k) \text{ (Jensen).}$$

F2 Warum senkt Bagging die Varianz nicht auf null?

A: Es bleibt $\rho\sigma^2$; nur weniger Korrelation ρ hilft weiter (Random Forest).

F3 Warum wird bei k-NN skaliert?

A: Ein Feature mit großer Skala dominiert den Abstand.

„Mehrere Bäume, weniger Varianz -- solange sie nicht alle dasselbe lernen.“

Verlustfunktionen

Konvexe Ersatzverluste (Surrogate Losses)

Der 0/1-Verlust ist nicht optimierbar -- also nutzen wir konvexe Ersatzverluste. ♥

Merke:
Margin $z = y\theta^\top x$: $z > 0$ heißt richtig klassifiziert!

Quelle: extra-notes/loss-functions.pdf und extra-notes/representer-function.pdf (J. Duchi)


1 Der Margin

Für $y \in \{-1, +1\}$ und $\hat{y} = \theta^\top x$ ist $z = y\theta^\top x$ der **Margin**: $z > 0$ richtig, $z < 0$ falsch; $|z|$ misst die Sicherheit.
Empirisches Risiko:
 $J(\theta) = \frac{1}{n} \sum_i \phi(y^{(i)}\theta^\top x^{(i)})$.

2 Problem: 0/1-Verlust

$\phi_{01}(z) = \mathbf{1}\{z \leq 0\}$ zählt Fehler, ist aber unstetig, nicht konvex und NP-hart zu minimieren.
Wunsch: ϕ konvex, stetig, $\phi(z) \rightarrow 0$ für $z \rightarrow \infty$, $\phi(z) \rightarrow \infty$ für $z \rightarrow -\infty$.

3 Skizze: Verluste über z



4 Drei Verluste, drei Verfahren

Verlust	$\phi(z)$	Verfahren
Logistisch	$\log(1 + e^{-z})$	Logistische Regression
Hinge	$\max(1 - z, 0)$	Support Vector Machine
Exponentiell	e^{-z}	AdaBoost

Verbindendes Prinzip: alle minimieren $\frac{1}{n} \sum \phi(y\theta^\top x)$ – nur ϕ unterscheidet sich; alle sind konvexe obere Schranken des 0/1-Verlusts.

5 Generisches Training

`(</> ERM mit Ersatzverlust`

`init  $\theta \leftarrow 0$`

`repeat: wähle Beispiel  $(x_i, y_i)$`

`$z \leftarrow y_i \theta^\top x_i$`

`$g \leftarrow \phi'(z) \cdot y_i x_i$`

`$\theta \leftarrow \theta - \alpha g$`

α : Lernrate, ϕ' : Ableitung; logistisch $-1/(1 + e^z)$

Hinge: -1 falls $z < 1$, sonst 0 (Subgradient)

exp: $-e^{-z}$

Beispiel: Verluste bei drei Margins

z	0/1	logist.	Hinge	exp
3	0	0.05	0	0.05
0.5	0	0.47	0.5	0.61
-1	1	1.31	2	2.72

Selbst richtig klassifizierte Punkte mit kleinem Margin ($z = 0.5$) werden noch bestraft $\Rightarrow$ Ansporn, den Margin zu vergrößern.

6 Verallgemeinerte Verluste

Allgemein: $L(\theta^\top x, y)$ (z : Score, k : Anzahl Klassen). Regression: $\frac{1}{2}(z - y)^2$. Binär: $\log(1 + e^{-yz})$. Multiklasse mit $\Theta = [\theta_1 \dots \theta_k]$:

$$L(\Theta^\top x, y) = \log \sum_{i=1}^k e^{x^\top (\theta_i - \theta_y)}$$

(Cross-Entropy/Softmax; θ_y : Parameter der wahren Klasse, Θ : alle Klassenparameter als Spalten). Mit konvexem L und ℓ_2 -Regularisierung gilt das Representer-Theorem.

7 Wann welcher Verlust?

- Wahrscheinlichkeiten nötig $\rightarrow$ logistisch
- Margin/Sparsität $\rightarrow$ Hinge
- Boosting $\rightarrow$ exponentiell (ausreißeranfällig)

8 Key Takeaways

- ✓ Margin $z = y\theta^\top x$
- ✓ 0/1 nicht optimierbar $\Rightarrow$ Surrogat
- ✓ logistisch = LogReg, Hinge = SVM, exp = AdaBoost

9 Querverweise

- Logistische Regression, SVM, Ensembles
- Praktische Aufgabe: p01_lr.py (Aufgabenblatt 2) nutzt genau diese ± 1 -Notation

? Selbsttest: kannst du das erklären?

F1 Warum nicht den 0/1-Verlust minimieren?

A: Unstetig, nichtkonvex, NP-hart.

F2 Welcher Verlust gehört zu SVM, AdaBoost, LogReg?

A: Hinge, exponentiell, logistisch.

F3 Was ist der Margin?

A: $z = y\theta^\top x$: $z > 0$ richtig, $|z|$ Sicherheit.

„Optimiere, was du optimieren kannst -- und hoffe, dass es mit dem zusammenfällt, was du willst.“

Neuronale Netze

Deep Learning: Architektur & Bausteine

Schicht für Schicht: lineare Abbildung plus Nichtlinearität -- beliebig tief. ❤️

Merke:
Ohne Nichtlinearität kollabiert jedes Netz zu einem linearen Modell!

Quelle: main_notes.pdf (Deep Learning), notes/cs229-notes-deep_learning.pdf

1 Idee

Lineare Modelle sind beschränkt. Durch **Komposition nichtlinearer Schichten** approximiert ein Netz beliebig komplexe Funktionen. Ein Netz lernt seine Merkmale selbst, statt sie von Hand zu entwerfen.


2 Forward-Pass

$$\begin{aligned} a^{[0]} &= x \\ z^{[\ell]} &= W^{[\ell]} a^{[\ell-1]} + b^{[\ell]} \\ a^{[\ell]} &= \sigma(z^{[\ell]}), \quad \ell < r \\ \hat{y} &= W^{[r]} a^{[r-1]} + b^{[r]} \end{aligned}$$

Legende: r Schichten, ℓ Schichtindex, $W^{[\ell]}, b^{[\ell]}$ Gewichte und Bias, z Vorstufe, a Aktivierung, σ nichtlineare Aktivierung, $\hat{y}$ Ausgabe.

Ohne σ : $W^{[r]} \dots W^{[1]} x = \tilde{W} x$ (linear!).

3 Skizze: 3-4-1-Netz



4 Aktivierungsfunktionen

Name	Formel	Einsatz
Sigmoid	$1/(1 + e^{-z})$	Ausgabe binär
Tanh	$\frac{e^z - e^{-z}}{e^z + e^{-z}}$	veraltet (verborgen)
ReLU	$\max(z, 0)$	Standard (verborgen)
Leaky ReLU	$\max(z, \gamma z)$, $\gamma \approx 0.01$	gegen „dying ReLU“
GELU	$z \Phi(z)$, Φ : Gauß-CDF	Transformer
Softmax	$e^{z_k} / \sum_j e^{z_j}$	Ausgabe Mehrklassen

5 Moderne Bausteine

Legende: W_1, W_2, b_1, b_2 Gewichte/Bias, $\hat{\mu}, \hat{\sigma}$ Mittel und Streuung über die Merkmale, γ, β lernbare Skala/Verschiebung, k Filtergröße, s Schrittweite, w_j Filtergewichte, m Breite.

ResNet: $\text{Res}(z) = z + \sigma(W_2 \sigma(W_1 z + b_1) + b_2)$ – Gradient fließt durch die Abkürzung (gegen Vanishing Gradients).

LayerNorm: $\text{LN}(z) = \gamma \odot \frac{z - \hat{\mu}}{\hat{\sigma}} + \beta$ (skaleninvariant in W).

Faltung (CNN): $\text{Conv}(z)_i = \sum_{j=1}^k w_j z_{i-s-j+1}$.

Parameter-Sharing: $O(m^2) \rightarrow O(km)$.

Beispiel: Forward-Pass 2-2-1 mit ReLU

$x = (1, 2)$, $W^{[1]} = \begin{pmatrix} 1 & -1 \\ 0.5 & 1 \end{pmatrix}$, $b^{[1]} = 0$, $W^{[2]} = (1, 2)$, $b^{[2]} = -1$.

Lösung $z^{[1]} = (1 - 2, 0.5 + 2) = (-1, 2.5)$

$a^{[1]} = \text{ReLU}(z^{[1]}) = (0, 2.5)$

$\hat{y} = 1 \cdot 0 + 2 \cdot 2.5 - 1 = 4$; Verlust ($y=3$): $\frac{1}{2}(4 - 3)^2 = 0.5$.

6 Beispiel: Parameter zählen

Netz $100 \rightarrow 50 \rightarrow 10$ (voll verbunden):

Schicht 1: $100 \cdot 50 + 50 = 5050$

Schicht 2: $50 \cdot 10 + 10 = 510$

Summe: **5560** Parameter.

Allgemein: Schicht mit $m_{\text{in}} \rightarrow m_{\text{out}}$ hat $m_{\text{in}} m_{\text{out}} + m_{\text{out}}$ Parameter.

7 Vorteile

- ✓ universelle Approximation
- ✓ lernt Merkmale selbst
- ✓ skaliert mit Daten & Rechenleistung

8 Grenzen

- ✗ nichtkonvex, viele Hyperparameter
- ✗ datenhungrig, schwer interpretierbar
- ✗ anfällig für Adversarial Examples

9 Key Takeaways

- ✓ $z = W a + b$, $a = \sigma(z)$
- ✓ ReLU = Standard, Softmax am Ausgang
- ✓ ResNet/LayerNorm/CNN als Bausteine

10 Ausgabe & Verlust

- binär: Sigmoid + Cross-Entropy
- Mehrklassen: Softmax + Cross-Entropy
- Regression: linear + MSE

11 Start des Trainings

- Gewichte klein zufällig initialisieren (nicht 0: Symmetriebroch!)
 - Eingaben normalisieren
 - Mini-Batch-SGD (nächste Seite)

12 Querverweise

- Backpropagation: wie der Gradient entsteht
- Regularisierung: Weight Decay = L2
- Foundation Models: Transformer = MLP + Attention

? Selbsttest: kannst du das erklären?

F1 Wozu Nichtlinearität?

A: Ohne σ ist ein tiefes Netz nur eine lineare Abbildung $\tilde{W}x$.

F2 Wozu ResNets?

A: Skip-Connections lassen den Gradient durch viele Schichten fließen.

F3 Parameter einer Schicht $m_{\text{in}} \rightarrow m_{\text{out}}$?

A: $m_{\text{in}} m_{\text{out}} + m_{\text{out}}$.

„Tiefe Netze sind einfache Bausteine -- nur sehr oft hintereinander.“

Rückwärts durch das Netz:
die Kettenregel, systematisch
angewandt. ❤️

Backpropagation & Optimierung

Gradienten effizient berechnen und nutzen

Merke:
Der Gradient kostet nur so viel
wie der Forward-Pass: $O(N)$!

Quelle: main_notes.pdf (Backpropagation), notes/cs229-notes-backprop.pdf

1 Theorem

Lässt sich der Verlust in einem Forward-Pass mit Aufwand N berechnen, so lässt sich der vollständige Gradient $\nabla_{\theta} J$ ebenfalls in $O(N)$ berechnen. Backprop ist "nur" die Kettenregel mit Zwischenspeicherung.

2 Formeln

Legende: $u^{[\ell]}$ Zwischenwert nach Modul ℓ , M_{ℓ} Modul (Schicht), $\theta^{[\ell]}$ dessen Parameter, J Verlust, B Rückwärtsfunktion (transponierte Ableitung des Moduls), L Anzahl Module.


Forward: $u^{[\ell]} = M_{\ell}(u^{[\ell-1]}; \theta^{[\ell]})$, $J = u^{[L]}$.
Backward:

$$\frac{\partial J}{\partial u^{[L]}} = 1$$

$$\frac{\partial J}{\partial u^{[\ell-1]}} = B[M_{\ell}, u^{[\ell-1]}] \left(\frac{\partial J}{\partial u^{[\ell]}} \right)$$

$$\frac{\partial J}{\partial \theta^{[\ell]}} = B_{\theta}[M_{\ell}, \theta^{[\ell]}] \left(\frac{\partial J}{\partial u^{[\ell]}} \right)$$

3 Skizze: Vor- & Rückwärts



4 Backprop im MLP

`</> Backpropagation`

Forward (Zwischenwerte speichern)

$a_0 \leftarrow x$; **for** $\ell = 1..L$:

$z_{\ell} \leftarrow W_{\ell} a_{\ell-1} + b_{\ell}$; $a_{\ell} \leftarrow \sigma(z_{\ell})$

Backward

$\delta_L \leftarrow \partial J / \partial z_L$

for $\ell = L..1$:

$\partial J / \partial W_{\ell} \leftarrow \delta_{\ell} a_{\ell-1}^T$; $\partial J / \partial b_{\ell} \leftarrow \delta_{\ell}$

$\delta_{\ell-1} \leftarrow (W_{\ell}^T \delta_{\ell}) \odot \sigma'(z_{\ell-1})$

5 Mini-Batch-SGD

`</> Mini-Batch SGD`

init θ (zufällig)

repeat bis Konvergenz:

Batch $B \subset \{1..n\}$, $|B| = B$

$g \leftarrow \frac{1}{B} \sum_{i \in B} \nabla_{\theta} J^{(i)}(\theta)$

$\theta \leftarrow \theta - \alpha g$

(B Batch, B Batchgröße, $J^{(i)}$ Verlust von Beispiel i , g Gradientenschätzung, α Lernrate.) $B = 1$: reines SGD (verrauscht); $B = n$: Batch-GD (teuer). Kleine Batches sind billig und wirken leicht regularisierend.

Web-Zusatz: in der Praxis oft Momentum bzw. Adam statt reinem SGD.

Beispiel: Backprop von Hand

$\hat{y} = w_2 \text{ReLU}(w_1 x)$, $x = 2$, $y = 0$, $w_1 = 1$, $w_2 = 0.5$,
 $J = \frac{1}{2}(\hat{y} - y)^2$.

Lösung Forward: $z = 2$, $a = 2$, $\hat{y} = 1$, $J = 0.5$.

Backward: $\partial J / \partial \hat{y} = 1$; $\partial J / \partial w_2 = 1 \cdot a = 2$;

$\partial J / \partial a = 1 \cdot w_2 = 0.5$; $\partial J / \partial z = 0.5$ ($\text{ReLU}' = 1$);

$\partial J / \partial w_1 = 0.5 \cdot x = 1$.

SGD ($\alpha = 0.1$): $w_2 = 0.3$, $w_1 = 0.9 \Rightarrow \hat{y} = 0.54$, $J = 0.146 < 0.5$

Verlust sinkt.

6 Praxis & Fallstricke

- **Gradient-Check:** $\frac{J(\theta+\varepsilon) - J(\theta-\varepsilon)}{2\varepsilon}$ mit Backprop vergleichen.
- **Vanishing/Exploding Gradients:** Sigmoid/Tanh sättigen; Abhilfe: ReLU, ResNet, LayerNorm, gute Initialisierung.
- Lernrate zu groß $\rightarrow$ Divergenz, zu klein $\rightarrow$ Stillstand.

7 Vorteile

- ✓ exakter Gradient
- ✓ Aufwand $\approx$ ein Forward-Pass
- ✓ Autodiff-Frameworks übernehmen es

8 Grenzen

- ✗ Zwischenwerte brauchen Speicher
- ✗ nichtkonvex: nur lokale Minima
- ✗ Hyperparameter-Tuning nötig

9 Key Takeaways

- ✓ Backprop = Kettenregel rückwärts
- ✓ Kosten $O(N)$
- ✓ SGD in Mini-Batches

? Selbsttest: kannst du das erklären?

F1 Aufwand von Backprop?

A: $O(N)$, wie ein Forward-Pass.

F2 Was ist ein Gradient-Check?

A: $\frac{J(\theta+\varepsilon) - J(\theta-\varepsilon)}{2\varepsilon}$ mit Backprop vergleichen.

F3 Wirkung der Batchgröße?

A: $B=1$ verrauscht, $B=n$ teuer; Mini-Batch als Kompromiss.

„Rückwärts rechnen, vorwärts lernen.“

Backpropagation: Vertiefung

Herleitung der Rückwärtsrekursion

Kettenregel rückwärts: wie Gradienten durch ein Netz fließen -- mit Autograd-check. ❤

Merke:
 $\delta_{\ell-1} = (W_{\ell}^T \delta_{\ell}) \odot \sigma'(z_{\ell-1})$

Quelle: main_notes.pdf Kap. 7.4--7.5, notes/cs229-notes-backprop.pdf; Schritte und Zahlenbeispiel ergänzt; Code: code/torch_autograd.py (real ausgeführt)

1 Kettenregel im Skalarfall

Legende: x Eingabe, y Ziel, $\hat{y}$ Vorhersage, w_1, w_2 Gewichte, z Vorstufe, a Aktivierung, $\text{ReLU}(z) = \max(0, z)$, J Verlust.

$$J = \frac{1}{2}(\hat{y} - y)^2, \hat{y} = w_2 a, a = \text{ReLU}(z), z = w_1 x:$$

$$\begin{aligned} \frac{\partial J}{\partial \hat{y}} &= \hat{y} - y \\ \frac{\partial J}{\partial w_2} &= \frac{\partial J}{\partial \hat{y}} a, & \frac{\partial J}{\partial a} &= \frac{\partial J}{\partial \hat{y}} w_2 \\ \frac{\partial J}{\partial z} &= \frac{\partial J}{\partial a} \text{ReLU}'(z), & \frac{\partial J}{\partial w_1} &= \frac{\partial J}{\partial z} x \end{aligned}$$

Jeder Schritt multipliziert die Ableitung des nächsten Moduls - rückwärts von J zu den Parametern.

In Worten: Backprop ist die Kettenregel: Wie stark J auf w_1 reagiert, ist das Produkt der lokalen Steigungen entlang des Wegs.

2 Matrixform im MLP

$$z_{\ell} = W_{\ell} a_{\ell-1} + b_{\ell}, a_{\ell} = \sigma(z_{\ell}); \delta_{\ell} := \partial J / \partial z_{\ell}.$$

Legende: ℓ Schichtindex, W_{ℓ}, b_{ℓ} Gewichte und Bias, a_{ℓ} Aktivierung, z_{ℓ} Vorstufe, σ Aktivierungsfunktion, δ_{ℓ} Fehlersignal, $\odot$ elementweises Produkt.

$$\begin{aligned} \frac{\partial J}{\partial W_{\ell}} &= \delta_{\ell} a_{\ell-1}^T, & \frac{\partial J}{\partial b_{\ell}} &= \delta_{\ell} & z_{\ell} \text{ linear in } W_{\ell}, b_{\ell} \\ \frac{\partial J}{\partial a_{\ell-1}} &= W_{\ell}^T \delta_{\ell} & & & z_{\ell} \text{ linear in } a_{\ell-1} \\ \delta_{\ell-1} &= (W_{\ell}^T \delta_{\ell}) \odot \sigma'(z_{\ell-1}) & & & \text{Kettenregel durch } \sigma \end{aligned}$$

In Worten: δ_{ℓ} sagt, wie stark J auf z_{ℓ} reagiert. Es wandert mit W^T eine Schicht zurück und wird an jedem Neuron mit σ' gedämpft.

3 Softmax + Cross-Entropy: $\delta_L = p - y$

Ausgabe z_L , $p = \text{softmax}(z_L)$, $J = -\sum_k y_k \log p_k$ (y one-hot):

Legende: z_L Scores der letzten Schicht, p_k Klassenwahrscheinlichkeit, y_k wahre Klasse (one-hot: eine 1, sonst 0), 1_{kj} Kronecker-Delta (1 für $k=j$, sonst 0).

$$\begin{aligned} \frac{\partial J}{\partial z_j} &= -\sum_k y_k \frac{1}{p_k} \frac{\partial p_k}{\partial z_j} = -\sum_k y_k \frac{1}{p_k} p_k (1_{kj} - p_j) & \text{Softmax-Jacobi} \\ &= -y_j + p_j \sum_k y_k = p_j - y_j \end{aligned}$$

Sehr einfacher Startwert für die Rückwärtsrekursion: Vorhersage minus Wahrheit.

4 Warum $O(N)$?

Legende: N Anzahl Module/Parameter, B Batchgröße, A_{ℓ} Aktivierungen des Batchs als Spalten.

Forward: pro Modul eine Auswertung; Backward: pro Modul eine Matrix-Vektor-Multiplikation ($W^T \delta$) plus ein äußeres Produkt (δa^T) - dieselbe Größenordnung wie vorwärts. Zwischenwerte z_{ℓ}, a_{ℓ} werden gespeichert und wiederverwendet (kein erneutes Ausrechnen von Teilgradienten). **Vektorisierung:** mit Batch-Matrizen $A_{\ell} = [a^{(1)} \dots a^{(B)}]$ wird $\delta_{\ell} A_{\ell-1}^T$ zu einer einzigen Matrixmultiplikation.

5 Vanishing / Exploding Gradients

Legende: L Anzahl Schichten, $\text{diag}(\cdot)$ Diagonalmatrix, σ' Ableitung der Aktivierung.

Durch L Schichten: $\delta_1 = \left(\prod_{\ell=2}^L \text{diag}(\sigma'(z_{\ell-1})) W_{\ell}^T \right) \delta_L$.

Sigmoid: $\sigma' \leq \frac{1}{4} \Rightarrow$ Faktor $\leq (\frac{1}{4})^L$ verschwindet; große $\|W\| \Rightarrow$ explodiert.

In Worten: ein Produkt vieler Faktoren < 1 schrumpft auf null, > 1 wächst ins Unendliche.

Abhilfe: ReLU ($\sigma' = 1$ für $z > 0$), ResNet-Skip (additiver Pfad, Ableitung $+I$), Normalisierung, passende Initialisierung.

6 Gradient-Check

Backprop-Gradient gegen zentralen Differenzenquotienten prüfen (θ_j : ein Parameter, e_j : Einheitsvektor dazu, ε : winziger Schritt):

$$\frac{\partial J}{\partial \theta_j} \approx \frac{J(\theta + \varepsilon e_j) - J(\theta - \varepsilon e_j)}{2\varepsilon}, \quad \varepsilon \approx 10^{-5}$$

Relativer Fehler $\lesssim 10^{-6} \Rightarrow$ korrekt. Frameworks (Autograd) machen den Rückwärtslauf automatisch - das Prinzip bleibt dasselbe (Code: unten).

In Worten: Einen Parameter minimal verschieben und messen, wie sich J ändert: die numerische Steigung.

Backpropagation: Praxis

Backprop einmal komplett durchgerechnet und mit Autograd geprüft. ❤️

Merke:
Von Hand rechnen, dann vom Framework bestätigen lassen

Rechenbeispiel und Autograd-Code

Quelle: main_notes.pdf Kap. 7.4--7.5, notes/cs229-notes-backprop.pdf; Schritte und Zahlenbeispiel ergänzt; Code: code/torch_autograd.py (real ausgeführt)

Beispiel: komplettes Backprop im 2-2-1-Netz (vgl. Kapitel Neuronale Netze)

Legende: W_1, b_1 und W_2, b_2 Gewichte der zwei Schichten, z_1, a_1 Vorstufe und Aktivierung der ersten Schicht. $x = (1, 2)$, $W_1 = \begin{pmatrix} 1 & -1 \\ 0.5 & 1 \end{pmatrix}$, $b_1 = 0$, **ReLU**, $W_2 = (1, 2)$, $b_2 = -1$, $y = 3$. **Forward:** $z_1 = (-1, 2.5)$, $a_1 = (0, 2.5)$, $\hat{y} = 4$, $J = \frac{1}{2}(4 - 3)^2 = 0.5$.

Lösung $\delta_2 = \hat{y} - y = 1$. $\partial J / \partial W_2 = \delta_2 a_1^\top = (0, 2.5)$, $\partial J / \partial b_2 = 1$.

$\delta_1 = (W_2^\top \delta_2) \odot \text{ReLU}'(z_1) = (1, 2) \odot (0, 1) = (0, 2)$ (das erste Neuron ist "tot": $z < 0$).

$\partial J / \partial W_1 = \delta_1 x^\top = \begin{pmatrix} 0 & 0 \\ 2 & 4 \end{pmatrix}$ (maschinell nachgerechnet).

(/) Autograd: das Backprop-Beispiel von Hand nachgerechnet

```
import torch
x, y = torch.tensor(2.0), torch.tensor(0.0)
w1 = torch.tensor(1.0, requires_grad=True)
w2 = torch.tensor(0.5, requires_grad=True)
y_hat = w2 * torch.relu(w1 * x) # Forward
J = 0.5 * (y_hat - y) ** 2
J.backward() # Backprop = Kettenregel rueckwaerts
print("J =", J.item(), "| dJ/dw1 =", w1.grad.item(), "| dJ/dw2 =", w2.grad.item())
```

Ausgabe (real ausgeführt)

J = 0.5 | dJ/dw1 = 1.0 | dJ/dw2 = 2.0

? Selbsttest: kannst du das herleiten?

F1 Warum $\delta_L = p - y$ bei Softmax + Cross-Entropy?

A: Softmax-Jacobi

$\partial p_k / \partial z_j = p_k (\mathbf{1}_{kj} - p_j)$ und $\sum_k y_k = 1$ heben sich zu $p_j - y_j$ auf.

F2 Woher kommt $W^\top \delta$?

A: $z = Wa + b$ ist linear in a :

$\partial J / \partial a = W^\top \partial J / \partial z$.

F3 Warum verschwinden Gradienten bei Sigmoid?

A: $\sigma' \leq 0.25$, Produkt über viele Schichten $\rightarrow 0$.

„Backprop ist keine Magie -- nur die Kettenregel mit gutem Buchhalter.“

Neuronale Netze trainieren:
Optimierer, Initialisierung,
Normalisierung und Regularisierung. ❤️

Deep Learning: Training & Praxis

Optimierer, Init, BatchNorm, Dropout, Early Stopping

Merke:
Adam $\approx$ Momentum +
adaptive Lernraten

Quelle: main_notes.pdf (Deep Learning: LayerNorm, SGD, Regularisierung); Adam, Dropout, BatchNorm, Initialisierung als Web-Ergänzung (markiert),
Code: vertiefungsseite

1 Momentum & Adam (Web)

Legende: g Gradient, θ Parameter, α Lernrate, v Geschwindigkeit, m gleitender Mittelwert der Gradienten, $\hat{v}$ (bei Adam) der Quadrate, β, β_1, β_2 Abklingraten, t Schritt, ϵ kleine Konstante.

Momentum: $v \leftarrow \beta v + g$, $\theta \leftarrow \theta - \alpha v$ (glättet Zickzack).

Adam: $m \leftarrow \beta_1 m + (1 - \beta_1) g$,
 $v \leftarrow \beta_2 v + (1 - \beta_2) g^2$, $\hat{m} = \frac{m}{1 - \beta_1^t}$,
 $\hat{v} = \frac{v}{1 - \beta_2^t}$:


$$\theta \leftarrow \theta - \alpha \frac{\hat{m}}{\sqrt{\hat{v} + \epsilon}}$$

2 Lernraten-Schedules

Konstante Lernrate ist selten optimal: Step decay, Cosine-Abklingen, Warmup (klein starten, dann hoch). Zu große Rate $\rightarrow$ Verlust springt/divergiert; zu kleine $\rightarrow$ Stillstand. Vor dem Tuning:

Verlustkurve plotten.

3 Skizze: SGD vs. Momentum



4 Initialisierung (Web)

Nicht alle Gewichte = 0: dann sind alle Neuronen einer Schicht identisch (Symmetrie!). Zufällig mit passender Varianz (n_{in} Anzahl Eingänge): Xavier $\text{Var}(W) = \frac{1}{n_{in}}$ (Tanh/Sigmoid), He

$\text{Var}(W) = \frac{2}{n_{in}}$ (ReLU).

Ziel: Aktivierungen und Gradienten weder verschwinden noch explodieren lassen.

5 Normalisierung

BatchNorm (Web): $\text{BN}(z) = \gamma \frac{z - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} + \beta$ mit Batch-Statistiken

μ_B, σ_B^2 (γ, β lernbare Skala und Verschiebung) (im Test: gleitende Mittelwerte).

LayerNorm (Notes): Statistik pro Beispiel über die Features, unabhängig von der Batchgröße $\Rightarrow$ Standard in Transformern (Kapitel Neuronale Netze).

Wirkung: stabileres, schnelleres Training, größere Lernraten.

Beispiel: erster Adam-Schritt

$g = 2$, $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\alpha = 0.001$, $t = 1$.

Lösung $m = 0.1 \cdot 2 = 0.2$, $v = 0.001 \cdot 4 = 0.004$.

$\hat{m} = \frac{0.2}{0.1} = 2$, $\hat{v} = \frac{0.004}{0.001} = 4$.

Schritt $= \alpha \frac{\hat{m}}{\sqrt{\hat{v}}} = 0.001 = \alpha$: Adam skaliert so, dass der erste Schritt etwa die Größe α hat, unabhängig von der Gradientengröße.

Dropout ($p_{\text{keep}} = 0.5$): aus $(1, 2, 3, 4)$ wird z. B. $(2, 0, 6, 0)$ (verbleibende $\times 2$, inverted dropout).

6 Regularisierung im Deep Learning

- **Weight Decay** = L2 (Notes: $\frac{\lambda}{2} \|\theta\|^2$).
- **Dropout (Web):** im Training zufällig Neuronen ausschalten $\rightarrow$ implizites Ensemble.
- **Early Stopping:** Training beenden, wenn der Validierungsfehler steigt.
- **Datenaugmentierung:** Bilder drehen/spiegeln/zuschneiden.

7 Training debuggen

1. Erst auf kleinem Batch überanpassen (Verlust $\rightarrow 0$?) – sonst Bug.
2. Anfangsverlust prüfen ($\approx \log K$ bei K Klassen).
3. Lernrate über Größenordnungen probieren.
4. Train- vs. Validierungskurve: Gap $\Rightarrow$ Overfitting.
5. Gradient Clipping bei explodierenden Gradienten.

8 PyTorch-Trainingschleife (Skizze)

```
</> PyTorch
for Epoche in Epochen:
    model.train()
    for (x, y) in Mini-Batches:
        opt.zero_grad()
        loss = loss_fn(model(x), y)
        loss.backward() # Backprop
        opt.step()      # Update
```

Vollständiger, getesteter Code: Vertiefungsseite.

9 Key Takeaways

- ✓ Adam als robuster Standard, SGD+Momentum oft bessere Endleistung; Schedules und Warmup
- ✓ He-Initialisierung für ReLU; BatchNorm/LayerNorm stabilisieren; Dropout, Weight Decay, Early Stopping gegen Overfitting

? Selbsttest: kannst du das erklären?

F1 Warum nicht alle Gewichte mit 0 initialisieren?

A: Alle Neuronen bleiben identisch (gleiche Gradienten): Symmetrie wird nie gebrochen.

F2 Was bewirkt Dropout?

A: Zufälliges Ausschalten erzwingt redundante Merkmale, wirkt wie ein Ensemble.

F3 Was unterscheidet BatchNorm und LayerNorm?

A: BatchNorm normiert über den Batch, LayerNorm über die Features eines Beispiels.

„Training ist Handwerk: beobachte die Kurven, verändere eine Sache nach der anderen.“

Struktur nutzen: Faltungen für Bilder, Rekurrenz und Gates für Sequenzen. ♥

CNN & RNN / LSTM

Faltungsnetze und rekurrente Netze

Merke:
Parameter-Sharing macht CNNs klein, LSTM-Gates machen RNNs lernfähig

Quelle: main_notes.pdf (Modules in modern neural networks: Faltungsschichten); RNN/LSTM, Größenformeln und Pooling als Web-Ergänzung (markiert), Code: Vertiefungsseite

1 Faltung

Ein kleiner Filter w gleitet über die Eingabe z (1D-Notes; k Filterbreite, s Schrittweite (Stride), ℓ Startversatz, i Ausgabeposition):


$$\text{Conv}(z)_i = \sum_{j=1}^k w_j z_{is-\ell+(j-1)}$$

Parameter-Sharing: $O(km)$ statt $O(m^2)$
Parameter. Ausgabegröße: $\lfloor \frac{n+2p-k}{s} \rfloor + 1$ (n Eingabelänge, Padding p , Stride s , k Filterbreite).

2 Aufbau eines CNN (Web)

Conv $\rightarrow$ ReLU $\rightarrow$ Pooling wiederholen, am Ende Flatten + voll verbundene Schicht + Softmax. **Max-Pooling** (2×2) halbiert die Auflösung und macht robust gegen kleine Verschiebungen. Parameter je Conv-Schicht: $k^2 c_{in} c_{out} + c_{out}$.

3 Skizze: 1D-Filter



4 Warum CNNs funktionieren

- **Lokalität:** Kanten, Ecken hängen nur von Nachbarpixeln ab.
- **Translationsäquivalenz:** derselbe Filter erkennt ein Muster überall.
- **Hierarchie:** tiefe Schichten kombinieren Kanten zu Formen zu Objekten (Rezeptives Feld wächst).
- Weniger Parameter $\Rightarrow$ weniger Overfitting, effizient.

5 RNN: Gedächtnis über Zeit

$$h_t = \tanh(W_h h_{t-1} + W_x x_t + b), \quad y_t = W_y h_t$$

Gleiche Gewichte in jedem Zeitschritt; der versteckte Zustand h_t trägt die Historie. Training per Backpropagation Through Time: der Gradient wird über viele Faktoren W_h multipliziert $\Rightarrow$ **Vanishing/Exploding Gradients**, lange Abhängigkeiten gehen verloren.

Beispiel: 1D-Faltung von Hand

$z = (1, 2, 3, 4, 5)$, Filter $w = (1, 0, -1)$, Stride 1, kein Padding.

Lösung Größe $\frac{5-3}{1} + 1 = 3$. Ausgabe:

$1 \cdot 1 + 2 \cdot 0 + 3 \cdot (-1) = -2$; $2 \cdot 4 = -2$; $3 \cdot 5 = -2 \Rightarrow (-2, -2, -2)$ (konstanter Anstieg $\rightarrow$ konstante Antwort: der Filter ist ein Kantendetektor).

CNN-Parameter: 28×28 , Conv 3×3 ($1 \rightarrow 8$): $3 \cdot 3 \cdot 1 \cdot 8 + 8 = 80$; nach 2 Blöcken und FC ($784 \rightarrow 10$): $80 + 1168 + 7850 = 9098$ (Code: Vertiefungsseite).

6 LSTM: Gates gegen Vergessen (Web)

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \text{ (Vergessen)}$$

$$i_t = \sigma(W_i[\cdot] + b_i), \quad \tilde{c}_t = \tanh(W_c[\cdot] + b_c)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

$$h_t = o_t \odot \tanh(c_t), \quad o_t = \sigma(W_o[\cdot] + b_o)$$

Der Zellzustand c_t ist eine "Datenautobahn" mit additivem Update $\Rightarrow$ Gradient bleibt erhalten. GRU: vereinfachte Variante.

7 Von RNN zu Attention

RNNs verarbeiten Sequenzen nacheinander (nicht parallelisierbar, Gedächtnis begrenzt). **Self-Attention** (Kapitel Foundation Models) lässt jedes Token direkt auf alle anderen zugreifen und ist parallelisierbar $\Rightarrow$ Transformer haben RNNs bei Sprache weitgehend abgelöst.

8 Vorteile

- ✓ CNN: wenige Parameter, Bildstruktur
- ✓ LSTM: lange Abhängigkeiten
- ✓ beide End-to-End trainierbar

9 Grenzen

- ✗ CNN: kaum globaler Kontext
- ✗ RNN: sequentiell, langsam
- ✗ alle: viel Daten und Rechenzeit

10 Key Takeaways

- ✓ Faltung: lokal + geteilte Gewichte
- ✓ RNN: h_t als Gedächtnis
- ✓ LSTM-Gates lösen Vanishing Gradients

? Selbsttest: kannst du das erklären?

F1 Wie groß ist die Faltungsausgabe?

A: $\lfloor (n + 2p - k) / s \rfloor + 1$ (Länge n , Filter k , Padding p , Stride s).

F2 Warum haben CNNs weniger

Parameter als voll verbundene Netze?

A: Derselbe kleine Filter wird an allen Positionen wiederverwendet (Sharing).

F3 Wie helfen LSTM-Gates?

A: Additives Update des Zellzustands mit Vergessens-/Eingabe-Gate erhält den Gradienten über lange Zeit.

„Die richtige Architektur ist Vorwissen über die Struktur der Daten.“

Quelle: main_notes.pdf (Deep Learning); Adam, Dropout, CNN, LSTM als Web-Ergänzung (markiert); Herleitung ausformuliert; Code: code/torch_mlp.py, torch_cnn.py, torch_lstm.py (real ausgeführt)

1 Adam: warum Bias-Korrektur?

Legende: t Schrittzähler, g_t Gradient in Schritt t , m_t gleitender Mittelwert der Gradienten (Momentum), $\beta_1 \approx 0.9$ Abklingrate, $\hat{m}_t$ korrigierter Wert, $\hat{v}_t$ dasselbe für die Gradientenquadrate.

$m_0 = 0$, $m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t = (1 - \beta_1) \sum_{i=1}^t \beta_1^{t-i} g_i$. Bei stationären Gradienten $\mathbb{E} g_i = g$:

$$\begin{aligned} \mathbb{E}[m_t] &= (1 - \beta_1) g \sum_{i=1}^t \beta_1^{t-i} && \text{Erwartungswert} \\ &= (1 - \beta_1^t) g && \text{geometrische Summe} \end{aligned}$$

Der Schätzer ist am Anfang zu klein $\Rightarrow$ Korrektur $\hat{m}_t = m_t / (1 - \beta_1^t)$ (analog $\hat{v}_t$). Beispiel $t = 1$: $m_1 = 0.1 g$, $\hat{m}_1 = g$.

In Worten: m_t ist ein Durchschnitt der letzten Gradienten. Weil er bei 0 startet, fällt er anfangs zu klein aus; das Teilen durch $1 - \beta_1^t$ gleicht das aus.

MLP mit Mini-Batches, Adam, Dropout und Weight Decay

```
import torch, torch.nn as nn
from sklearn.datasets import make_moons
torch.manual_seed(0)
X, y = make_moons(400, noise=0.2, random_state=0)
X, y = torch.tensor(X, dtype=torch.float32), torch.tensor(y)
model = nn.Sequential(nn.Linear(2, 32), nn.ReLU(), nn.Dropout(0.2),
                      nn.Linear(32, 32), nn.ReLU(), nn.Linear(32, 2))
opt = torch.optim.Adam(model.parameters(), lr=1e-2, weight_decay=1e-4) # L2
loss_fn = nn.CrossEntropyLoss() # Softmax + Cross-Entropy
for epoch in range(200):
    model.train()
    for i in torch.randperm(len(X)).split(64): # Mini-Batches
        opt.zero_grad()
        loss = loss_fn(model(X[i]), y[i])
        loss.backward() # Backprop
        opt.step() # Update
    if epoch % 50 == 0:
        model.eval()
        acc = (model(X).argmax(1) == y).float().mean().item()
        print(f"Epoche {epoch:3d} loss {loss.item():.3f} acc {acc:.3f}")
```

Ausgabe (real ausgeführt)

Epoche	0	loss	0.446	acc	0.855
Epoche	50	loss	0.200	acc	0.960
Epoche	100	loss	0.013	acc	0.973
Epoche	150	loss	0.014	acc	0.973

CNN: Formen und Parameterzahlen

```
import torch, torch.nn as nn
net = nn.Sequential(
    nn.Conv2d(1, 8, kernel_size=3, padding=1), nn.ReLU(), nn.MaxPool2d(2), # 28 -> 14
    nn.Conv2d(8, 16, kernel_size=3, padding=1), nn.ReLU(), nn.MaxPool2d(2), # 14 -> 7
    nn.Flatten(), nn.Linear(16 * 7 * 7, 10))
x = torch.randn(4, 1, 28, 28) # Batch von 4 Bildern
print("Ausgabe:", tuple(net(x).shape))
print("Parameter Conv1:", sum(p.numel() for p in net[0].parameters()), "(= 3*3*1*8 + 8)")
print("Parameter gesamt:", sum(p.numel() for p in net.parameters()))
```

Ausgabe (real ausgeführt)

Ausgabe: (4, 10)
Parameter Conv1: 80 (= 3*3*1*8 + 8)
Parameter gesamt: 9098

LSTM in PyTorch und die Parameterzahlen der Architekturen nachgerechnet. ❤️

DL-Praxis: Vertiefung 2

LSTM, Parameterzahlen und Selbsttest

Merke:
Parameter zählen prüft, ob man die Architektur verstanden hat

Quelle: main_notes.pdf (Deep Learning); Adam, Dropout, CNN, LSTM als Web-Ergänzung (markiert); Herleitung ausformuliert; Code: code/torch_mlp.py, torch_cnn.py, torch_lstm.py (real ausgeführt)

(/) LSTM-Sequenzklassifikator

```
import torch, torch.nn as nn
class SeqClassifier(nn.Module):
    def __init__(self, d_in=5, hidden=16, n_cls=3):
        super().__init__()
        self.lstm = nn.LSTM(d_in, hidden, batch_first=True)
        self.head = nn.Linear(hidden, n_cls)
    def forward(self, x):
        # x: (Batch, Zeit, Features)
        out, (h, c) = self.lstm(x)
        # h: letzter versteckter Zustand
        return self.head(h[-1])
net = SeqClassifier()
x = torch.randn(8, 20, 5)
# 8 Sequenzen, 20 Zeitschritte
print("Ausgabe:", tuple(net(x).shape), "| Parameter:", sum(p.numel() for p in net.parameters()))
```

Ausgabe (real ausgeführt)

Ausgabe: (8, 3) | Parameter: 1523

2 Lesart der Ausgaben

Legende: Conv: $\text{Kern}^2 \cdot \text{Eingangskanäle} \cdot \text{Ausgangskanäle} + \text{Ausgangskanäle (Bias)}$; FC: $\text{Eingänge} \times \text{Ausgänge} + \text{Bias}$; LSTM: $4 \text{ Gates} \times \text{Hidden} \times (\text{Eingabe} + \text{Hidden} + \text{Bias})$.

MLP: Verlust $0.45 \rightarrow 0.01$, Accuracy $0.86 \rightarrow 0.97$ auf den Moons-Daten (Trainingsdaten, mit Dropout im Training). **CNN:** $28 \times 28 \rightarrow 14 \times 14 \rightarrow 7 \times 7$, Conv1 hat 80 Parameter, insgesamt 9098 (der FC-Teil $16 \cdot 49 \cdot 10 + 10 = 7850$ dominiert). **LSTM:** 1523 Parameter für Eingabe 5, versteckt 16: $4 \cdot 16 \cdot (5 + 16 + 1) = 1408$ plus Kopf $16 \cdot 3 + 3 = 51$ plus zweiter Bias-Vektor 64.

? Selbsttest: kannst du das herleiten?

F1 Warum teilt Adam durch $1 - \beta_1^t$?

A: m_t startet bei 0: $\mathbb{E}m_t = (1 - \beta_1^t)g$ ist zu klein, die Korrektur skaliert zurück.

F2 Wie viele Parameter hat Conv 3×3 ($1 \rightarrow 8$)?

A: $3 \cdot 3 \cdot 1 \cdot 8 + 8 = 80$.

F3 Was macht `opt.zero_grad()`?

A: Löscht die akkumulierten Gradienten vor dem nächsten Backward-Pass.

Foundation Models

Selbstüberwachtes Lernen & Transformer

Labels aus den Daten selbst erzeugen: maskierte oder nächste Teile vorhersagen.



Merke:
Next-Token:
 $\mathcal{L} = -\sum_t \log P(x_t | x_{<t}; \theta)$

Quelle: main_notes.pdf (Self-supervised learning and foundation models)

1 Motivation


Annotierte Daten sind teuer.

Selbstüberwachtes Lernen: nutze Struktur in den Daten selbst als Supervision (Pretraining auf riesigen unlabeled Daten), dann Anpassung an Zielaufgaben.

2 Pretraining: Vision

- **Kontrastiv** (SimCLR, MoCo): zwei Augmentierungen desselben Bildes = positiv, andere Bilder = negativ.
- **Masked Image Modeling** (MAE): verdeckte Bildteile aus dem Kontext rekonstruieren.

3 Skizze: Transformer-Block



4 Self-Attention

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Jedes Token bildet Query, Key, Value (X Token-Matrix, W_Q, W_K, W_V gelernte Matrizen, d_k Key-Dimension; $Q = XW_Q$, $K = XW_K$, $V = XW_V$) und mittelt die Values nach Ähnlichkeit.
Multi-Head: mehrere Attention-Köpfe parallel.

```
</> Self-Attention
S ← QKT / √dk
P ← softmax(S) # zeilenweise
return PV
```

Beispiel: Attention mit 2 Tokens

$d_k = 2$, $Q = K = I$, $V = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$.

Lösung $QK^T / \sqrt{2} = \text{diag}(0.71, 0.71)$. Zeile 1:

$\text{softmax}(0.71, 0) = (0.67, 0.33)$.

Ausgabe Zeile 1: $0.67 \cdot (1, 2) + 0.33 \cdot (3, 4) = (1.66, 2.66)$ - Mischung, die stärker Token 1 gewichtet.

5 Bausteine & Training

Feed-Forward: positionsweises MLP nach der Attention.
Positionskodierung: Attention ist permutationsinvariant, also Positionsinformation addieren. Residual + LayerNorm stabilisieren.

Pretraining: Sprachmodell sagt das nächste Token voraus, $\mathcal{L} = -\sum_t \log P(x_t | x_1 \dots x_{t-1})$.

Zero-Shot / In-Context: Aufgaben lösen allein durch Prompt (mit Beispielen), ohne Fine-Tuning.

6 Foundation-Model-Paradigma

1. **Pretrain** selbstüberwacht auf riesigen Daten
 2. **Adaptieren:** Fine-Tuning, Prompting, In-Context-Learning
 3. **Einsetzen** für viele Aufgaben mit wenig Labels
- Skalierung (Daten, Parameter, Rechenleistung) verbessert Fähigkeiten, oft emergent. (Siehe auch Double Descent: große Modelle generalisieren trotzdem.)

7 Vorteile

- ✓ wenige Labels nötig
- ✓ ein Modell für viele Aufgaben
- ✓ skaliert mit Daten

8 Grenzen

- ✗ enorme Rechen-/Datenkosten
- ✗ schwer interpretierbar
- ✗ übernimmt Verzerrungen der Daten

9 Key Takeaways

- ✓ Supervision aus den Daten selbst
- ✓ Attention: $\text{softmax}(QK^T / \sqrt{d_k})V$
- ✓ Pretrain → Adaptieren

? Selbsttest: kannst du das erklären?

F1 Was ist selbstüberwachtes Lernen?

A: Labels aus den Daten selbst (nächstes Token, maskierte Teile, Augmentierungen).

F2 Formel der Self-Attention?

A: $\text{softmax}(QK^T / \sqrt{d_k})V$.

F3 Wozu Positionskodierung?

A: Attention ist permutationsinvariant ⇒ Position explizit addieren.

„Lies das ganze Internet, sage das nächste Wort vorher -- und lerne dabei die Welt.“

Bias & Varianz

Zu einfach $\Rightarrow$ Bias (underfitting). Zu flexibel $\Rightarrow$ Varianz (overfitting). $\heartsuit$

Generalisierung, Underfitting, Overfitting & Double Descent

Merke:
Test-MSE
 $= \sigma^2 + \text{Bias}^2 + \text{Varianz}$

Quelle: main_notes.pdf (Generalization, Kap. 8), notes/cs229-notes4.pdf, notes/error-analysis.pdf

1 Intuition

Bias: Fehler, der bleibt, selbst mit unendlich vielen Daten – die Hypothesenklasse ist zu schwach (z. B. Gerade statt Parabel).

Varianz: wie stark h_S zwischen verschiedenen Trainingssets gleicher Größe schwankt – das Modell lernt Rauschen mit.


2 Zerlegung (Regression)

$$\mathbb{E}[(y - h_S(x))^2] = \underbrace{\sigma^2}_{\text{Rauschen}} + \underbrace{(h^* - \bar{h})^2}_{\text{Bias}^2} + \underbrace{\mathbb{E}[(\bar{h} - h_S)^2]}_{\text{Varianz}}$$

Legende: y Beobachtung, h_S auf Trainingsmenge S gelerntes Modell, h^* wahre Funktion, σ^2 Rauschvarianz, $\mathbb{E}_S$ Erwartung über Trainingsmengen.


$\bar{h} = \mathbb{E}_S[h_S]$ ist das "mittlere Modell" (Zentrum der Punktwolke rechts).

3 Parameterraum: Zielscheiben




blau: θ^* , rot: $\hat{\theta}_S$ verschiedener Datensätze

4 Modellkomplexität



5 Double Descent



Im überparametrisierten Regime wählt Gradient Descent implizit die Minimum-Norm-Lösung – oft gut.

Beispiel: Polynomgrad wählen (illustrative Zahlen)

Daten aus einer Parabel + Rauschen.

Grad	1	2	5
Train-MSE	0.30	0.05	0.00
Test-MSE	0.32	0.06	0.45

Grad 1: beide hoch $\Rightarrow$ **Bias**. Grad 5: Train ≈ 0 , Test hoch $\Rightarrow$ **Varianz**. Grad 2: bester Kompromiss.

6 Diagnose-Regeln

- **Hoher Bias:** Trainingsfehler schon hoch, kleine Lücke zum Testfehler; mehr Daten helfen nicht.
- **Hohe Varianz:** große Lücke Train/Test; Testfehler sinkt noch mit mehr Daten.
- Irreduzibles Rauschen σ^2 kann man nie eliminieren.

7 Gegen Bias

- komplexeres Modell / mehr Features
- weniger Regularisierung
- länger trainieren

8 Gegen Varianz

- mehr Trainingsdaten
- Regularisierung, weniger Features
- Bagging / Ensembles

9 Key Takeaways

- ✓ $\sigma^2 + \text{Bias}^2 + \text{Var}$
- ✓ Bias: Klasse zu schwach
- ✓ Varianz: Datensatz-Empfindlichkeit
- ✓ Double Descent bei $n \approx d$

? Selbsttest: kannst du das erklären?

F1 Zerlegung des Test-MSE?

A: σ^2 (Rauschen) + Bias^2 + Varianz.

F2 Woran erkennt man hohen Bias?

A: Trainingsfehler schon hoch, kleine Lücke zum Testfehler.

F3 Was ist Double Descent?

A: Testfehler steigt bei $n \approx d$ und fällt im überparametrisierten Regime erneut.

„Ein Modell muss so komplex sein wie die Daten – und keinen Deut komplexer.“

Lerntheorie

Wann darf ich dem Trainingsfehler trauen? Die Antwort liefert die Lerntheorie.



Hoeffding, Uniform Convergence & VC-Dimension

Merke:
Generalisierungslücke
 $\approx \sqrt{\log |\mathcal{H}|/n}$: nur
logarithmisch in $|\mathcal{H}|$!

Quelle: notes/cs229-notes4.pdf, extra-notes/hoeffding.pdf (J. Duchi), main_notes.pdf (Kap. 8)

1 Die Frage

Trainingsfehler

$J(h) = \frac{1}{n} \sum_i \mathbf{1}\{h(x^{(i)}) \neq y^{(i)}\}$ vs.
wahrer Fehler $L(h)$ (h Hypothese, $\mathcal{H}$
Hypothesenraum, 1 Indikator, n
Trainingsgröße). Wir wollen:


$|J(h) - L(h)|$ klein für alle $h \in \mathcal{H}$

(uniform convergence), denn $\hat{h}$ wird erst
nach Ansicht der Daten gewählt.

2 Werkzeugkasten

- **Markov:** $P(Z \geq t) \leq \mathbb{E}[Z]/t$ ($Z \geq 0$)
- **Chebyshev:**
 $P(|Z - \mathbb{E}Z| \geq t) \leq \text{Var}(Z)/t^2$
- **Chernoff:** exponentiell, über $\mathbb{E}[e^{\lambda Z}]$
- **Union Bound:** $P(\cup A_i) \leq \sum P(A_i)$

3 Skizze: Konzentration



4 Hoeffdingsche Ungleichung

Seien $Z_i \in [a, b]$ unabhängig (t : erlaubte Abweichung des
Mittelwerts). Dann für $t \geq 0$:

$$P\left(\left|\frac{1}{n} \sum_i (Z_i - \mathbb{E}Z_i)\right| \geq t\right) \leq 2 \exp\left(-\frac{2nt^2}{(b-a)^2}\right)$$

Für Fehler-Indikatoren ($a=0, b=1$):

$P(|J(h) - L(h)| \geq \gamma) \leq 2e^{-2\gamma^2 n}$. Beweis: Chernoff + Hoeffdings
Lemma $\mathbb{E}[e^{\lambda(Z - \mathbb{E}Z)}] \leq e^{\lambda^2(b-a)^2/8}$.

5 Endliche Hypothesenklasse

Union Bound über $k = |\mathcal{H}|$ Hypothesen (γ Toleranz, δ
Fehlerwahrscheinlichkeit, $\hat{h}$ ERM-Lösung):

$P(\exists h : |J - L| > \gamma) \leq 2k e^{-2\gamma^2 n}$. Mit Wahrscheinlichkeit
 $\geq 1 - \delta$:

$$|J(h) - L(h)| \leq \sqrt{\frac{\log(2k/\delta)}{2n}} \quad \forall h \in \mathcal{H}$$

Stichprobenkomplexität: $n \geq \frac{1}{2\gamma^2} \log \frac{2k}{\delta}$. Für ERM:
 $L(\hat{h}) \leq \min_h L(h) + 2\gamma$.

6 VC-Dimension

$VC(\mathcal{H})$ = Größe der größten Punktmenge, die $\mathcal{H}$ in jeder
Beschriftung korrekt trennen kann ("shattern"). Lineare
Klassifikatoren in $\mathbb{R}^d$: $VC = d + 1$.

Für unendliches $\mathcal{H}$ gilt (mit Wkt. $\geq 1 - \delta$; $O(\cdot)$: bis auf
Konstanten)

$$L(h) \leq J(h) + O\left(\sqrt{\frac{VC}{n} \log \frac{n}{VC}} + \frac{1}{n} \log \frac{1}{\delta}\right)$$

$\Rightarrow$ Bedarf an Daten wächst linear mit VC.

Beispiel: zwei Rechnungen

(a) $k = 10^6$ Hypothesen, $\delta = 0.05$, $\gamma = 0.05$:

$$n \geq \frac{\ln(2 \cdot 10^6 / 0.05)}{2 \cdot 0.05^2} = \frac{17.5}{0.005} \approx 3500 \text{ Beispiele.}$$

(b) Geraden in 2D ($d=2$): 3 Punkte in allgemeiner Lage lassen
sich in allen 2^3 Beschriftungen trennen $\Rightarrow VC = 3 = d + 1$. Vier
Punkte in XOR-Anordnung nicht.

7 Grenzen der Theorie

- Schranken oft sehr pessimistisch
- Deep Learning: $VC \gg n$, trotzdem
gute Generalisierung (Double Descent)

8 Key Takeaways

- ✓ Hoeffding: $2e^{-2n\gamma^2}$
- ✓ Union Bound $\Rightarrow \log |\mathcal{H}|$
- ✓ VC-Dim. für unendliche $\mathcal{H}$

9 Querverweise

- Bias-Varianz: γ ist die Varianz-Seite
- Regularisierung senkt effektive
Komplexität
- Perceptron: Fehlerschranke ähnlich im
Geist

? Selbsttest: kannst du das erklären?

F1 Was sagt Hoeffding?

A: $P(|\bar{Z} - \mathbb{E}\bar{Z}| \geq t) \leq 2e^{-2nt^2/(b-a)^2}$.

F2 Woher kommt $\log |\mathcal{H}|$?

A: Union Bound über $|\mathcal{H}|$ Hypothesen
(uniform convergence).

F3 VC-Dimension linearer Klassifikatoren
im $\mathbb{R}^d$?

A: $d + 1$.

„Mit genug Daten und einer nicht zu großen Hypothesenklasse wird aus Training Vertrauen.“

Generalisierung & Lerntheorie: Vertiefung

Bias-Varianz, Konzentrationsungleichungen und Generalisierungsschranken -- mit allen Zwischenschritten.



Merke:
Trainingsfehler → wahrer Fehler: die Brücke der Lerntheorie

Herleitung, Hoeffding, Perceptron

Quelle: main_notes.pdf Kap. 8 (Bias-varianz, Sample Complexity), extra-notes/hoeffding.pdf, notes/cs229-notes6.pdf; Schritte ergänzt

1 Bias-Varianz-Zerlegung (Regression)

Legende: $h^*(x)$ wahre Funktion, ξ Rauschen, S Trainingsmenge, h_S darauf gelerntes Modell, $\bar{h} = \mathbb{E}_S[h_S]$ mittleres Modell über alle möglichen Trainingsmengen, $\perp$ unabhängig.

Setup: $y = h^*(x) + \xi$, $\xi \sim \mathcal{N}(0, \sigma^2)$, unabhängig vom Trainingsset S ; h_S das gelernte Modell, $\bar{h} = \mathbb{E}_S[h_S]$.

$$\begin{aligned} \text{MSE}(x) &= \mathbb{E}[(y - h_S(x))^2] = \mathbb{E}[(\xi + (h^* - h_S))^2] & y &= h^* + \xi \\ &= \mathbb{E}[\xi^2] + \mathbb{E}[(h^* - h_S)^2] = \sigma^2 + \mathbb{E}[(h^* - h_S)^2] & \mathbb{E}[\xi] &= 0 \text{ und } \xi \perp S: \text{Kreuzterm} = 0 \\ &= \sigma^2 + \mathbb{E}[(h^* - \bar{h}) + (\bar{h} - h_S)^2] & \pm \bar{h} & \\ &= \sigma^2 + (h^* - \bar{h})^2 + \mathbb{E}[(\bar{h} - h_S)^2] & h^* - \bar{h} \text{ konstant, } \mathbb{E}[\bar{h} - h_S] &= 0: \text{Kreuzterm} = 0 \\ &= \underbrace{\sigma^2}_{\text{Rauschen}} + \underbrace{(h^* - \bar{h})^2}_{\text{Bias}^2} + \underbrace{\text{Var}(h_S(x))}_{\text{Varianz}}. \end{aligned}$$

In Worten: Der erwartete Fehler zerfällt in nicht vermeidbares Rauschen, die systematische Abweichung des Durchschnittsmodells (Bias²) und das Schwanken um dieses Durchschnittsmodell (Varianz).

Die Hilfsregel: für $A \perp B$ mit $\mathbb{E}A = 0$ gilt $\mathbb{E}[(A+B)^2] = \mathbb{E}A^2 + \mathbb{E}B^2$ (Kreuzterm $2\mathbb{E}[A]\mathbb{E}[B] = 0$).

2 Hoeffding (Beweisskizze)

$Z_i \in [a, b]$ unabhängig, $\bar{Z} = \frac{1}{n} \sum Z_i$. Für $\lambda > 0$:

Legende: Z_i Zufallsgrößen (z. B. 0/1-Fehler), $[a, b]$ deren Wertebereich, t Abweichung, λ Hilfsparameter der Chernoff-Methode.

$$\begin{aligned} P(\bar{Z} - \mathbb{E}\bar{Z} \geq t) &\leq e^{-\lambda t} \mathbb{E}[e^{\lambda(\bar{Z} - \mathbb{E}\bar{Z})}] & \text{Markov auf } e^{\lambda \cdot} \\ &= e^{-\lambda t} \prod_i \mathbb{E}[e^{\frac{\lambda}{n}(Z_i - \mathbb{E}Z_i)}] & \text{Unabhängigkeit} \\ &\leq e^{-\lambda t} e^{n \frac{\lambda^2(b-a)^2}{8n^2}} & \text{Hoeffdings Lemma} \end{aligned}$$

Optimales $\lambda = \frac{4nt}{(b-a)^2} \Rightarrow e^{-2nt^2/(b-a)^2}$; beide Seiten: Faktor 2.

In Worten: Das Stichprobenmittel weicht nur selten weit vom wahren Mittel ab, und zwar exponentiell selten in n .

3 Generalisierungsschranke

Legende: $\mathcal{H}$ Hypothesenraum mit k Elementen, $J(h)$ Trainingsfehler, $L(h)$ wahrer Fehler, γ Toleranz, δ Fehlerwahrscheinlichkeit, $\hat{h}$ ERM-Lösung, h^* bestes h in $\mathcal{H}$.

$$\begin{aligned} P(\exists h \in \mathcal{H} : |J(h) - L(h)| > \gamma) &\leq \sum_h P(|J - L| > \gamma) & \text{Union Bound} \\ &\leq 2k e^{-2\gamma^2 n} =: \delta & \text{Hoeffding} \\ \Rightarrow \gamma &= \sqrt{\frac{\log(2k/\delta)}{2n}} \end{aligned}$$

ERM $\hat{h}$, bestes h^* : $L(\hat{h}) \leq J(\hat{h}) + \gamma \leq J(h^*) + \gamma \leq L(h^*) + 2\gamma$.

In Worten: Für jedes einzelne h ist Trainings- $\approx$ wahrer Fehler; die Union Bound sichert das für alle k zugleich. ERM verliert höchstens 2γ gegen das Beste.

4 Perceptron-Fehlerschranke

Legende: $\theta^{(k)}$ Gewichte nach k Updates, (x, y) falsch klassifiziertes Beispiel, u perfekter Trennvektor, γ Margin, D Radius der Daten.

Fehler beim k -ten Update: $y\theta^{(k)\top}x \leq 0$, $\theta^{(k+1)} = \theta^{(k)} + yx$; $\|u\| = 1$, $yu^\top x \geq \gamma$, $\|x\| \leq D$.

$$\theta^{(k+1)\top}u = \theta^{(k)\top}u + yx^\top u \geq \theta^{(k)\top}u + \gamma \Rightarrow \geq k\gamma$$

$$\|\theta^{(k+1)}\|^2 = \|\theta^{(k)}\|^2 + 2y\theta^{(k)\top}x + \|x\|^2$$

$$\leq \|\theta^{(k)}\|^2 + D^2 \Rightarrow \leq kD^2$$

$$k\gamma \leq \theta^{(k+1)\top}u \leq \|\theta^{(k+1)}\| \leq \sqrt{k}D \Rightarrow k \leq (D/\gamma)^2$$

Beispiel: Konzentration in Zahlen

Fehlerrate einer Hypothese, $n = 1000$ Trainingsbeispiele, Toleranz $\gamma = 0.05$.

Lösung Hoeffding:

$$P(|J - L| \geq 0.05) \leq 2e^{-2 \cdot 0.0025 \cdot 1000} = 2e^{-5} \approx \mathbf{0.013}.$$

Mit $k = 10^6$ Hypothesen: $2 \cdot 10^6 e^{-5} \gg 1$ - Schranke nutzlos; man braucht $n \geq 3500$ (Kapitel Lerntheorie).

5 Lese-Tipps

- Kreuzterme fallen weg, wenn Erwartungswert 0 und Unabhängigkeit.
- "± einfügen" ist der Standardtrick (Bias-Varianz).
- Konzentration: Markov → Chernoff → Hoeffding; dann Union Bound für "für alle h ".

? Selbsttest: kannst du das herleiten?

F1 Warum verschwindet der Kreuzterm

$$\mathbb{E}[(h^* - \bar{h})(\bar{h} - h_S)]?$$

A: $h^* - \bar{h}$ ist konstant und $\mathbb{E}[\bar{h} - h_S] = 0$.

F2 Wo geht die Union Bound ein?

A: Sie macht aus "für ein festes h " ein "für alle $h \in \mathcal{H}$ " (Faktor k).

F3 Warum begrenzen zwei Ungleichungen die Perceptron-Fehler?

A: Projektion auf u wächst linear, Norm nur wie $\sqrt{k}$: beides passt nur für $k \leq (D/\gamma)^2$.

„Erst zerlegen, dann abschätzen: Fehler = Rauschen + Bias + Varianz.“

Große Gewichte bestrafen: das Modell wird einfacher, die Varianz sinkt. ❤️

Regularisierung & Modellauswahl

Overfitting bändigen, Hyperparameter richtig wählen

Merke:
L2 = Gauß-Prior, L1 = Laplace-Prior (MAP-Sicht)

Quelle: main_notes.pdf (Regularization and model selection), notes/cs229-notes5.pdf

1 Idee

Zum Verlust einen **Strafterm** addieren:

L2 (Ridge): $J_\lambda = J + \frac{\lambda}{2} \|\theta\|_2^2$

L1 (Lasso): $J_\lambda = J + \lambda \|\theta\|_1$

λ steuert den Kompromiss Bias $\leftrightarrow$ Varianz (J : ursprünglicher Verlust, $\|\theta\|_2^2 = \sum \theta_j^2$, $\|\theta\|_1 = \sum |\theta_j|$).

2 Bayessche Sicht (MAP)

$$\theta_{\text{MAP}} = \arg \max_{\theta} [\log p(y|X, \theta) + \log p(\theta)]$$


Gauß-Prior $\theta_j \sim \mathcal{N}(0, \tau^2)$ (τ^2

Prior-Varianz) $\Rightarrow$ L2. Laplace-Prior

$p(\theta_j) \propto e^{-|\theta_j|/b} \Rightarrow$ L1. Lineare

Regression: $\theta = (X^T X + 2\lambda\sigma^2 I)^{-1} X^T y$
(immer invertierbar; σ^2 Rauschvarianz, b Laplace-Skala, I Einheitsmatrix).

3 Skizze: L1 vs. L2



4 Kreuzvalidierung

K-Fold Cross-Validation

teile Daten in K gleich große Teile

for jeden Kandidaten λ :

for $k = 1..K$:

trainiere auf allen Teilen außer k

$e_k \leftarrow$ Fehler auf Teil k

$$CV(\lambda) \leftarrow \frac{1}{K} \sum_k e_k$$

wähle $\lambda^* = \arg \min CV(\lambda)$

trainiere neu auf allen Trainingsdaten

Beispiel: Ridge in 1D

Daten $(1, 1), (2, 2), (3, 2)$, Modell $y \approx \theta x$ (ohne Bias). $\sum xy = 11$, $\sum x^2 = 14$.

Lösung $\theta_\lambda = \frac{\sum xy}{\sum x^2 + \lambda} = \frac{11}{14 + \lambda}$

$\lambda = 0$: $\theta = 0.786$ | $\lambda = 2$: $\theta = 0.688$ | $\lambda = 14$: $\theta = 0.393$

Je größer λ , desto stärker schrumpft θ Richtung 0.

5 Modellauswahl-Strategien

- **Hold-out** (z. B. 70/30 oder Train/Val/Test): schnell, aber verschwendet Daten.
- **K-Fold** ($K=5, 10$): stabilere Schätzung.
- **Leave-one-out** ($K=n$): fast unverzerrt, teuer.
- **Feature-Auswahl**: Forward Search (Features einzeln hinzufügen), Backward Search (entfernen), Filter (Korrelation).

Testset nur einmal am Ende benutzen!

6 Implizite Regularisierung

Auch ohne Strafterm regularisiert Gradient Descent: im überparametrisierten Regime wählt SGD unter allen Interpolatoren bevorzugt die mit minimaler Norm (ähnlich L2). Frühes Stoppen wirkt ähnlich.

Tipp: λ per Kreuzvalidierung auf logarithmischem Gitter suchen ($10^{-4}, \dots, 10^2$).

7 Vorteile

- ✓ weniger Overfitting
- ✓ L1: automatische Feature-Auswahl
- ✓ stabilere Lösung ($X^T X$ invertierbar)

8 Grenzen

- ✗ λ muss gewählt werden
- ✗ zu großes $\lambda \Rightarrow$ Bias
- ✗ Features vorher skalieren

9 Key Takeaways

- ✓ L2 schrumpft, L1 macht spärlich
- ✓ Regularisierung = Prior (MAP)
- ✓ λ via Kreuzvalidierung

? Selbsttest: kannst du das erklären?

F1 L1 vs. L2?

A: L2 schrumpft gleichmäßig; L1 erzeugt Sparsität (Nullen).

F2 Bayessche Deutung?

A: L2 = Gauß-Prior, L1 = Laplace-Prior (MAP).

F3 Wozu K-Fold-CV?

A: Hyperparameter wählen, danach auf allen Daten neu trainieren.

„Regularisierung ist Vorsicht in Formeln: lieber ein bisschen zu einfach als zu eifrig.“

Ridge, MAP und Lasso ausgerechnet -- Regularisierung ist ein Prior in Verkleidung.



Regularisierung: Vertiefung

Herleitung und Code

Merke:
 $\lambda = \sigma^2 / \tau^2$: starker Prior = starke Regularisierung

Quelle: main_notes.pdf Kap. 9 (Regularisierung, Bayes); Schritte ergänzt; Code: code/sk_regularization.py (real ausgeführt)

1 Ridge-Lösung

$$J_\lambda = \frac{1}{2} \|X\theta - y\|^2 + \frac{\lambda}{2} \|\theta\|^2$$

Legende: $\lambda \geq 0$ Stärke der Regularisierung, $\|\theta\|^2 = \sum \theta_j^2$, I Einheitsmatrix, $\succ 0$ positiv definit (alle Eigenwerte > 0), λ_i Eigenwerte von $X^\top X$.

$$\nabla J_\lambda = X^\top (X\theta - y) + \lambda\theta = 0$$

$$(X^\top X + \lambda I)\theta = X^\top y \Rightarrow \theta_\lambda = (X^\top X + \lambda I)^{-1} X^\top y$$

$X^\top X + \lambda I \succ 0$ für $\lambda > 0$: immer invertierbar. Eigenwerte $\lambda_i \rightarrow \lambda_i + \lambda$: kleine Richtungen werden gedämpft.

In Worten: Der Strafterm zieht θ zum Nullpunkt. Die Lösung sieht aus wie die Normalgleichung mit einem zusätzlichen λ auf der Diagonalen.

2 MAP = Ridge

Prior $\theta \sim \mathcal{N}(0, \tau^2 I)$, Rauschen $\mathcal{N}(0, \sigma^2)$:

Legende: $p(\theta)$ Prior (Vorwissen über θ), τ^2 Prior-Varianz, σ^2 Rauschvarianz, θ_{MAP} wahrscheinlichstes θ nach Sicht der Daten.

$$\theta_{\text{MAP}} = \arg \max [\log p(y|X, \theta) + \log p(\theta)]$$

$$= \arg \min \left[\frac{1}{2\sigma^2} \|X\theta - y\|^2 + \frac{1}{2\tau^2} \|\theta\|^2 \right] \quad - \log \text{ der Gauß-Dichten}$$

$= \arg \min \frac{1}{2} \|X\theta - y\|^2 + \frac{\lambda}{2} \|\theta\|^2$ mit $\lambda = \frac{\sigma^2}{\tau^2}$. Starker Prior (kleines τ) = großes λ .

In Worten: MAP maximiert Likelihood mal Prior. Der Minus-Logarithmus davon ist Fehlerquadratsumme plus Strafterm, also genau Ridge.

3 Lasso: Soft-Thresholding

Legende: z unregularisierte Lösung, λ Stärke, $s \in \partial|\theta|$ Subgradient (bei $\theta = 0$ ganzes Intervall $[-1, 1]$).

1D (bzw. orthonormale Designs): $\min_\theta \frac{1}{2} (\theta - z)^2 + \lambda |\theta|$.

Subgradient: $\theta - z + \lambda s = 0$ mit $s \in \partial|\theta|$.

$$\theta > 0 : \theta = z - \lambda \quad (z > \lambda) \quad \theta < 0 : \theta = z + \lambda \quad (z < -\lambda)$$

$$\theta = 0 : |z| \leq \lambda$$

$\theta^* = \text{sign}(z) \max(|z| - \lambda, 0)$: kleine Koeffizienten werden exakt Null (Sparsität).

In Worten: Lasso schiebt jeden Koeffizienten um λ Richtung Null; was betragsmäßig kleiner als λ ist, landet auf Null.

Beispiel: Ridge-Schrumpfung nachgerechnet

1D ohne Bias: $\sum xy = 11$, $\sum x^2 = 14$ (Summen über die Datenpunkte), θ Steigung, λ Stärke. Ridge: $(14 + \lambda)\theta = 11$.

Lösung $\lambda = 0$: $\theta = 0.786$; $\lambda = 2$: $\frac{11}{16} = 0.688$; $\lambda = 14$:

$\frac{11}{28} = 0.393$.

Lasso ($z = 0.786$): $\lambda = 0.3 \rightarrow 0.486$; $\lambda = 1 \rightarrow 0$ (exakt null).

Code: Ridge schrumpft, Lasso macht spärlich

```
import numpy as np
from sklearn.datasets import make_regression
from sklearn.linear_model import Lasso, Ridge, LinearRegression
X, y, w = make_regression(100, 20, n_informative=4, noise=10,
                        coef=True, random_state=0)
print("wahre Nicht-Null-Koeff.: ", int((w != 0).sum()))
for name, m in [("OLS", LinearRegression()), ("Ridge a=50", Ridge(50)),
                ("Lasso a=2", Lasso(2))]:
    m.fit(X, y)
    print(f"{name:10s} |w|_2 {np.linalg.norm(m.coef_):6.1f} "
          f"NulLEN {int((np.abs(m.coef_) < 1e-8).sum()):2d}")
```

Ausgabe (real ausgeführt)

```
wahre Nicht-Null-Koeff.: 4
OLS |w|_2 77.9 NulLEN 0
Ridge a=50 |w|_2 52.7 NulLEN 0
Lasso a=2 |w|_2 74.1 NulLEN 16
```

4 Lesart der Ausgabe

Nur 4 von 20 Features sind informativ. Ridge schrumpft die Norm (77.9 $\rightarrow$ 52.7), setzt aber keinen Koeffizienten auf null. Lasso setzt 16 von 20 Koeffizienten exakt auf null; übrig bleiben 4, so viele wie informative Features (Sparsität, Herleitung: Soft-Thresholding). α steuert die Stärke; sklearn nennt den Regularisierungsparameter alpha (bei LogisticRegression: $C = 1/\lambda$).

? Selbsttest: kannst du das herleiten?

F1 Wie hängen λ und der Prior zusammen?

A: $\lambda = \sigma^2 / \tau^2$ (Rauschvarianz durch Prior-Varianz).

F2 Warum macht L1 Koeffizienten exakt null?

A: Der Subgradient von $|\theta|$ ist bei 0 das Intervall $[-1, 1]$; für $|z| \leq \lambda$ liegt das Optimum bei 0.

F3 Warum ist $X^\top X + \lambda I$ immer invertierbar?

A: Alle Eigenwerte sind $\geq \lambda > 0$.

„Was wie ein Trick aussieht, ist meist ein Prior in Verkleidung.“

Gute Modelle brauchen gute Validierung und die richtigen Hyperparameter. ❤️

Validierung & Hyperparameter-Tuning

Cross-Validation, Grid/Random Search, Nested CV

Merke:
Testset nur einmal am Ende benutzen!

Quelle: hand-notes/ML Notes.pdf (Cross-Validation & Hyperparameter Tuning), notes/os229-notes5.pdf (Model selection)

1 Warum Kreuzvalidierung?

Ein einzelner Train/Test-Split liefert eine verrauschte Schätzung des Generalisierungsfehlers. CV nutzt mehrere Splits und mittelt $\Rightarrow$ stabilere Schätzung, bessere Datennutzung.

2 K-Fold

Daten in K Teile; jeder Teil ist einmal Validierung, der Rest Training:

$$CV = \frac{1}{K} \sum_{k=1}^K \text{Score}_k$$

Üblich $K = 5$ oder 10 . Danach: mit dem besten Hyperparameter auf allen Daten neu trainieren.

3 Skizze: 5 Folds

1	Test	Train	Train	Train	Train
2	Train	Test	Train	Train	Train
3	Train	Train	Test	Train	Train
4	Train	Train	Train	Test	Train
5	Train	Train	Train	Train	Test

4 CV-Varianten

- **Stratified K-Fold:** Klassenanteile pro Fold erhalten (Ungleichgewicht).
- **Leave-One-Out:** $K = n$, fast unverzerrt, sehr teuer.
- **Repeated K-Fold:** mit neuen Zufallssplits wiederholen.
- **Zeitreihen-CV (Walk-Forward):** Training immer vor der Validierung, nie in die Zukunft blicken.
- **Group-CV:** zusammengehörige Beispiele nie über Folds verteilen.

6 Grid vs. Random Search

`</>` Random Search mit CV

repeat T mal:

ziehe Kombination h zufällig aus dem Suchraum

$s(h) \leftarrow$ CV-Score von Modell(h)

wähle $h^* = \arg\max_h s(h)$; trainiere neu auf allen Daten

Grid: alle Kombinationen (exponentiell viele). Random: oft effizienter, weil meist nur wenige Hyperparameter wirklich zählen.

5 Parameter vs. Hyperparameter

Parameter werden gelernt (Gewichte θ , W). Hyperparameter legt man vorher fest und tut sie (Lernrate, λ , C , γ , k , Baumtiefe, K bei K-Means, Netzgröße). Gute Hyperparameter $\Rightarrow$ besseres Modell; sie nie mit dem Testset wählen.

7 Nested Cross-Validation

Wird der selbe CV-Score zum Tunen und zum Berichten genutzt, ist er optimistisch verzerrt. Lösung:

`</>` Nested CV

for äußerer Fold $k = 1..K$:

Trainingsteil $\rightarrow$ innere CV: wähle h^*

trainiere mit h^* auf dem ganzen Trainingsteil

bewerte auf dem äußeren Testfold $\rightarrow s_k$

Bericht: $\frac{1}{K} \sum_k s_k$

Beispiel: Auswertung & Rechenaufwand

5-Fold-Scores (0.82, 0.85, 0.80, 0.84, 0.83).

Lösung Mittel = **0.828**, Standardabweichung $s \approx 0.019 \Rightarrow$

"0.83 $\pm$ 0.02".

Random Forest, Gitter $3 \times 2 = 6$ Kombinationen, 5-Fold: $6 \cdot 5 = 30$ Fits (+1 Refit).

Nested (5 außen, 3 innen): $5 \cdot (3 \cdot 6 + 1) = 95$ Fits – deshalb bei großen Modellen Random Search.

8 Tuning-Workflow

1. Suchraum und Metrik festlegen
2. Suchstrategie (Grid/Random/Bayes)
3. CV-Score je Kombination
4. beste Kombination wählen
5. auf allen Trainingsdaten neu trainieren
6. einmal auf dem Testset bewerten

9 Fallstricke

- × Testset zum Tunen benutzen
- × Vorverarbeitung vor dem Split (Leakage) $\rightarrow$ Pipeline
- × ungeeignete CV für Zeitreihen/Gruppen
- × zu große Suche $\Rightarrow$ Overfitting auf den Validierungsfolds

10 Key Takeaways

- ✓ Mehr Splits $\Rightarrow$ stabilere Schätzung; Stratified bei Ungleichgewicht, Walk-Forward bei Zeitreihen
- ✓ Random Search $\geq$ Grid bei vielen Hyperparametern; Nested CV für ehrliche Bewertung

? Selbsttest: kannst du das erklären?

F1 Wozu Nested CV?

A: Tuning und Bewertung trennen: sonst ist der CV-Score optimistisch.

F2 Warum Walk-Forward bei Zeitreihen?

A: Zufällige Folds würden Zukunftsdaten ins Training mischen (Leakage).

F3 Warum am Ende neu auf allen Daten trainieren?

A: CV dient nur der Auswahl; das finale Modell soll alle Trainingsdaten nutzen.

„Validiere klug, tune weise, teste nur einmal.“

Gaussian Processes

Bayessche Regression mit Kernels

Nicht ein bester Fit, sondern eine Verteilung über Funktionen -- samt Unsicherheit.



Merke:
Vorhersage =
Konditionierung einer
Gauß-Verteilung!

Quelle: section/cs229-gaussian_processes.pdf (Chuang Do, Honglak Lee)

1 Bayessche Sicht

Klassisch: ein Best-Fit- θ . Bayessch:
Posterior-Verteilung über Modelle $\Rightarrow$
jede Vorhersage kommt mit einem
Unsicherheitsmaß (Konfidenzband).


2 Was ist ein GP?

Stochastischer Prozess $\{f(x)\}$, bei dem
jede endliche Teilmenge gemeinsam
multivariat gaußverteilt ist:

$$f(\cdot) \sim \mathcal{GP}(m(\cdot), k(\cdot, \cdot))$$

Mittelwertfunktion m , Kovarianzfunktion
= **Kernel** k .

3 Skizze: Posterior



4 Modell & Kernel

Legende: f unbekannte Funktion, ε Rauschen mit Varianz σ^2 ,
 $k(x, x')$ Kernel (Ähnlichkeit zweier Eingaben), τ Längenskala.

$$y^{(i)} = f(x^{(i)}) + \varepsilon^{(i)}, \varepsilon \sim \mathcal{N}(0, \sigma^2), \text{ Prior } f \sim \mathcal{GP}(0, k).$$

Standard: Squared-Exponential-Kernel

$$k(x, x') = \exp\left(-\frac{\|x - x'\|^2}{2\tau^2}\right)$$

Nahe Punkte $\rightarrow$ stark korreliert $\Rightarrow$ Funktionen sind lokal glatt;
 τ klein: wackelig, τ groß: glatt.

5 Vorhersage (Posterior Predictive)

Gemeinsam gaußverteilt $\Rightarrow$ Konditionieren:

Legende: X Trainings-, X_* Testeingaben, $K(A, B)$ Matrix der
Kernelwerte aller Paare aus A und B , μ_* , Σ_* Mittel und
Kovarianz der Vorhersage, I Einheitsmatrix.

$$\mu_* = K(X_*, X)(K(X, X) + \sigma^2 I)^{-1} y$$

$$\Sigma_* = K(X_*, X_*) - K(X_*, X)(K(X, X) + \sigma^2 I)^{-1} K(X, X_*)$$

6 Algorithmus

GP-Regression

$K \leftarrow [k(x_i, x_j)]_{ij}$ # $n \times n$ Gram-Matrix; L : Cholesky-Faktor,
 α : Gewichtsvektor

$L \leftarrow \text{chol}(K + \sigma^2 I)$

$\alpha \leftarrow (L^\top)^{-1} (L^{-1} y)$

for Testpunkt x_* :

$k_* \leftarrow [k(x_i, x_*)]_i$

$\mu_* \leftarrow k_*^\top \alpha$

$v \leftarrow L^{-1} k_*$; $\sigma_*^2 \leftarrow k(x_*, x_*) - v^\top v$

Beispiel: 1 Trainingspunkt

$(x, y) = (0, 1)$, $\sigma^2 = 0.1$, $\tau = 1$. Vorhersage bei $x_* = 1$:

Lösung $K + \sigma^2 I = 1.1$, $k_* = e^{-1/2} = 0.607$.

$$\mu_* = 0.607 \cdot \frac{1}{1.1} \cdot 1 = \mathbf{0.55}$$

$$\Sigma_* = 1 - \frac{0.607^2}{1.1} = 1 - 0.334 = \mathbf{0.67}$$

Bei $x_* = 0$: $\mu = 0.91$, $\text{Var} = 0.09$ (sicher). Bei $x_* = 3$: $\mu \approx 0$, $\text{Var} \approx 1$ (zurück zum Prior).

7 Vorteile

- ✓ liefert Unsicherheit
- ✓ wenige Hyperparameter
- ✓ Prädiktion in geschlossener Form

8 Grenzen

- ✗ $O(n^3)$ Zeit, $O(n^2)$ Speicher
- ✗ Kernel-Wahl entscheidend
- ✗ Schwierig bei sehr großem n

9 Key Takeaways

- ✓ Prior über Funktionen via Kernel
- ✓ Vorhersage = Gauß-Konditionierung
- ✓ Σ_* ist kalibrierte Unsicherheit

10 Verbindungen

Kernelisierte Bayessche lineare Regression liefert dieselbe Vorhersageverteilung wie GP-Regression – die Funktions-Sicht ist nur viel einfacher herzuleiten. Bausteine: Multivariate Gauß-Formeln (Marginal/Conditional aus der Faktorenanalyse), Kernels (Mercer), MAP-Regularisierung.

? Selbsttest: kannst du das erklären?

F1 Was definiert einen GP?

A: Mittelwertfunktion m und Kernel k ;
jede endliche Teilmenge ist gaußverteilt.

F2 Was liefert Σ_* ?

A: Vorhersage-Unsicherheit: klein nahe
Trainingspunkten, groß weit weg.

F3 Rechenaufwand?

A: $O(n^3)$ (Cholesky der $n \times n$ -Matrix).

„Ein guter Vorhersager weiß, wann er etwas nicht weiß.“

Erst diagnostizieren, dann reparieren -- nicht planlos herumprobieren. ❤️

Praktische Fehleranalyse

Diagnostik, Error & Ablative Analysis

Merke:
Lernkurve lesen: Lücke $\Rightarrow$ Varianz, hoher Train-Fehler $\Rightarrow$ Bias

Quelle: materials/ML-advice.pdf (A. Ng), notes/error-analysis.pdf (Y. Le Colonneo), section/error-analysis.pdf

1 Problem


Spamfilter mit 20% Testfehler. Mögliche Maßnahmen: mehr Daten, weniger/mehr Features, mehr Iterationen, Newton, anderes λ , SVM... Blindes Ausprobieren kostet Wochen. **Diagnose zuerst!**

2 Lernkurven

Plotte Train- und Testfehler über der Trainingsgröße m :

- **Varianz:** große Lücke, Test fällt noch $\Rightarrow$ mehr Daten helfen
- **Bias:** Train schon hoch, kleine Lücke $\Rightarrow$ Modell ausdrucksstärker machen

3 Skizze: zwei Diagnosen



4 Welche Maßnahme behebt was?

Maßnahme	behebt
mehr Trainingsbeispiele	hohe Varianz
weniger Features	hohe Varianz
mehr / bessere Features	hohen Bias
mehr Iterationen, Newton	Optimierungsalgorithmus
anderes λ / C , andere Klasse	Optimierungsziel

5 Algorithmus oder Ziel?

Ein SVM schlägt BLR (Bayessche Logistische Regression) bei der wahren Metrik $a(\theta)$, obwohl BLR das Ziel $J(\theta)$ maximiert (θ Parameter, J Zielfunktion, a Metrik, die uns wirklich interessiert). Vergleiche $J(\theta_{\text{SVM}})$ mit $J(\theta_{\text{BLR}})$:

```

</> Diagnose
if  $J(\theta_{\text{BLR}}) < J(\theta_{\text{SVM}})$ :
    Problem = Optimierer (nicht konvergiert)
     $\rightarrow$  mehr Iterationen, Newton, andere  $\alpha$ 
else: #  $J$  erreicht, aber  $a$  schlecht
    Problem = Zielfunktion falsch
     $\rightarrow$  anderes  $\lambda/C$ , Gewichte, andere Klasse
    
```

6 Error Analysis (Pipeline)

Bei mehrstufigen Systemen jede Komponente einzeln durch die Ground Truth ersetzen und die Gesamtgenauigkeit messen:

+ perfektes Preprocessing	85.1 %
+ perfekte Gesichtsdetektion	91 %
+ perfekte Augen-Segmentierung	95 %

(Start: 85.1%) Große Sprünge zeigen, wo Arbeit sich lohnt.

7 Ablative Analyse

Umgekehrt: vom guten System aus Komponenten entfernen.

Gesamtsystem	99.9 %
– Rechtschreibung	99.0 %
– Text-Parser	95 %
– Bild-Features (Baseline)	94 %

Zeigt, welche Features wirklich beitragen (gut für Publikationen).

Beispiel: Fehler manuell zählen

Katzenklassifikator, Accuracy 90%. Von 100 Fehlern sind ...

Lösung 5 Hunde: Selbst mit perfektem Hunde-Filter steigt die Accuracy nur 90% $\rightarrow$ **90.5%** – nicht lohnend.

50 Hunde: $\rightarrow$ **95%** – hier lohnt sich die Arbeit!

8 Vorgehen in 5 Schritten

1. Baseline bauen, Metrik festlegen
2. Lernkurve $\rightarrow$ Bias oder Varianz?
3. Optimierer vs. Ziel prüfen
4. Error Analysis der Pipeline
5. ca. 100 Fehler kategorisieren, priorisieren

9 Key Takeaways

- ✓ Diagnose vor Aktion
- ✓ Lernkurve: Lücke = Varianz, Train hoch = Bias
- ✓ J vs. a : Optimierer oder Ziel schuld?
- ✓ Fehleranalyse zeigt die Obergrenze des Gewinns

? Selbsttest: kannst du das erklären?

F1 Lernkurve: Varianz oder Bias?

A: Große Lücke $\Rightarrow$ Varianz; hoher Trainingsfehler $\Rightarrow$ Bias.

F2 $J(\theta_{\text{BLR}}) < J(\theta_{\text{SVM}})$ bedeutet?

A: Optimierer hat sein Ziel nicht erreicht (Konvergenzproblem).

F3 Error vs. Ablative Analysis?

A: Error: Komponenten durch Ground Truth ersetzen; Ablation: Komponenten entfernen.

„Wer nicht misst, verbessert das Falsche.“

Die Trainings-Kosten sind nur ein Proxy -- Metriken übersetzen das echte Ziel in eine Zahl. ❤️

Evaluationsmetriken

Confusion Matrix, Precision/Recall, ROC & PR

Merke:
Accuracy < AUROC < AUPRC bei starkem Klassenungleichgewicht

Quelle: section/evaluation_metrics_spring2020.pdf (Y. Chen, nach A. Avati)

1 Warum Metriken?


Nicht alle Fehler sind gleich teuer (übersehener Tumor vs. Fehlalarm). Metriken quantifizieren die Lücke zwischen Baseline, aktuellem und gewünschtem Ergebnis und steuern die Teamarbeit.

2 Konfusionsmatrix

	Label +	Label -
Vorhersage +	TP	FP
Vorhersage -	FN	TN

FP = Fehler 1. Art, FN = Fehler 2. Art

3 Skizze: ROC & PR



4 Punkt-Metriken

Metrik	Formel	Frage
Accuracy	$\frac{TP + TN}{\text{alle}}$	Anteil richtig
Precision	$\frac{TP}{TP + FP}$	Positive echt?
Recall (Sens.)	$\frac{TP}{TP + FN}$	Positive gefunden?
Specificity	$\frac{TN}{TN + FP}$	Negative gefunden?
F1	$\frac{2PR}{P + R}$	harm. Mittel (P, R)

Beispiel: Schwelle 0.5 vs. 0.6

20 Beispiele (10 pos., 10 neg.).

Lösung Schwelle 0.5: TP=9, FP=2, FN=1, TN=8: Acc = $\frac{17}{20} = 0.85$,

Prec = $\frac{9}{11} = 0.82$, Recall = 0.90, Spec = 0.80, F1 = **0.857**.

Schwelle 0.6: TP=7, FP=2, FN=3, TN=8: Acc = 0.75, Prec = 0.78, Recall = 0.70, F1 = 0.737.

Höhere Schwelle $\Rightarrow$ weniger Recall.

7 Klassenungleichgewicht

Prävalenz < 5%: Accuracy ist trivial hoch (immer Mehrheitsklasse), AUROC leicht hochzuhalten (viele Negative sehr niedrig scoren), AUPRC robuster.

Log-Loss/Brier-Score $\frac{1}{n} \sum (\hat{p}_i - y_i)^2$ ($\hat{p}_i$ vorhergesagte Wkt., $y_i \in \{0, 1\}$) bewerten Kalibrierung und strafen selbstsichere Fehler hart (proper scoring rules).

8 Welche Metrik?

- FN teuer $\rightarrow$ Recall
- FP teuer $\rightarrow$ Precision
- Ungleichgewicht $\rightarrow$ AUPRC, F1
- Wahrscheinlichkeiten $\rightarrow$ Log-Loss

9 Fallstricke

- ✗ Accuracy täuscht bei seltenen Klassen
- ✗ Test-Metrik nie zum Tuning nutzen
- ✗ Ranking-Metriken ignorieren Kalibrierung

10 Key Takeaways

- ✓ TP/FP/FN/TN als Basis
- ✓ Precision $\leftrightarrow$ Recall Tradeoff
- ✓ AUROC vs. AUPRC bei Ungleichgewicht

* Weitere Metriken & Mehrklassen (aus den ML Notes)

FPR = $\frac{FP}{FP + TN}$ = 1 - Spec, FNR = $\frac{FN}{FN + TP}$ = 1 - Recall, NPV = $\frac{TN}{TN + FN}$. Mehrklassen: One-vs-Rest, dann Metriken je Klasse mitteln - Macro (einfacher Mittelwert), Micro (globale Zählung aller TP/FP/FN), Weighted (nach Klassenhäufigkeit). Beispiel (80 TP, 20 FP, 10 FN, 90 TN): Acc = 0.85, Prec = 0.80, Recall = 0.89, F_1 = 0.84. Wahl: ausgeglichen $\rightarrow$ Accuracy/ F_1 ; Ungleichgewicht $\rightarrow$ PR-AUC/ F_1 ; FP teuer $\rightarrow$ Precision/Spezifität; FN teuer $\rightarrow$ Recall; Ranking $\rightarrow$ ROC-AUC/PR-AUC.

? Selbsttest: kannst du das erklären?

F1 Precision vs. Recall?

A: Precision = $\frac{TP}{TP + FP}$, Recall = $\frac{TP}{TP + FN}$.

F2 Wann AUPRC statt AUROC?

A: Bei starkem Klassenungleichgewicht (AUROC bleibt leicht hoch).

F3 Wirkung einer höheren Schwelle?

A: Weniger positive Vorhersagen: Recall sinkt, Precision steigt meist.

„Was du misst, wird besser -- also miss, was wirklich zählt.“

Regressionsmetriken

MAE, MSE, RMSE, R^2 und Adjusted R^2

Wie gut ist ein Regressionsmodell wirklich? Fehlermaße und Varianzerklärung. ❤️

Merke:
MSE $\leftrightarrow$ Gauß-Rauschen,
MAE $\leftrightarrow$ Laplace-Rauschen

Quelle: hand-notes/ML Notes.pdf (Regression Metrics); Rechenbeispiel dort korrigiert ($R^2 = 0.874$, nicht 0.884: SST = 12.30); Bezug zu MLE aus dem Kursstoff

1 Notation

y_i wahr, $\hat{y}_i$ vorhergesagt, $\bar{y}$ Mittel der wahren Werte, n Beispiele, p Prädiktoren, Residuum $e_i = y_i - \hat{y}_i$.
Ziel: kleine Fehler und Generalisierung (auf dem Testset messen!).

2 Fehlerbasierte Metriken


$$\text{MAE} = \frac{1}{n} \sum |y_i - \hat{y}_i|$$

$$\text{MSE} = \frac{1}{n} \sum (y_i - \hat{y}_i)^2$$


$$\text{RMSE} = \sqrt{\text{MSE}}$$

Kleiner ist besser. RMSE hat die Einheit von y ; MSE/RMSE bestrafen große Fehler stärker.

3 Skizze: gut vs. schlecht



gut: nahe an $y = \hat{y}$



schlecht: weit weg

4 R^2 und Adjusted R^2

$$R^2 = 1 - \frac{\text{SSE}}{\text{SST}} = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

$R^2 = 1$: perfekt; $R^2 = 0$: nicht besser als der Mittelwert;
 $R^2 < 0$: schlechter als der Mittelwert.

$$R^2_{\text{adj}} = 1 - (1 - R^2) \frac{n-1}{n-p-1}$$

Adjusted bestraft zusätzliche Prädiktoren $\Rightarrow$ fairer Vergleich bei verschiedener Featureanzahl.

5 Welche Metrik wann?

Metrik	Einsatz
MAE	robust gegenüber Ausreißern, leicht interpretierbar
MSE / RMSE	große Fehler sind besonders schlimm
R^2	Anteil erklärter Varianz, skalenfrei
Adj. R^2	Modelle mit verschiedener Featurezahl vergleichen

Beispiel: 5 Hauspreise (in 100 k€)

$y = (5.0, 6.0, 7.5, 8.0, 9.5)$, $\hat{y} = (4.6, 5.5, 8.0, 7.2, 10.0)$, Fehler $(0.4, 0.5, -0.5, 0.8, -0.5)$.

Lösung MAE = $\frac{0.4+0.5+0.5+0.8+0.5}{5} = 0.54$; MSE = $\frac{1.55}{5} = 0.31$;

RMSE = 0.557.

$\bar{y} = 7.2$, SST = $4.84 + 1.44 + 0.09 + 0.64 + 5.29 = 12.30$, SSE = 1.55:

$R^2 = 1 - \frac{1.55}{12.30} = 0.874$ (maschinell nachgerechnet).

6 Warum genau diese Fehler? (MLE)

Gauß-Rauschen $\Rightarrow$ MLE = MSE minimieren (Least Squares).
Laplace-Rauschen $\Rightarrow$ MAE (robust). Huber-Verlust: quadratisch für kleine, linear für große Fehler – Kompromiss. Metrik und Trainingsverlust sollten zum Anwendungsziel passen (Kapitel Fehleranalyse: Zielfunktion vs. Metrik).

7 Fallstricke

- × nur eine Metrik betrachten
- × R^2 auf Trainingsdaten (steigt immer)
- × verschiedene Skalen vergleichen (MSE)

8 Weitere Metriken (Web)

- MAPE (prozentual, Problem bei $y \approx 0$)
- Median AE (sehr robust)
- Quantil-/Pinball-Verlust

9 Key Takeaways

- ✓ MAE, MSE, RMSE, R^2
- ✓ $R^2 = 1 - \text{SSE}/\text{SST}$
- ✓ Metrik zum Ziel passend wählen

? Selbsttest: kannst du das erklären?

F1 Was bedeutet $R^2 = 0$?

A: Das Modell ist nicht besser als die Vorhersage des Mittelwerts $\bar{y}$.

F2 Wann MAE statt MSE?

A: Bei Ausreißern; MSE quadriert große Fehler.

F3 Warum Adjusted R^2 ?

A: R^2 steigt mit jedem Feature; Adjusted bestraft überflüssige Prädiktoren.

„Keine einzelne Zahl erzählt die ganze Geschichte – lies mehrere Metriken zusammen.“

Klassifikations- & Regressionsmetriken: Vertiefung

Herleitung und Code

AUROC als Wahrscheinlichkeit, F_1 als harmonisches Mittel und R^2 als Varianzzerlegung. ❤️

Merke: Kennzahlen sind Rechnungen -- man kann sie herleiten

Quelle: section/evaluation_metrics_spring2020.pdf, hand-notes/ML Notes.pdf; Herleitungen ausformuliert; Code: code/sk_metrics.py (real ausgeführt)

1 AUROC = $P(S^+ > S^-)$

Schwelle t : $TPR(t) = P(S^+ > t)$, $FPR(t) = P(S^- > t)$ mit Scores positiver/negativer Beispiele.

Legende: S^+ , S^- Score eines zufälligen positiven bzw. negativen Beispiels, t Entscheidungsschwelle, TPR/FPR Trefferrate/Fehlalarmrate, f_{S^-} Dichte der Negativ-Scores, AUC Fläche unter der ROC-Kurve.

$$AUC = \int TPR \, dFPR = \int P(S^+ > t) f_{S^-}(t) \, dt \\ = \mathbb{E}_{S^-} [P(S^+ > S^-)] = P(S^+ > S^-) \quad dFPR = -f_{S^-} \, dt$$

Empirisch: Anteil der (pos., neg.)-Paare mit $s^+ > s^-$ (Gleichstand zählt $\frac{1}{2}$) – die Mann-Whitney- U -Statistik. Nur das Ranking zählt, deshalb unabhängig von der Prävalenz.

In Worten: AUROC ist die Wahrscheinlichkeit, dass ein zufälliges positives Beispiel einen höheren Score bekommt als ein zufälliges negatives.

3 $R^2 \in [0, 1]$ (OLS mit Achsenabschnitt)

Legende: y_i Beobachtung, $\bar{y}$ deren Mittel, $\hat{y}_i$ Vorhersage, $e_i = y_i - \hat{y}_i$ Residuum; SST Gesamtstreuung, SSR erklärte Streuung, SSE unerklärte (Rest-)Streuung.

$$SST = \sum (y_i - \bar{y})^2 = \sum [(\hat{y}_i - \bar{y}) + (y_i - \hat{y}_i)]^2 \\ = SSR + SSE + 2 \sum (\hat{y}_i - \bar{y})(y_i - \hat{y}_i) \\ = SSR + SSE \quad \text{Kreuzterm} = 0$$

Das Kreuzterm-Null folgt aus den Normalgleichungen ($X^T e = 0$; 1 ist Spalte $\Rightarrow \sum e_i = 0$). Also $R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$.

In Worten: R^2 ist der Anteil der Streuung von y , den das Modell erklärt.

Beispiel: AUROC durch Paare zählen

10 positive, 10 negative Beispiele $\Rightarrow$ 100 Paare (jedes positive mit jedem negativen).

Lösung Mit den Scores aus dem Code ergibt das Auszählen **93.5** von 100 Paaren (Gleichstände halb) $\Rightarrow$ AUROC = 0.935 (identisch zu `roc_auc_score`).

$$F_1: TP = 9, FP = 2, FN = 1: \frac{2 \cdot 9}{18 + 2 + 1} = \mathbf{0.857}.$$

1/1 Klassifikations- und Regressionsmetriken in scikit-learn

```
import numpy as np
from sklearn.metrics import (confusion_matrix, precision_score, recall_score, f1_score,
                             roc_auc_score, average_precision_score, mean_absolute_error,
                             mean_squared_error, r2_score)

y = np.array([1]*10 + [0]*10)
s = np.array([.9, .8, .85, .7, .95, .6, .75, .9, .4, .55, .3, .2, .6, .1, .45, .35, .65, .25, .15, .05])
p = (s >= 0.5).astype(int)
print(confusion_matrix(y, p).tolist(), "[[TN, FP], [FN, TP]]")
print("P", precision_score(y, p), "R", recall_score(y, p), "F1", round(f1_score(y, p), 3))
print("AUROC", round(roc_auc_score(y, s), 3), "AUPRC", round(average_precision_score(y, s), 3))
yt = np.array([5.0, 6.0, 7.5, 8.0, 9.5]); yp = np.array([4.6, 5.5, 8.0, 7.2, 10.0])
print("MAE", mean_absolute_error(yt, yp), "MSE", round(mean_squared_error(yt, yp), 3),
      "RMSE", round(mean_squared_error(yt, yp) ** .5, 3), "R2", round(r2_score(yt, yp), 3))
```

Ausgabe (real ausgeführt)

```
[[8, 2], [1, 9]] [[TN, FP], [FN, TP]]
P 0.8181818181818182 R 0.9 F1 0.857
AUROC 0.935 AUPRC 0.939
MAE 0.54 MSE 0.31 RMSE 0.557 R2 0.874
```

4 Lesart der Ausgabe

`confusion_matrix` liefert Zeilen = Wahrheit ($[[TN, FP], [FN, TP]]$), anders als die Tabellen in diesem Skript (Zeilen = Vorhersage). Precision 0.82, Recall 0.90, $F_1 = 0.857$ entsprechen dem Beispiel oben; AUROC 0.935 und AUPRC 0.939 ändern sich nicht mit der Schwelle. Regression: MAE 0.54, RMSE 0.557, $R^2 = 0.874$ (Kapitel Regressionsmetriken).

? Selbsttest: kannst du das herleiten?

F1 Was ist AUROC als Wahrscheinlichkeit?
A: $P(S^+ > S^-)$ für zufällig gezogene positive/negative Beispiele (Mann-Whitney).

F2 Warum kommt TN in F_1 nicht vor?
A: $F_1 = \frac{2TP}{2TP + FP + FN}$ – TN kürzt sich.

F3 Warum ist $R^2 \geq 0$ bei OLS mit Achsenabschnitt?
A: $SST = SSR + SSE$ mit verschwindendem Kreuzterm.

„Wer eine Kennzahl herleiten kann, versteht, was sie nicht misst.“

Feature Importance & SHAP

Nicht nur wie gut, sondern warum: welche Features treiben die Vorhersage? ❤️

Merke:
Shapley: faire Aufteilung der Vorhersage auf die Features

Globale und lokale Erklärungen von Modellen

Quelle: notes/cs229-notes-ensemble.pdf (Variable Importance), materials/critiques-ml-aut19.pdf (Interpretierbarkeit); Permutation Importance und SHAP (Lundberg & Lee 2017) als Web-Zusatz markiert

1 Warum erklären?

Vertrauen, Fehlersuche, Regulierung.


Global: welche Features zählen insgesamt?

Lokal: warum bekam dieses Beispiel diese Vorhersage? Erklärt wird das Modell, nicht die Welt.

2 Impurity Importance (Bäume)

Mittlere Impurity-Abnahme über alle Splits eines Features (Notes: "variable importance"). Gratis beim Training, aber auf Trainingsdaten berechnet und verzerrt bei vielen Ausprägungen und korrelierten Features.

3 Skizze: lokale Erklärung (schematisch)



4 Permutation Importance

Wichtig ist, was fehlt, wenn man es zerstört: Feature mischen und Leistungsverlust messen.

```

</> Permutation Importance
s0 ← Score des Modells auf Testdaten # R: Wiederholungen
for Feature j: repeat R mal:
    Xπ ← X mit Spalte j zufällig permutiert
    sj(r) ← Score auf Xπ
PIj ← s0 - meanr sj(r)
    
```

Modell-agnostisch; Problem: gemischte Werte sind evtl. unrealistisch.

6 SHAP

Shapley-Werte für ML: $v(S) = \mathbb{E}[f(x) | x_S]$ (unbekannte Features "ausintegrieren"). Additive Erklärung:

$$f(x) = \varphi_0 + \sum_{j=1}^d \varphi_j, \quad \varphi_0 = \mathbb{E}[f(X)]$$

TreeSHAP (exakt, schnell), KernelSHAP (modellagnostisch, gewichtete Regression), DeepSHAP. Global: $\frac{1}{n} \sum_i |\varphi_j^{(i)}|$.

7 Fallstricke

- × SHAP ≠ Kausalität: erklärt das Modell, nicht die Welt
- × korrelierte Features: Wichtigkeit verteilt sich, unrealistische Punkte
- × Aufwand $O(2^d) \Rightarrow$ Näherungen; Hintergrunddaten bestimmen φ_0

5 Shapley-Werte (Spieltheorie)

Features sind "Spieler", $v(S)$ der Wert einer Koalition, die Vorhersage der Gewinn:

$$\varphi_j = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|!(n-|S|-1)!}{n!} [v(S \cup \{j\}) - v(S)]$$

= mittlerer Grenzbeitrag von j über alle Reihenfolgen. **Axiome:** Effizienz $\sum_j \varphi_j = v(N) - v(\emptyset)$, Symmetrie, Dummy (unwichtig $\Rightarrow 0$), Additivität. Eindeutig.

Beispiel: Shapley-Werte von Hand

$f(x_1, x_2) = 3x_1 + 2x_2 + 4x_1x_2$, Instanz $x = (1, 1)$, Baseline $(0, 0)$: $v(\emptyset) = 0$, $v(\{1\}) = 3$, $v(\{2\}) = 2$, $v(\{1, 2\}) = 9$.

Lösung $\varphi_1 = \frac{1}{2}(3-0) + \frac{1}{2}(9-2) = 5$; $\varphi_2 = \frac{1}{2}(2-0) + \frac{1}{2}(9-3) = 4$.

Summe = 9 = $f(x) - f(0)$ (Effizienz). Die Interaktion $4x_1x_2$ wird fair je zur Hälfte aufgeteilt (2 + 2).

10 Key Takeaways

- ✓ Impurity schnell, aber verzerrt $\rightarrow$ Permutation (Testdaten) robuster $\rightarrow$ SHAP: global und lokal, additiv
- ✓ Shapley = mittlerer Grenzbeitrag; $\sum \varphi_j = f(x) - \text{Baseline}$; Herleitung und Code: nächste Seite

8 Vergleich der Verfahren

Verfahren	Ebene	Misst	Daten	Schwäche
Koeffizienten w_j (linear)	global	Effekt pro Einheit	Training	nur lineare Modelle, skalenabhängig
Impurity Importance	global	Split-Gewinn	Training	Bias, verzerrt bei Korrelation
Permutation Importance	global	Leistungsverlust	Test	unrealistische Mischungen
SHAP (mean $ \varphi $)	global und lokal	Beitrag zur Vorhersage	Hintergrund + Instanz	teuer, nicht kausal

9 Einordnung: Leistungsmetriken, Feature Importance/SHAP, Fairness

Leistungsmetriken: wie gut? Feature Importance/SHAP: warum (braucht keine Labels). Fairness: für wen (Metrik je Gruppe, braucht ein sensibles Merkmal). Tabelle: Kapitel Fairness-Analyse.

? Selbsttest: kannst du das erklären?

F1 Was unterscheidet Permutation Importance von Impurity Importance?

A: Permutation misst den Leistungsverlust auf Testdaten, Impurity den Split-Gewinn auf Trainingsdaten (verzerrt bei vielen Ausprägungen).

F2 Was garantiert die Effizienz-Eigenschaft?

A: $\sum_j \varphi_j = f(x) - \mathbb{E}[f(X)]$: die Beiträge erklären die Vorhersage vollständig.

F3 Wodurch unterscheiden sich SHAP und Fairness-Metriken?

A: SHAP erklärt warum (Features), Fairness misst für wen (Gruppen).

„Erst wissen, wie gut das Modell ist -- dann verstehen, warum.“

SHAP: Vertiefung

Warum genau diese Formel? Herleitung der Shapley-Werte, Linear-SHAP und getesteter Code. ❤️

Herleitung, Rechenbeispiel und exakter Code

Merke:
Telescoping: die Grenzbeiträge einer Reihenfolge addieren sich zu $v(N) - v(\emptyset)$

Quelle: Shapley (1953), Lundberg & Lee (2017) als Web-Zusatz; Herleitung ausformuliert; Code: code/np_shapley.py (real ausgeführt)

1 Von Reihenfolgen zur Formel

Legende: N Menge aller n Features, j das betrachtete Feature, $S \subseteq N$ Koalition (Teilmenge von Features), $v(S)$ Wert der Koalition (Vorhersage, wenn nur S bekannt ist), φ_j Shapley-Wert, π Reihenfolge, P_j^π Features vor j in π .

Ordne die Features in einer Reihenfolge π und "füge sie nacheinander hinzu": Beitrag von j ist $v(P_j^\pi \cup \{j\}) - v(P_j^\pi)$ (P_j^π : Vorgänger). Mittel über alle $n!$ Reihenfolgen:

$$\begin{aligned}\varphi_j &= \frac{1}{n!} \sum_{\pi} [v(P_j^\pi \cup \{j\}) - v(P_j^\pi)] && \text{Definition} \\ &= \sum_{S \subseteq N \setminus j} \frac{|S|!(n-|S|-1)!}{n!} [v(S \cup j) - v(S)] && \text{Reihenfolgen gruppieren}\end{aligned}$$

3 Linear-SHAP

$f(x) = w^T x + b$, unabhängige Features, (w Koeffizienten, b Achsenabschnitt, $\mathbb{E}x_j$ Mittel von Feature j)
 $v(S) = \mathbb{E}[f \mid x_S] = \sum_{j \in S} w_j x_j + \sum_{j \notin S} w_j \mathbb{E}x_j + b$. Grenzbeitrag von j ist unabhängig von S :

$$v(S \cup j) - v(S) = w_j(x_j - \mathbb{E}x_j) \Rightarrow \varphi_j = w_j(x_j - \mathbb{E}x_j)$$

Für lineare Modelle ist SHAP also Koeffizient $\times$ Abweichung vom Mittel.

In Worten: Ein Feature trägt so viel bei, wie sein Wert vom Durchschnitt abweicht, verstärkt durch den Koeffizienten.

2 Effizienz (Teleskopsumme)

Für eine Reihenfolge $\pi = (j_1, \dots, j_n)$ ist die Summe aller Beiträge

$$\sum_{k=1}^n [v(\{j_1..j_k\}) - v(\{j_1..j_{k-1}\})] = v(N) - v(\emptyset)$$

(Zwischenterme kürzen sich).

In Worten: Fügt man die Features nacheinander hinzu, ergeben die Beiträge zusammen genau den Weg von der Baseline $v(\emptyset)$ zur Vorhersage $v(N)$.

Mittelung über π ändert das nicht:

$$\sum_j \varphi_j = v(N) - v(\emptyset) = f(x) - \mathbb{E}[f(X)].$$

4 KernelSHAP & Aufwand

Legende: $z' \in \{0, 1\}^n$ Koalitionsvektor (1: Feature bekannt), $|z'|$ Anzahl bekannter Features, $\binom{n}{|z'|}$ Binomialkoeffizient, $\pi(z')$ Gewicht.

Exakt: 2^n Koalitionen. KernelSHAP: gewichtete lineare Regression über Koalitionen $z' \in \{0, 1\}^n$ mit dem Shapley-Kern

$$\pi(z') = \frac{n-1}{\binom{n}{|z'|} |z'| (n-|z'|)}$$

Die Regressionskoeffizienten sind dann die φ_j . TreeSHAP: nutzt die Baumstruktur (polynomial). Fehlende Features: interventional (Hintergrunddaten, Standard) oder konditional (mit Korrelation, schwer zu schätzen); der Hintergrund bestimmt φ_0 .

Beispiel: Linear-SHAP

$f(x) = 2x_1 - x_2 + 3$ (Modell), $\mathbb{E}X = (1, 2)$ (Mittelwerte der Features), $x = (3, 1)$ (zu erklärende Instanz), φ_j Beitrag von Feature j .

Lösung Baseline $\varphi_0 = f(\mathbb{E}X) = 2 - 2 + 3 = 3$.

$$\varphi_1 = 2(3 - 1) = 4, \varphi_2 = -1(1 - 2) = +1.$$

$3 + 4 + 1 = 8 = f(x)$ (Additivität). Beide Beiträge positiv: $x_2 = 1$ liegt unter dem Mittel, das Minuszeichen kehrt den Effekt um.

Shapley-Werte exakt durch Aufzählen aller Reihenfolgen

```
from itertools import permutations
import numpy as np
# Modell mit Interaktion: f(x) = 3*x1 + 2*x2 + 4*x1*x2
f = lambda x: 3*x[0] + 2*x[1] + 4*x[0]*x[1]
x, base = np.array([1., 1.]), np.array([0., 0.]) # Instanz, Baseline
def v(S):
    z = base.copy()
    for j in S: z[j] = x[j]
    return f(z)
phi, perms = np.zeros(2), list(permutations(range(2)))
for p in perms:
    S = []
    for j in p:
        phi[j] += (v(S + [j]) - v(S)) / len(perms)
        S.append(j)
print("phi =", phi)
print("Summe =", phi.sum(), "; f(x)-f(0) =", f(x) - f(base))
```

Ausgabe (real ausgeführt)

```
phi = [5. 4.]
Summe = 9.0 ; f(x)-f(0) = 9.0
```

? Selbsttest: kannst du das herleiten?

F1 Warum ist die Summe der Shapley-Werte gleich $v(N) - v(\emptyset)$?

A: Innerhalb jeder Reihenfolge ist die Summe der Grenzbeiträge eine Teleskopsumme; der Mittelwert über Reihenfolgen erhält das.

F2 Wie sieht SHAP für ein lineares Modell aus?

A: $\varphi_j = w_j(x_j - \mathbb{E}x_j)$.

F3 Warum ist exakte Berechnung teuer?

A: 2^n Koalitionen bzw. $n!$ Reihenfolgen; deshalb TreeSHAP/KernelSHAP.

Erklärungen in der Praxis:
drei Verfahren am selben Mo-
dell vergleichen und die Aus-
gabe richtig lesen. ❤️

Merke:
Impurity kann täuschen,
Permutation ist ehrlicher,
SHAP zerlegt pro Fall

Quelle: Code: code/sk_shap.py (real ausgeführt); Interpretation nach Lundberg & Lee (2017) und scikit-learn-Doku (Web-Zusatz)

(/) Random Forest: Impurity vs. Permutation vs. SHAP (globale und lokale Erklärung)

```
import numpy as np, shap
from sklearn.datasets import load_diabetes
from sklearn.ensemble import RandomForestRegressor
from sklearn.inspection import permutation_importance
from sklearn.model_selection import train_test_split
X, y = load_diabetes(return_X_y=True, as_frame=True)
Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.3, random_state=0)
rf = RandomForestRegressor(200, min_samples_leaf=5, random_state=0)
rf.fit(Xtr, ytr)
imp = rf.feature_importances_ # Impurity (Train)
perm = permutation_importance(rf, Xte, yte, n_repeats=20,
                             random_state=0).importances_mean # Test
expl = shap.TreeExplainer(rf)
sv = expl.shap_values(Xte) # (n, d) Shapley-Werte
glob = np.abs(sv).mean(0) # globale Wichtigkeit
rows = sorted(zip(X.columns, imp, perm, glob), key=lambda t: -t[3])
for n, a, b, c in rows[:4]:
    print(f'{n:4s} imp {a:.2f} perm {b:.2f} SHAP {c:.1f}')
pred = rf.predict(Xte)[0] # lokal: 1 Patient
print("Additiv.: ", round(pred, 1), "=",
      round(expl.expected_value[0] + sv[0].sum(), 1))
```

Ausgabe (real ausgeführt)

```
s5 imp 0.35 perm 0.19 SHAP 27.9
bmi imp 0.34 perm 0.16 SHAP 26.6
bp imp 0.09 perm 0.03 SHAP 9.1
s3 imp 0.06 perm -0.02 SHAP 7.4
Additiv.: 252.3 = 252.3
```

1 Lesart der Ausgabe

Alle drei nennen s5 und bmi vorn, aber Impurity gibt bp (0.09) und s3 (0.06) noch Gewicht, während Permutation nur 0.03 bzw. sogar negativ (-0.02) liefert: Shufflen von s3 verbessert das Testergebnis leicht, das Feature trägt auf Testdaten nichts bei. SHAP ist in Einheiten der Zielgröße und pro Patient zerlegbar; Baseline + $\sum \varphi_j$ ergibt exakt die Vorhersage (252.3).

2 Welchen Explainer nehmen?

- **Bäume** (RF, XGBoost, LightGBM): TreeExplainer, exakt und schnell.
- **Lineare Modelle**: LinearExplainer oder direkt $w_j(x_j - \mathbb{E}x_j)$.
- **Beliebige Modelle**: KernelExplainer; Hintergrund klein halten (k-Means-Zentren, 50 bis 100 Punkte), sonst wird es sehr langsam.
- **Tiefe Netze**: DeepExplainer bzw. GradientExplainer.

3 Typische Plots

- **Summary/Beeswarm**: global, Farbe = Merkmalswert, $x = \varphi_j$.
- **Bar (mean $|\varphi_j|$)**: Rangfolge wie Permutation, aber in Einheiten der Zielgröße.
- **Waterfall/Force**: lokal, Baseline $\rightarrow$ Vorhersage.
- **Dependence**: φ_j gegen x_j , zeigt Nichtlinearität und Interaktionen.

Fairness-Analyse

Ein Modell kann im Mittel gut sein und trotzdem bestimmte Gruppen systematisch benachteiligen. ❤️

Gruppenmetriken: Demographic Parity, Equalized Odds & Co.

Merke:
Gleiche Accuracy ≠ gleiche Behandlung

Quelle: materials/critiques-ml-aut19.pdf (Ethische Fragen); Definitionen nach Hardt et al. 2016, Chouldechova 2017, Kleinberg et al. 2016 sowie fairlearn als Web-Zusatz markiert; Rechenbeispiel selbst erstellt und maschinell geprüft

1 Woher kommt Unfairness?

- **Historischer Bias** in Daten (frühere Entscheidungen)
- **Stichprobenbias**: Gruppen unterrepräsentiert
- **Label-Bias**: Ziel misst Ersatzgröße (Festnahme statt Straftat)
- **Proxies**: PLZ korreliert mit Herkunft

2 Setup

A sensibles Merkmal (Geschlecht, Herkunft, Alter), Y wahres Label, $\hat{Y}$ Vorhersage, S Score. Fairness heißt: eine Statistik von $\hat{Y}$ soll sich zwischen den Gruppen $A = a$ und $A = b$ nicht (zu stark) unterscheiden.

Merkmal einfach weglassen genügt nicht (Proxies).

3 Skizze: Konfusionsmatrix je Gruppe

	Gruppe A		Gruppe B	
	$Y=1$	$Y=0$	$Y=1$	$Y=0$
$\hat{Y}=1$	6	2	1	1
$\hat{Y}=0$	2	10	3	15

Accuracy beide 0.80!

4 Gruppenmetriken (Definitionen)

Demographic Parity: $P(\hat{Y}=1|A=a) = P(\hat{Y}=1|A=b)$

Equal Opportunity: $P(\hat{Y}=1|Y=1, a) = P(\hat{Y}=1|Y=1, b)$ (TPR)

Equalized Odds: TPR und FPR gleich

Predictive Parity: $P(Y=1|\hat{Y}=1, a) = \dots b$ (PPV)

Kalibrierung: $P(Y=1|S=s, a) = s \forall a$

Disparate Impact: $\frac{P(\hat{Y}=1|b)}{P(\hat{Y}=1|a)}$, **80%-Regel**: Verhältnis < 0.8 gilt als Warnsignal.

5 Was welche Metrik verlangt

- **Demographic Parity**: gleiche Auswahlrate, ignoriert das Label – passt, wenn Unterschiede in Y selbst Folge von Diskriminierung sind.
- **Equal Opportunity**: Qualifizierte haben gleiche Chance (TPR), z. B. Kreditvergabe.
- **Equalized Odds**: zusätzlich gleiche Fehlalarme (FPR).
- **Predictive Parity/Kalibrierung**: ein positives Ergebnis bedeutet in jeder Gruppe dasselbe.
- **Individuelle Fairness**: ähnliche Personen → ähnliche Ergebnisse.

Beispiel: Kreditmodell mit 40 Anträgen (je 20 pro Gruppe; Zahlen aus der Konfusionsmatrix oben)

Lösung Auswahlrate: $A = \frac{8}{20} = 0.40$, $B = \frac{2}{20} = 0.10 \Rightarrow$ Disparate Impact $= \frac{0.10}{0.40} = 0.25 < 0.8$ verletzt. TPR: $A = \frac{6}{8} = 0.75$, $B = \frac{1}{4} = 0.25$

(Differenz **0.50**). FPR: $A = \frac{2}{12} = 0.17$, $B = \frac{1}{16} = 0.06$. PPV: $A = 0.75$, $B = 0.50$. Accuracy: beide $\frac{16}{20} = 0.80$.

Das Modell erkennt kreditwürdige Antragsteller in Gruppe B nur zu 25% – die Gesamtgenauigkeit verrät das nicht (Kapitel Klassifikationsmetriken: Accuracy täuscht).

6 Unmöglichkeit (Kurzfassung)

Unterscheiden sich die Basisraten $p = P(Y=1)$ (hier 0.40 vs. 0.20), können Kalibrierung/PPV und gleiche FPR und FNR nicht gleichzeitig gelten – außer der Klassifikator ist perfekt. Fairness ist deshalb

eine Wertentscheidung: welches Kriterium passt zum Kontext (rechtlich, ethisch)? Herleitung: nächste Seite.

7 Gegenmaßnahmen

Pre-Processing: Daten reparieren (Reweighting, Resampling).

In-Processing: Nebenbedingung oder Strafterm im Training,

adversariales Debiasing. **Post-Processing**: gruppenspezifische Schwellwerte nach dem Training (Hardt et al.). Jede Maßnahme kostet oft etwas Gesamtleistung.

8 Einordnung: Fairness, Feature Importance und Leistungsmetriken

	Leistungsmetriken	Feature Importance / SHAP	Fairness-Metriken
Frage	Wie gut ist das Modell?	Warum sagt es das?	Für wen und wie gleich gut?
Vergleicht	Vorhersage mit Label	Vorhersage mit Eingaben	Metrik zwischen Gruppen
Braucht A?	nein	nein (Proxy-Suche mit SHAP)	ja
Zusammenspiel	Gesamtwert versteckt Gruppen	zeigt, ob A/Proxies das Modell treiben	Metrik je Gruppe statt Mittel

9 Praxis-Workflow

1. Kontext und Schaden klären, Kriterium wählen
2. Metriken pro Gruppe berechnen (nicht nur global)
3. mit SHAP prüfen, ob A/Proxies stark wirken
4. Gegenmaßnahme wählen, Leistungsverlust messen
5. dokumentieren (Model Card), nach dem Deployment überwachen

10 Key Takeaways

- ✓ Gruppenmetriken vergleichen Statistiken zwischen Gruppen
- ✓ Accuracy allein verbirgt Ungleichbehandlung
- ✓ Kriterien widersprechen sich bei ungleichen Basisraten
- ✓ Vertiefung mit Herleitung und Code: nächste Seite

? Selbsttest: kannst du das erklären?

F1 Was ist der Unterschied zwischen

Demographic Parity und Equal Opportunity?
A: DP gleicht die Auswahlrate an (ohne Label); Equal Opportunity die TPR unter den tatsächlich Positiven.

F2 Warum reicht es nicht, das sensible Merkmal zu entfernen?

A: Proxies (z. B. PLZ) tragen dieselbe Information.

F3 Was besagt die 80%-Regel?

A: Verhältnis der Auswahlraten < 0.8 deutet auf nachteilige Wirkung.

„Fairness ist keine Zahl, sondern eine begründete Entscheidung.“

Fairness: Vertiefung

Warum sich Fairness-Kriterien widersprechen -- Herleitung, Reweighing und Code. 

Merke:

$$\text{FPR} = \frac{p}{1-p} \cdot \frac{1-\text{PPV}}{\text{PPV}} \cdot \text{TPR}$$

Herleitung und Gegenmaßnahmen

Quelle: Chouldechova (2017), Kleinberg et al. (2016), Kamiran & Calders (2012), Hardt et al. (2016) als Web-Zusatz; Herleitungen ausformuliert; Code: code/np_fairness.py (fairlearn, real ausgeführt)

1 Zusammenhang PPV, TPR, FPR

Legende: Y wahres Label, p Basisrate (Anteil positiver Fälle), TPR Trefferrate, FPR Fehlalarmrate, PPV Precision, TP, FP Anteile in der Konfusionsmatrix.

Basisrate $p = P(Y=1)$. Aus der Konfusionsmatrix (Anteile):
 $TP = p \cdot \text{TPR}$, $FP = (1-p) \cdot \text{FPR}$.

$$\text{PPV} = \frac{TP}{TP + FP} = \frac{p \text{ TPR}}{p \text{ TPR} + (1-p) \text{ FPR}} \quad \text{Definition}$$

$$\Rightarrow \text{FPR} = \frac{p}{1-p} \cdot \frac{1-\text{PPV}}{\text{PPV}} \cdot \text{TPR} \quad \text{nach FPR umstellen}$$

In Worten: PPV, TPR, FPR und Basisrate hängen fest zusammen: Kennt man drei, ist die vierte bestimmt.

Beispiel: Formel mit den Daten der Vorseite prüfen

Gruppe A: Basisrate $p = 0.40$, $\text{PPV} = 0.75$, $\text{TPR} = 0.75$;
Auswahlrate = Anteil der als positiv Vorhergesagten.

Lösung $\text{FPR}_A = \frac{0.4}{0.6} \cdot \frac{0.25}{0.75} \cdot 0.75 = \frac{2}{3} \cdot \frac{1}{3} \cdot 0.75 = 0.167$ stimmt.

Gruppe B: $p = 0.20$, $\text{PPV} = 0.50$, $\text{TPR} = 0.25$:

$\frac{0.2}{0.8} \cdot 1 \cdot 0.25 = 0.0625$ stimmt.

Auswahlrate = $p \text{ TPR} + (1-p) \text{ FPR}$: $A = 0.3 + 0.1 = 0.4$, $B = 0.05 + 0.05 = 0.1$.

2 Unmöglichkeit

Seien PPV und TPR (also auch FNR) in beiden Gruppen gleich. Dann bestimmt die Formel FPR eindeutig aus p :

$$p_a \neq p_b \Rightarrow \text{FPR}_a \neq \text{FPR}_b$$

Ausnahmen: perfekter Klassifikator ($\text{PPV} = 1 \Rightarrow \text{FPR} = 0$) oder $\text{TPR} = 0$. Also kollidieren **Predictive Parity** und

Equalized Odds, sobald die Basisraten verschieden sind.

3 Reweighing (Pre-Processing)

Legende: A sensibles Merkmal (Gruppe), Y Label, $w(a, y)$ Gewicht für Gruppe a und Label y .

Gewicht je (Gruppe a , Label y), sodass A und Y im gewichteten Datensatz unabhängig werden:

$$w(a, y) = \frac{P(A=a) P(Y=y)}{P(A=a, Y=y)}$$

In Worten: Zähler: so viele Fälle würde man bei Unabhängigkeit erwarten; Nenner: so viele gibt es tatsächlich. Unterrepräsentierte Kombinationen bekommen mehr Gewicht.

Danach mit Gewichten trainieren (sample_weight). Es ändert die Daten, nicht das Modell.

4 Post-Processing: Schwellwerte

Ein Score S (Modellausgabe); pro Gruppe ein eigener Schwellwert t_a wählen, sodass z. B. die TPR gleich wird (Equal Opportunity). Man liest t_a aus der ROC-Kurve der Gruppe ab. Einfach, modellunabhängig, braucht aber A zur Anwendungszeit und kann anderen Kriterien schaden.

`</> Gruppen-Schwellwerte`

for Gruppe a : $t_a \leftarrow$ kleinstes t mit $\text{TPR}_a(t) \geq \tau$ # τ : Ziel-Trefferrate
 $\hat{y} \leftarrow \mathbf{1}[S \geq t_A]$

Fairness: Praxis

Reweighing-Beispiel und fairlearn

Reweighing mit echten Zahlen und die Fairness-Metriken je Gruppe in Code.



Merke:
Offenlegen, was man misst -- die Wahl der Metrik ist eine Entscheidung

Quelle: Chouldechova (2017), Kleinberg et al. (2016), Kamiran & Calders (2012), Hardt et al. (2016) als Web-Zusatz; Herleitungen ausformuliert; Code: code/np_fairness.py (fairlearn, real ausgeführt)

Beispiel: Reweighing mit den 40 Anträgen (A: 8 pos. / 12 neg.; B: 4 pos. / 16 neg.)

Lösung $P(A) = P(B) = 0.5$, $P(Y=1) = \frac{12}{40} = 0.3$.

$w(A, 1) = \frac{0.5 \cdot 0.3}{0.2} = \mathbf{0.75}$, $w(A, 0) = \frac{0.5 \cdot 0.7}{0.3} = 1.17$, $w(B, 1) = \frac{0.5 \cdot 0.3}{0.1} = \mathbf{1.5}$, $w(B, 0) = \frac{0.5 \cdot 0.7}{0.4} = 0.875$.

Gewichtete positive Rate: $A = \frac{0.75 \cdot 8}{0.75 \cdot 8 + 1.17 \cdot 12} = \frac{6}{20} = 0.30$, $B = \frac{1.5 \cdot 4}{1.5 \cdot 4 + 0.875 \cdot 16} = \frac{6}{20} = 0.30$ **gleich** : positive Beispiele der benachteiligten Gruppe zählen mehr.

(/) Fairness-Analyse mit fairlearn: Metriken je Gruppe (MetricFrame) und Differenzen

```
import numpy as np
from fairlearn.metrics import (MetricFrame, selection_rate, true_positive_rate,
                              demographic_parity_difference, equalized_odds_difference)
from sklearn.metrics import accuracy_score, precision_score

# Gruppe A (20 Anträge) und Gruppe B (20 Anträge)
y_true = np.array([1]*8 + [0]*12 + [1]*4 + [0]*16)
y_pred = np.array([1]*6 + [0]*2 + [1]*2 + [0]*10
                  + [1]*1 + [0]*3 + [1]*1 + [0]*15)
g = np.array(["A"]*20 + ["B"]*20)
mf = MetricFrame(metrics={"select": selection_rate, "TPR": true_positive_rate,
                          "PPV": precision_score, "acc": accuracy_score},
                 y_true=y_true, y_pred=y_pred, sensitive_features=g)
mf.by_group.index.name = "Gruppe"
print(mf.by_group.round(2))
dp = demographic_parity_difference(y_true, y_pred, sensitive_features=g)
eo = equalized_odds_difference(y_true, y_pred, sensitive_features=g)
print("DP-Diff :", round(dp, 2))
print("EO-Diff :", round(eo, 2))
print("Disp.Imp.:", mf.by_group.select["B"] / mf.by_group.select["A"])
```

Ausgabe (real ausgeführt)

	select	TPR	PPV	acc
Gruppe				
A	0.4	0.75	0.75	0.8
B	0.1	0.25	0.50	0.8
DP-Diff	: 0.3			
EO-Diff	: 0.5			
Disp.Imp.:	0.25			

5 Lesart der Ausgabe

Beide Gruppen haben dieselbe Accuracy (0.8), aber die TPR fällt von 0.75 (A) auf 0.25 (B): demographic_parity_difference = 0.3, equalized_odds_difference = 0.5 (die größere der TPR- und FPR-Differenz), Disparate Impact 0.25. Die Kennzahlen stammen aus einem Modell – welche davon zu optimieren ist, entscheidet der Anwendungskontext, nicht der Code.

? Selbsttest: kannst du das herleiten?

F1 Woher stammt $FPR = \frac{p}{1-p} \frac{1-PPV}{PPV} TPR$?

A: Aus $PPV = \frac{p \cdot TPR}{p \cdot TPR + (1-p) \cdot FPR}$ nach FPR umgestellt.

F2 Warum kollidieren Predictive Parity und Equalized Odds?

A: Bei gleichem PPV und TPR legt die Formel FPR über p fest; verschiedene p erzwingen verschiedene FPR.

F3 Was macht Reweighing?

A: Gewichtet (Gruppe, Label) so, dass A und Y unabhängig werden.

„Man kann nicht alles gleichzeitig gerecht machen -- aber man kann offenlegen, was man wählt.“

Feature Engineering & Preprocessing

Rohdaten sind erst der Anfang: saubere Daten und gute Features schlagen oft das bessere Modell. ❤️

Merke:
Garbage in, garbage out!

Fehlende Werte, Skalierung, Kategorien, Ausreißer,
Feature-Auswahl

Quelle: hand-notes/ML Notes.pdf (Feature Engineering & Preprocessing); Beispiele selbst ergänzt


1 Warum?

Modelle lernen nur, was in den Features steckt. **Preprocessing** macht Daten sauber und nutzbar; **Feature Engineering** erzeugt zusätzliche Signale (Kombinationen, Transformationen, Zeitmerkmale). Iterativer Prozess.

2 Fehlende Werte

MCAR (zufällig), MAR (hängt von anderen Features ab), MNAR (hängt vom fehlenden Wert selbst ab).
Imputation: Mittel/Median (numerisch), Modus oder Kategorie "fehlt" (kategorial), KNN- oder Modell-Imputation; Zeilen/Spalten löschen, wenn zu viel fehlt.

3 Skizze: Ausreißer & Log



4 Skalierung

$$\text{Standardisierung: } z = \frac{x - \mu}{\sigma} \quad \text{Min-Max: } x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

(μ, σ : Mittel und Streuung der Trainingsdaten; $x_{\min}, x_{\max}$ kleinster/größter Wert.) Standardisierung: Mittel 0, Std 1, empfindlich bei Ausreißern. Min-Max: Bereich $[0, 1]$, sehr empfindlich bei Ausreißern; robust: Median/IQR.

Nötig für distanz- und gradientenbasierte Verfahren (k-NN, SVM, K-Means, PCA, neuronale Netze, GD); nicht für Bäume.

5 Kategoriale Variablen

Verfahren	Idee / Vorsicht
Label-Encoding	Zahl pro Kategorie; erzeugt Scheinordnung
One-Hot	eine 0/1-Spalte je Kategorie (Dummy-Falle: eine weglassen bei linearen Modellen)
Ordinal	sinnvolle Rangfolge (niedrig < mittel < hoch)
Target-Encoding	Mittelwert des Ziels je Kategorie (Leakage-Gefahr!)

Beispiel: Skalieren von $x = (10, 20, 30, 100)$

Lösung $\mu = 40, \sigma = \sqrt{\frac{900+400+100+3600}{4}} = 35.4$

Standardisierung: $z = (-0.85, -0.57, -0.28, \mathbf{1.70})$.

Min-Max: $x' = \frac{x-10}{90} = (0, 0.11, 0.22, 1)$.

Der Ausreißer 100 quetscht die anderen Werte zusammen $\Rightarrow$ vorher cappen oder log-transformieren.

One-Hot: Stadt $\in \{\text{Delhi, Mumbai}\} \rightarrow (1, 0)$ bzw. $(0, 1)$.

6 Ausreißer & Transformationen

Erkennen: Boxplot/IQR-Regel (Q_1, Q_3 unteres/oberes Quartil, $IQR = Q_3 - Q_1$) ($x < Q_1 - 1.5 IQR$ oder $> Q_3 + 1.5 IQR$), z -Score > 3 . Behandeln: cappen (Winsorizing an Perzentilen), transformieren (log, Wurzel, Box-Cox), entfernen nur bei echten Fehlern (nicht bei seltenen, aber echten Werten). Weitere Transformationen: Binning, Interaktionen $A \times B$, Polynom-Features.

7 Feature-Auswahl

- **Filter:** Korrelation, χ^2 , Mutual Information – unabhängig vom Modell.
- **Wrapper:** Forward/Backward-Selektion, RFE – teuer, modellbezogen.
- **Embedded:** L1/Lasso, Elastic Net, Baum-Importance – Auswahl im Training.

8 Data Leakage vermeiden

Skalierer, Imputer und Encoder **nur auf dem Trainingsset anpassen** (fit) und dann auf Val/Test anwenden (transform). Am sichersten: alles in eine Pipeline (siehe Vertiefungsseite zu Workflow). Keine Zukunftsinformation in Zeitreihen-Features.

9 Zeit-Features

Aus Datum: Jahr, Monat, Wochentag, Quartal, Wochenende/Feiertag; Lag-Features, Rolling-Statistiken (Mittel, Std), Zeit seit letztem Ereignis – immer nur aus der Vergangenheit berechnen.

10 Key Takeaways

- ✓ Fehlende Werte, Ausreißer, Skalen zuerst klären
- ✓ Kategorien passend kodieren
- ✓ fit nur auf Train, transform überall

? Selbsttest: kannst du das erklären?

F1 Für welche Modelle ist Skalierung nötig?

A: Distanz-/gradientenbasierte (k-NN, SVM, K-Means, PCA, NN); nicht für Bäume.

F2 Warum One-Hot statt Label-Encoding?

A: Label-Encoding täuscht eine Ordnung vor, die es nicht gibt.

F3 Was ist Data Leakage beim Skalieren?

A: Mittel/Std aus dem gesamten Datensatz: Testinformation fließt ins Training.

„Gute Features sind halbe Modellierung.“

Ein guter Workflow macht aus einer Idee ein zuverlässiges, wiederholbares System.




ML-Workflow & Best Practices

Von der Problemdefinition bis zum Monitoring

Merke:
Iterieren, validieren,
dokumentieren -- nicht hetzen

Quelle: hand-notes/ML Notes.pdf (ML Fundamentals; End-to-End ML Workflow & Best Practices); MLOps-Teil größtenteils Web-Wissen (markiert)

1 Der End-to-End-Workflow (mit Rückkopplung)



2 Lernparadigmen & Aufgaben

- **Überwacht:** Klassifikation (Spam ja/nein), Regression (Hauspreis)
- **Unüberwacht:** Clustering, Dimensionsreduktion, Anomalieerkennung
- **Bestärkend:** Agent lernt aus Belohnung

Begriffe: Feature, Target, Modell, Training, Inferenz, Muster.
Datentypen: numerisch, kategorial (nominal/ordinal), Text, Bild, Zeitreihe.

4 Data Leakage

Falsch: Preprocessing auf allen Daten, dann splitten. **Richtig:** erst splitten, Transformer nur auf Train fiten.

Weitere Leaks: Ziel-Info in Features (Target Leakage), Zukunftsdaten bei Zeitreihen, Duplikate über Train/Test, Gruppen (Patienten) über Splits verteilt.

Symptom: zu gute Testergebnisse, die im Einsatz einbrechen.

6 Deployment & Monitoring (MLOps, Web)

- Modell versionieren, speichern; Inferenz-Pipeline testen; Eingaben validieren
- Latenz und Verfügbarkeit überwachen
- **Data/Concept Drift:** Verteilung ändert sich → Leistung fällt; Alarmer, regelmäßig neu trainieren
- Werkzeuge (Beispiele): Git/DVC, MLflow, CI/CD

Beispiel: Churn-Vorhersage (Kundenabwanderung) -- konkreter Ablauf

Lösung Problem: wird ein Kunde kündigen? (binäre Klassifikation, F1/AUPRC, da selten). **Daten:** CRM, Nutzung, Support-Tickets.

Vorverarbeitung: Median-Imputation, One-Hot (Region), Standardisierung; Split vor dem Fit, alles in einer Pipeline. **Modell:** Baseline LogReg, dann Random Forest/Gradient Boosting, Tuning per Random Search + Stratified CV. **Bewertung:** Test einmal (AUPRC, Confusion Matrix, Fehleranalyse). **Betrieb:** API, Drift-Monitoring, monatliches Retraining.

8 Key Takeaways

- ✓ Erst Problem und Metrik klären, dann Daten, dann Modell – Baseline zuerst
- ✓ Split vor Preprocessing, Testset einmal benutzen, alles in Pipelines
- ✓ Deployment ist nicht das Ende: überwachen und nachtrainieren

? Selbsttest: kannst du das erklären?

F1 Wofür braucht man ein Validation- und ein Testset?

A: Validation zum Wählen/Tunen, Test zur einmaligen, unverzerrten Endbewertung.

F2 Nenne zwei Arten von Data Leakage.

A: Preprocessing vor dem Split; Target-/Zukunftsinformation in Features.

F3 Was ist Concept Drift?

A: Die Beziehung zwischen Features und Ziel ändert sich im Betrieb ⇒ Modell veraltet.

„Ein starker Workflow schlägt ein geniales Modell in einer chaotischen Pipeline.“

Data Leakage in Zahlen und Nested CV mit Pipeline -- der Code hinter Feature Engineering, Tuning und Workflow.



Feature Engineering, Tuning & Workflow: Vertiefung

Code und Lesart

Merke:
Vorverarbeitung gehört in die Pipeline!

Quelle: hand-notes/ML Notes.pdf (Feature Engineering, Cross-Validation, End-to-End-Workflow); Beispiele selbst erstellt; Code: code/sk_leakage.py, sk_pipeline.py (real ausgeführt)

Data Leakage: Feature-Auswahl außerhalb vs. innerhalb der Kreuzvalidierung

```
import numpy as np
from sklearn.feature_selection import SelectKBest, f_classif
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import cross_val_score
from sklearn.pipeline import make_pipeline
rng = np.random.default_rng(0)
X = rng.normal(size=(100, 1000)) # reines Rauschen
y = rng.integers(0, 2, 100) # zufällige Labels
clf = LogisticRegression(max_iter=1000)
Xsel = SelectKBest(f_classif, k=20).fit_transform(X, y) # LEAK: alle Daten
print("Leakage :", cross_val_score(clf, Xsel, y, cv=5).mean().round(2))
pipe = make_pipeline(SelectKBest(f_classif, k=20), clf) # Auswahl im Fold
print("Pipeline :", cross_val_score(pipe, X, y, cv=5).mean().round(2))
```

Ausgabe (real ausgeführt)

Leakage : 0.88
Pipeline : 0.57

Lesart der Ausgabe: Data Leakage im Zahlenbeispiel

Die Daten sind reines Rauschen (Labels zufällig): ehrlich erreichbar sind ≈ 0.5 . Wählt man die 20 "besten" von 1000 Features auf dem gesamten Datensatz, findet man Features, die zufällig mit y korrelieren – die Kreuzvalidierung meldet trügerische 0.88. Steht die Auswahl in der Pipeline, wird sie in jedem Fold nur auf den Trainingsdaten gelernt: $0.57 \approx$ Zufall. Je mehr Features und je weniger Beispiele, desto größer der Leakage-Effekt. Zweites Snippet: Nested CV über Pipeline und Hyperparameter (Kapitel Validierung & Tuning).

ColumnTransformer + Pipeline + Nested Cross-Validation

```
import numpy as np, pandas as pd
from sklearn.compose import ColumnTransformer
from sklearn.impute import SimpleImputer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import GridSearchCV, cross_val_score, StratifiedKFold
rng = np.random.default_rng(0); n = 300
df = pd.DataFrame({"alter": rng.integers(18, 70, n).astype(float),
                  "einkommen": rng.normal(50, 15, n),
                  "stadt": rng.choice(["Delhi", "Mumbai", "Pune"], n)})
df.loc[rng.choice(n, 30, replace=False), "einkommen"] = np.nan # fehlende Werte
y = (df["einkommen"].fillna(50) + rng.normal(0, 10, n) > 50).astype(int)
pre = ColumnTransformer([("num", Pipeline([("imp", SimpleImputer(strategy="median")),
                                           ("sc", StandardScaler())]), ["alter", "einkommen"]),
                       ("cat", OneHotEncoder(handle_unknown="ignore"), ["stadt"])]))
pipe = Pipeline([("pre", pre), ("rf", RandomForestClassifier(random_state=0))]) # kein Leakage
grid = {"rf__n_estimators": [50, 200], "rf__max_depth": [3, None]}
inner = GridSearchCV(pipe, grid, cv=StratifiedKFold(3, shuffle=True, random_state=0))
print("Nested-CV Accuracy:", cross_val_score(inner, df, y, cv=5).mean().round(3))
```

Ausgabe (real ausgeführt)

Nested-CV Accuracy: 0.79

Selbsttest: kannst du das herleiten?

F1 Warum sind 0.88 im Leakage-Beispiel trügerisch?

A: Die Feature-Auswahl sah alle Labels; bei Rauschen ist ehrlich nur ≈ 0.5 erreichbar.

F2 Was tut die Pipeline?

A: Sie lernt Imputer, Skalierer und Selektor in jedem Fold nur auf dem Trainingsteil.

F3 Wozu Nested CV?

A: Tuning und Bewertung trennen, damit der Score nicht optimistisch verzerrt ist.

„Was in der Pipeline steht, kann nicht ins Testset lecken.“

K-Means Clustering

Ohne Labels: finde Gruppen ähnlicher Punkte. ♥

unüberwachtes Lernen: Zentroide alternierend anpassen

Merke:
Jeder Schritt senkt J -- aber nur bis zu einem lokalen Minimum!

Quelle: main_notes.pdf (Clustering), notes/cs229-notes7a.pdf

1 Idee

Gegeben Daten $\{x^{(i)}\}$ ohne Labels: teile sie in K Cluster mit Mittelpunkten (Zentroiden) $\mu_1, \dots, \mu_K$, sodass Punkte nahe an ihrem Zentroid liegen.


2 Zielfunktion

Summe der quadratischen Abstände zum zugewiesenen Zentroid:

$$J(c, \mu) = \sum_{i=1}^n \|x^{(i)} - \mu_{c(i)}\|^2$$

$c^{(i)} \in \{1..K\}$: Clusterzuweisung von Punkt i , μ_k : Zentroid von Cluster k , n : Anzahl Punkte. J ist nicht konvex.

3 Skizze: 2 Cluster



4 Algorithmus

K-Means

initialisiere $\mu_1, \dots, \mu_K$ (z.B. zufällige Datenpunkte)

repeat bis sich nichts mehr ändert:

Zuweisung

for jedes i : $c^{(i)} \leftarrow \arg \min_k \|x^{(i)} - \mu_k\|^2$

Update

for jedes k : $\mu_k \leftarrow$ Mittel aller $x^{(i)}$ mit $c^{(i)} = k$

Beide Schritte senken $J \Rightarrow$ Konvergenz zu einem (lokalen) Minimum.

5 Initialisierung & Wahl von K

K-Means++: nächsten Startzentroid mit Wahrscheinlichkeit $\propto \|x - \mu_{\text{nächster}}\|^2$ ziehen (verteilt Startpunkte) $\Rightarrow$ meist bessere Lösung.

Mehrere Neustarts, bestes J behalten.

K ist Hyperparameter: **Ellenbogen-Methode** (Web/Praxis): $J(K)$ plotten, wo die Kurve knickt.

Beispiel: lokales Minimum in 1D

Daten $\{1, 2, 9, 10, 20\}$, $K = 2$. **Aufgabe** Was passiert bei Start $\mu = (1, 10)$ bzw. $\mu = (2, 20)$?

Lösung Start $(1, 10)$: $\{1, 2\} \rightarrow \mu_1$; $\{9, 10, 20\} \rightarrow \mu_2$. Update: $\mu_1 = 1.5$, $\mu_2 = 13$.

Zuweisung bleibt $\Rightarrow$ konvergiert: $J = 0.5 + 16 + 9 + 49 = 74.5$.

Start $(2, 20)$: $\{1, 2, 9, 10\} \rightarrow \mu_1$, $\{20\} \rightarrow \mu_2$; $\mu = (5.5, 20)$,

$J = 20.25 + 12.25 + 12.25 + 20.25 = 65$ **besser!**

Gleiche Daten, andere Startwerte, unterschiedliches Ergebnis.

6 Vorteile

- ✓ einfach, schnell ($O(nKd)$ pro Runde)
- ✓ skaliert auf große Daten
- ✓ gut interpretierbar

7 Grenzen

- × lokale Minima, Startabhängig
- × K muss gewählt werden
- × nur kugelförmige, ähnlich große Cluster

8 Key Takeaways

- ✓ alternieren: zuweisen / Mittel bilden
- ✓ J fällt monoton
- ✓ K-Means++ & Neustarts

9 Querverweise

K-Means ist ein "hartes" EM mit kugelförmigen Gauß-Komponenten; weicher Nachfolger: Gauß-Gemisch (nächste Seite). Anwendungen: Segmentierung, Farbquantisierung.

* K-Means in der Praxis (aus den ML Notes)

Zielfunktion heißt auch WCSS/Inertia (within-cluster sum of squares). **Ellenbogen**: WCSS über K plotten. **Silhouette** je Punkt:

$s = \frac{b-a}{\max(a,b)} \in [-1, 1]$ (a mittlerer Abstand im eigenen Cluster, b zum nächsten anderen); Mittel nahe 1 = gut getrennt. sklearn:

`n_clusters, init='k-means++', n_init (Neustarts), max_iter, tol`. Vorher skalieren; nicht geeignet für nichtkonvexe/verschieden große Cluster und kategoriale Daten. Einsatz: Kundensegmentierung, Bildkompression (Farbquantisierung), Anomalieerkennung.

? Selbsttest: kannst du das erklären?

F1 Warum konvergiert K-Means?

A: Beide Schritte senken J ; endlich viele Zuordnungen $\Rightarrow$ lokales Minimum.

F2 Was ist K-Means++?

A: Startzentroide mit Wkt. $\propto$ Abstand² zum nächsten Zentroid.

F3 Wo ist K-Means schwach?

A: Lokale Minima, K nötig, nur kugelförmige Cluster.

„Zuweisen, mitteln, wiederholen -- bis nichts mehr wackelt.“

Kein K vorgeben: baue einen Baum von Clustern und schneide ihn an einer Höhe.



Hierarchisches Clustering

Agglomerativ, Linkage & Dendrogramm

Merke:
Die Höhe im Dendrogramm ist der Abstand beim Verschmelzen

Quelle: hand-notes/ML Notes.pdf (Hierarchical Clustering); Rechenbeispiel selbst ergänzt

1 Idee

Unüberwachtes Clustern ohne feste Clusterzahl: es entsteht eine

Hierarchie (Baum, Dendrogramm). Die gewünschte Clusterzahl wählt man erst danach durch einen horizontalen Schnitt.


2 Agglomerativ vs. divisiv

Agglomerativ (bottom-up, Standard):

jeder Punkt ein Cluster, das nächstliegende Paar verschmelzen, bis nur noch eines bleibt.

Divisiv (top-down): alle in einem Cluster, rekursiv teilen.

3 Skizze: Dendrogramm



4 Linkage: Abstand zwischen Clustern

- **Single:** $\min_{a \in A, b \in B} d(a, b)$ – neigt zu Ketten
- **Complete:** $\max_{a, b} d(a, b)$ – kompakte Cluster
- **Average:** Mittel aller Paarabstände
- **Ward:** verschmelzt so, dass die Zunahme der Varianz innerhalb der Cluster minimal ist (ähnlich K-Means)

Abstandsmaß: Euklid, Manhattan, Kosinus...

5 Algorithmus (agglomerativ)

Agglomeratives Clustering

jeder Punkt $\leftarrow$ eigenes Cluster

berechne Distanzmatrix D

repeat bis 1 Cluster:

$(A, B) \leftarrow \arg \min D(A, B)$ # nächstes Paar

verschmelze $A \cup B$; merke Höhe = $D(A, B)$

aktualisiere D (gemäß Linkage)

schneide Dendrogramm an Höhe h oder für K Cluster

Aufwand $O(n^2)$ Speicher, bis $O(n^3)$ Zeit.

Beispiel: 10-Punkte $\{1, 2, 6, 8, 15\}$

Lösung Single Linkage: verschmelze (1, 2) bei $d = 1$; (6, 8) bei 2; $\{1, 2\} - \{6, 8\}$ bei $\min = 6 - 2 = 4$; zuletzt mit 15 bei $15 - 8 = 7$.

Complete Linkage: 1; 2; $\max = 8 - 1 = 7$; $15 - 1 = 14$.

Schnitt bei Höhe 3 (single): Cluster $\{1, 2\}$, $\{6, 8\}$, $\{15\}$ – der große Sprung $2 \rightarrow 4$ legt $K = 3$ nahe.

6 Vergleich mit K-Means

	K-Means	Hierarchisch
K	vorab	nachträglich (Schnitt)
Form	kugelförmig	flexibel (je Linkage)
Aufwand	$O(nKd)$	$O(n^2)$ und mehr
Ergebnis	flache Partition	Hierarchie

7 Vorteile

- ✓ kein K nötig, Dendrogramm
- ✓ beliebige Abstandsmaße
- ✓ gut für kleine Datensätze

8 Grenzen

- ✗ teuer bei großem n
- ✗ Verschmelzungen nicht umkehrbar
- ✗ empfindlich bei Rauschen/Ausreißern

9 Key Takeaways

- ✓ Baum statt fester Partition
- ✓ Linkage bestimmt die Clusterform
- ✓ Schnitt beim größten Höhengsprung

? Selbsttest: kannst du das erklären?

F1 Was bedeutet die Höhe im Dendrogramm?

A: Der Abstand (nach Linkage), bei dem zwei Cluster verschmolzen wurden.

F2 Single vs. Complete Linkage?

A: Single: kleinster Paarabstand (Ketten); Complete: größter (kompakte Cluster).

F3 Wie wählt man die Clusterzahl?

A: Dendrogramm dort schneiden, wo der vertikale Abstand zwischen Verschmelzungen am größten ist.

„Kein K , kein Problem -- der Baum zeigt alle möglichen Clusterungen zugleich.“

Warum K-Means konvergiert
-- und Code für K-Means,
hierarchisches Clustering und
Gauß-Gemische. ❤️

K-Means & Clustering: Vertiefung

Herleitung und Code

Merke:
Jeder Schritt senkt J :
Zuweisen minimiert, mitteln
minimiert

Quelle: main_notes.pdf Kap. 10 (K-Means), notes/cs229-notes7a.pdf; hand-notes/ML Notes.pdf (K-Means, Hierarchical Clustering); Herleitung
ausformuliert; Code: code/sk_cluster.py (real ausgeführt)

1 K-Means: J sinkt in jedem Schritt

Legende: J Kosten (Summe der quadrierten Abstände zum Zentroid), $c^{(i)}$ Cluster von Punkt i , μ_k Zentroid von Cluster k , n_k Anzahl Punkte in Cluster k .

In Worten: Zwei Schritte, die J nie erhöhen: jeden Punkt dem nächsten Zentrum zuweisen, dann jedes Zentrum auf den Mittelwert seiner Punkte setzen.

Zuweisung: für festes μ minimiert $c^{(i)} = \arg \min_k \|x^{(i)} - \mu_k\|^2$ jeden Summanden $\Rightarrow J \downarrow$.

Update: für festes c gilt

$$\nabla_{\mu_k} \sum_{i:c^{(i)}=k} \|x^{(i)} - \mu_k\|^2 = -2 \sum_{i:c^{(i)}=k} (x^{(i)} - \mu_k) = 0$$
$$\Rightarrow \mu_k = \frac{1}{n_k} \sum_{i:c^{(i)}=k} x^{(i)} \quad \text{Hesse } 2n_k I \succ 0$$

$J \geq 0$ nicht steigend, endlich viele Zuweisungen $\Rightarrow$ Konvergenz (lokales Minimum, nichtkonvex).

Beispiel: Der Mittelwert minimiert

Punkte $\{1, 2, 9\}$, ein Cluster, Zentroid μ .

Lösung $J(\mu) = \sum (x - \mu)^2$: $J(2) = 1 + 0 + 49 = 50$,
 $J(\mu=4) = 9 + 4 + 25 = 38$ (Mittel), $J(6) = 25 + 16 + 9 = 50$.
Das Minimum liegt beim arithmetischen Mittel 4 (numerisch geprüft).

(/) K-Means (Inertia, Silhouette), hierarchisches Clustering, Gauß-Gemisch

```
from sklearn.datasets import make_blobs
from sklearn.cluster import KMeans, AgglomerativeClustering
from sklearn.mixture import GaussianMixture
from sklearn.metrics import silhouette_score
X, _ = make_blobs(300, centers=3, cluster_std=0.8, random_state=0)
for k in (2, 3, 4, 5):
    km = KMeans(n_clusters=k, n_init=10, random_state=0).fit(X)
    print(f"k={k} Inertia={km.inertia_:7.1f} Silhouette={silhouette_score(X, km.labels_):.3f}")
agg = AgglomerativeClustering(n_clusters=3, linkage="ward").fit(X)
gmm = GaussianMixture(n_components=3, random_state=0).fit(X)
print("Hierarchisch Clustergrößen:", sorted(map(int, __import__("numpy").bincount(agg.labels_))))
print("GMM Gewichte phi:", gmm.weights_.round(2))
```

Ausgabe (real ausgeführt)

```
k=2 Inertia= 819.6 Silhouette=0.493
k=3 Inertia= 367.6 Silhouette=0.557
k=4 Inertia= 310.3 Silhouette=0.460
k=5 Inertia= 268.1 Silhouette=0.399
Hierarchisch Clustergrößen: [97, 98, 105]
GMM Gewichte phi: [0.31 0.33 0.36]
```

? Selbsttest: kannst du das herleiten?

F1 Warum sinkt J im Zuweisungsschritt?

A: Jedes $x^{(i)}$ wählt den nächsten Zentroid, das minimiert seinen Summanden.

F2 Warum ist der Zentroid der Mittelwert?

A: Ableiten und Null setzen:
 $\sum (x - \mu) = 0$, Hesse $2n_k I \succ 0$.

F3 Warum nur ein lokales Minimum?

A: J ist nichtkonvex; das Ergebnis hängt von der Initialisierung ab.

„Zuweisen, mitteln, wiederholen -- und jedes Mal wird es besser.“

Latente Variablen: erst raten (E-Schritt), dann neu schätzen (M-Schritt). ♥

EM-Algorithmus

Gauß-Gemische & Expectation-Maximization

Merke:
Jede Iteration erhöht $\log p(x; \theta)$
-- nie weniger!

Quelle: main_notes.pdf (Mixture of Gaussians, EM), notes/cs229-notes7b.pdf, notes/cs229-notes8.pdf

1 Gauß-Gemisch (MoG)

$$p(x) = \sum_{k=1}^K \phi_k \mathcal{N}(x; \mu_k, \Sigma_k)$$

(K Komponenten, ϕ_k Mischgewicht, μ_k, Σ_k Mittel/Kovarianz von Komponente k .) Latente Variable $z \sim \text{Multinomial}(\phi)$ (welche Komponente?), $x|z=k \sim \mathcal{N}(\mu_k, \Sigma_k)$. z ist nicht beobachtet.


2 Jensen & ELBO

Jensen: für konkaves f gilt $\mathbb{E}[f(X)] \leq f(\mathbb{E}[X])$. Damit für jedes $Q(z)$:

$$\log p(x; \theta) \geq \sum_z Q(z) \log \frac{p(x, z; \theta)}{Q(z)}$$

(ELBO). Gleichheit, wenn $Q(z) = p(z|x; \theta)$. (x Beobachtung, z verborgene Variable, θ Parameter, Q frei wählbare Verteilung über z .)

3 Skizze: untere Schranke



4 Allgemeiner EM

EM (allgemein)

repeat bis Konvergenz:

E-Schritt

$$Q_i(z^{(i)}) \leftarrow p(z^{(i)} | x^{(i)}; \theta)$$

M-Schritt

$$\theta \leftarrow \arg \max_{\theta} \sum_i \sum_z Q_i(z) \log \frac{p(x^{(i)}, z; \theta)}{Q_i(z)}$$

E: ELBO scharf machen (Schranke berührt). M: ELBO in θ hochschieben $\Rightarrow \log p$ steigt monoton.

5 EM für Gauß-Gemische

EM für MoG

repeat:

E: Verantwortlichkeit $\gamma_{ik} = P(z_i=k|x_i)$

$$\gamma_{ik} \leftarrow \frac{\phi_k \mathcal{N}(x_i; \mu_k, \Sigma_k)}{\sum_j \phi_j \mathcal{N}(x_i; \mu_j, \Sigma_j)}$$

M: gewichtete MLE

$$\phi_k \leftarrow \frac{1}{n} \sum_i \gamma_{ik}$$

$$\mu_k \leftarrow \frac{\sum_i \gamma_{ik} x_i}{\sum_i \gamma_{ik}}$$

$$\Sigma_k \leftarrow \frac{\sum_i \gamma_{ik} (x_i - \mu_k)(x_i - \mu_k)^T}{\sum_i \gamma_{ik}}$$

Beispiel: eine EM-Iteration in 1D

Daten $x = \{0, 1, 4\}$, $\mu = (0, 4)$, $\sigma = 1$, $\phi = (0.5, 0.5)$.

Lösung E: $\gamma_{\cdot 1} = (0.9997, 0.982, 0.0003)$ (z. B. $x=1$:

$$\frac{\mathcal{N}(1; 0, 1)}{\mathcal{N}(1; 0, 1) + \mathcal{N}(1; 4, 1)} = \frac{0.242}{0.242 + 0.0044}$$

M: $\sum \gamma_{\cdot 1} = 1.982 \Rightarrow \phi_1 = 0.66$, $\mu_1 = \frac{0.982 + 0.0012}{1.982} \approx 0.50$, $\mu_2 \approx 3.95$.

Die Zentren rücken zu den Datenclustern.

6 Praxis & Konvergenz

- Nichtkonvex: nur lokales Maximum; mehrere Starts.
- Initialisierung oft mit K-Means.
- Degeneriert eine Komponente ($\Sigma_k \rightarrow 0$): regularisieren.
- K-Means = hartes EM (Verantwortlichkeit 0/1).

7 Vorteile

- ✓ weiche Zuordnung, Wahrscheinlichkeiten
- ✓ allgemein für latente Variablen
- ✓ monotoner Fortschritt

8 Grenzen

- ✗ lokale Optima, langsam
- ✗ K muss vorgegeben werden
- ✗ bei wenig Daten instabil

9 Key Takeaways

- ✓ E: $Q = p(z|x; \theta)$
- ✓ M: gewichtete MLE
- ✓ $\log p$ steigt monoton

? Selbsttest: kannst du das erklären?

F1 Was macht der E-Schritt?

A: $Q_i(z) = p(z|x_i; \theta)$: macht die ELBO-Schranke scharf.

F2 Warum steigt $\log p$ monoton?

A: Der M-Schritt hebt die ELBO, die stets unter $\log p$ liegt.

F3 K-Means und EM?

A: K-Means = hartes EM mit gleichen, kugelförmigen Gauß-Komponenten.

„Rate klug, schätze neu -- und wiederhole, bis das Raten nichts mehr ändert.“

Jensen, ELBO, Monotonie und der M-Schritt des Gauß-Gemischs -- mit Code, der die Log-Likelihood steigen lässt.



EM-Algorithmus: Vertiefung

Herleitung und Code

Merke:

Alle Schätzer sind Maximum Likelihood mit Nebenbedingungen

Quelle: main_notes.pdf Kap. 11 (EM, Jensen, ELBO), notes/cs229-notes8.pdf; Schritte ergänzt; Code: code/sk_gmm.py (real ausgeführt)

1 Jensen $\Rightarrow$ ELBO

Legende: x Beobachtung, z verborgene Variable (z. B. Cluster), θ Parameter, $Q(z)$ frei gewählte Verteilung über z , $\mathbb{E}_{z \sim Q}$ Erwartung darüber, ELBO untere Schranke für $\log p(x; \theta)$.

In Worten: Der Logarithmus einer Summe ist schwer zu maximieren. Jensen liefert eine handliche untere Schranke: die Summe steht dann außerhalb des Logarithmus.

Beliebiges $Q(z)$ mit $\sum_z Q = 1$; $\log$ ist konkav ($\mathbb{E}f(X) \leq f(\mathbb{E}X)$):

$$\begin{aligned} \log p(x; \theta) &= \log \sum_z Q(z) \frac{p(x, z; \theta)}{Q(z)} = \log \mathbb{E}_{z \sim Q} \left[\frac{p(x, z; \theta)}{Q(z)} \right] \\ &\geq \mathbb{E}_{z \sim Q} \left[\log \frac{p(x, z; \theta)}{Q(z)} \right] = \text{ELBO}(Q, \theta) \end{aligned}$$

Jensen

2 Wann ist die Schranke scharf?

$$\log p(x; \theta) = \text{ELBO}(Q, \theta) + \text{KL}(Q(z) \parallel p(z|x; \theta))$$

Legende: KL Kullback-Leibler-Divergenz (Abstand zweier Verteilungen, immer ≥ 0), $p(z|x; \theta)$ Posterior der verborgenen Variablen.

$\text{KL} \geq 0$, $= 0$ genau für $Q(z) = p(z|x; \theta)$: **E-Schritt**. (Gleichheit in Jensen: der Quotient $\frac{p(x, z; \theta)}{Q(z)} = p(x)$ ist konstant in z genau dann, wenn $Q \propto p(x, z)$, also $Q = p(z|x; \theta)$.)

In Worten: Die Lücke zwischen $\log p$ und ELBO ist genau die KL. Wählt man Q als Posterior, ist die Lücke null.

3 Warum EM nie schlechter wird

Legende: $\ell(\theta) = \log p(x; \theta)$ Log-Likelihood, t Iteration, Q_t Verteilung aus dem E-Schritt von Iteration t .

$$\begin{aligned} \ell(\theta_t) &= \text{ELBO}(Q_t, \theta_t) && \text{E-Schritt: scharf} \\ &\leq \text{ELBO}(Q_t, \theta_{t+1}) && \text{M-Schritt maximiert in } \theta \\ &\leq \ell(\theta_{t+1}) && \text{ELBO ist immer eine untere Schranke} \end{aligned}$$

$\ell(\theta_t)$ steigt monoton; Konvergenz zu einem lokalen Maximum.

In Worten: E-Schritt legt die Schranke genau an die Kurve an, M-Schritt hebt sie, und die Schranke liegt nie über der Kurve: der Wert kann nicht sinken.

4 M-Schritt für Gauß-Gemische

Legende: $\gamma_{ik} = Q(z_i=k)$ Verantwortung von Komponente k für Punkt i , ϕ_k Mischgewicht, μ_k, Σ_k Mittel und Kovarianz von Komponente k , λ Lagrange-Multiplikator für $\sum_k \phi_k = 1$.

Zu maximieren: $\sum_{i,k} \gamma_{ik} [\log \phi_k + \log \mathcal{N}(x_i; \mu_k, \Sigma_k)]$.

$$\nabla_{\mu_k} = \sum_i \gamma_{ik} \Sigma_k^{-1} (x_i - \mu_k) = 0 \Rightarrow \mu_k = \frac{\sum_i \gamma_{ik} x_i}{\sum_i \gamma_{ik}}$$

$$\begin{aligned} \mathcal{L} \phi &= \sum_{i,k} \gamma_{ik} \log \phi_k - \lambda (\sum_k \phi_k - 1) \Rightarrow \frac{\sum_i \gamma_{ik}}{\phi_k} = \lambda \\ \Rightarrow \phi_k &= \frac{1}{n} \sum_i \gamma_{ik} \quad (\text{da } \sum_{i,k} \gamma_{ik} = n) \end{aligned}$$

In Worten: Der M-Schritt ist eine gewichtete Maximum-Likelihood-Schätzung: Mittelwert und Anteile, jeweils mit den Verantwortungen gewichtet.

Beispiel: die Likelihood steigt

Daten $x = (0, 1, 4)$, $\sigma = 1$. Vor: $\mu = (0, 4)$, $\phi = (0.5, 0.5)$. Nach einer Iteration: $\mu = (0.50, 3.95)$, $\phi = (0.66, 0.34)$.

Lösung $\ell_{\text{vor}} \approx -5.32 \rightarrow \ell_{\text{nach}} \approx -4.91$ (maschinell berechnet): Log-Likelihood steigt, wie der Beweis oben verlangt.

EM für ein Gauß-Gemisch: die Log-Likelihood steigt monoton

```
import numpy as np
from sklearn.datasets import make_blobs
from sklearn.mixture import GaussianMixture
X, _ = make_blobs(300, centers=3, cluster_std=[1.0, 1.5, 0.7],
                  random_state=0)
prev = -np.inf
for it in (1, 2, 3, 5, 10, 20):
    # EM-Iterationen fortsetzen
    gmm = GaussianMixture(3, max_iter=it, tol=0, init_params="random",
                          random_state=1).fit(X)
    ll = gmm.score(X) * len(X) # Log-Likelihood
    print(f"iter {it:2d} logL {ll:8.1f} steigt: {ll >= prev - 1e-6}")
    prev = ll
```

Ausgabe (real ausgeführt)

```
iter 1 logL -1207.3 steigt: True
iter 2 logL -1207.2 steigt: True
iter 3 logL -1206.9 steigt: True
iter 5 logL -1205.0 steigt: True
iter 10 logL -1166.4 steigt: True
iter 20 logL -1147.4 steigt: True
```

5 Lesart der Ausgabe

Die Log-Likelihood steigt in jeder Iteration (steigt: True) – das beweist die Herleitung oben: E-Schritt macht die ELBO scharf, M-Schritt hebt sie, $\text{ELBO} \leq \log p$. Der Anstieg ist nicht gleichmäßig (langsam bei Iteration 1–5, dann schneller); EM konvergiert zu einem lokalen Maximum, die Startwerte (init_params) entscheiden.

? Selbsttest: kannst du das herleiten?

F1 Welche Ungleichung liefert die ELBO?

A: Jensen für den konkaven $\log$.

F2 Warum ist $Q = p(z|x)$ die beste Wahl im E-Schritt?

A: Dann verschwindet der KL-Term: $\text{ELBO} = \log p(x; \theta)$.

F3 Wie erhält man ϕ_k im M-Schritt?

A: Lagrange mit $\sum \phi_k = 1$: $\phi_k = \frac{1}{n} \sum_i \gamma_{ik}$.

„Rate klug, schätze neu – und die Likelihood kann nicht sinken.“

Faktorenanalyse

Latentes Gauß-Modell für $n \gg m$

Viele Features, wenig Daten: erkläre die Korrelationen durch wenige latente Faktoren. ❤️

Merke:
 $x \sim \mathcal{N}(\mu, \Lambda\Lambda^\top + \Psi)$ --
 Korrelation ohne volle Kovarianzmatrix

Quelle: notes/cs229-notes9.pdf (Factor Analysis), section/gaussians.pdf, section/more_on_gaussians.pdf


1 Problem: $n \gg m$

Mehr Features als Beispiele: die MLE-Kovarianz $\hat{\Sigma}$ hat Rang $\leq m - 1 < n$, ist **singulär**, $\hat{\Sigma}^{-1}$ existiert nicht $\Rightarrow$ Gauß-Dichte nicht berechenbar.

2 Einschränkungen von Σ

Diagonal: $\Sigma_{jj} = \frac{1}{m} \sum_i (x_j^{(i)} - \mu_j)^2$, nur Achsen-Ellipsen.
Kugel: $\Sigma = \sigma^2 I$.
 Beide nicht singulär, aber keine Korrelationen. FA: Kompromiss.

3 Skizze: Ebene + Rauschen



4 Das Modell

$z \in \mathbb{R}^k$ latent ($k \ll n$; n Merkmale, Λ Ladungsmatrix, Ψ diagonale Rauschkovarianz):
 $z \sim \mathcal{N}(0, I)$, $x|z \sim \mathcal{N}(\mu + \Lambda z, \Psi)$
 äquivalent $x = \mu + \Lambda z + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \Psi)$, Ψ diagonal, $z \perp \varepsilon$.
 Randverteilung:

$$x \sim \mathcal{N}(\mu, \Lambda\Lambda^\top + \Psi)$$

$\Lambda \in \mathbb{R}^{n \times k}$ Ladungen: $O(nk)$ statt $O(n^2)$ Parameter.

5 Gauß-Formeln (Marginal/Bedingt)

Für $x = (x_1, x_2) \sim \mathcal{N}(\mu, \Sigma)$ (in zwei Blöcke zerlegt; Σ_{12} Kovarianz zwischen den Blöcken) gilt: $x_1 \sim \mathcal{N}(\mu_1, \Sigma_{11})$ und
 $\mu_{1|2} = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2)$
 $\Sigma_{1|2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$
 Diese Formeln liefern auch die GP-Vorhersage.

6 EM für Faktorenanalyse

`</> EM für FA`

keine geschlossene MLE $\Rightarrow$ EM

repeat:

E: Posterior über z

$$\mu_{z|x} \leftarrow \Lambda^\top (\Lambda\Lambda^\top + \Psi)^{-1} (x - \mu)$$

$$\Sigma_{z|x} \leftarrow I - \Lambda^\top (\Lambda\Lambda^\top + \Psi)^{-1} \Lambda$$

M: Λ, Ψ, μ aus $\mathbb{E}[z|x], \mathbb{E}[zz^\top|x]$

Beispiel: 1 Faktor, 2 Features

$\Lambda = \begin{pmatrix} 1 \\ 0.5 \end{pmatrix}$, $\Psi = \text{diag}(0.1, 0.2)$.

Lösung $\Sigma = \Lambda\Lambda^\top + \Psi = \begin{pmatrix} 1.1 & 0.5 \\ 0.5 & 0.45 \end{pmatrix}$.

Korrelation $\rho = \frac{0.5}{\sqrt{1.1 \cdot 0.45}} \approx \mathbf{0.71}$ – allein durch den gemeinsamen Faktor.

Parameterzahl, $n = 100, k = 5$: volle Σ : 5050; FA: $nk + n = \mathbf{600}$.

7 Bezug zu PCA

FA ist probabilistisch (Rauschen Ψ , EM).
 PCA entspricht dem Grenzfall $\Psi = \sigma^2 I$, $\sigma^2 \rightarrow 0$ und ist eine direkte Eigenvektor-Lösung.

8 Vorteile

- ✓ funktioniert bei $n \gg m$
- ✓ Korrelationen modelliert
- ✓ probabilistisch, EM

9 Grenzen

- ✗ Lösung nur bis auf Rotation eindeutig
- ✗ EM: lokale Optima
- ✗ k muss gewählt werden

10 Key Takeaways

- ✓ $x = \mu + \Lambda z + \varepsilon$, $\Sigma = \Lambda\Lambda^\top + \Psi$
- ✓ Formeln für Marginale/Bedingte von Gauß-Verteilungen
- ✓ Lernen per EM (E: Posterior $z|x$)

? Selbsttest: kannst du das erklären?

F1 Warum Faktorenanalyse?

A: Bei $n \gg m$ ist $\hat{\Sigma}$ singulär; FA braucht nur $nk + n$ Parameter.

F2 Randverteilung von x ?

A: $\mathcal{N}(\mu, \Lambda\Lambda^\top + \Psi)$.

F3 FA vs. PCA?

A: FA probabilistisch (Rauschen Ψ , EM);
 PCA = Grenzfall $\Psi = \sigma^2 I$, $\sigma^2 \rightarrow 0$.

„Wenig Faktoren, viele Beobachtungen – die Korrelation hat eine Ursache.“

Sequenzen: die Zustände sind versteckt, sichtbar sind nur die Ausgaben. ♥

Hidden Markov Models

Zeitreihen mit latenten Zuständen

Merke:
Drei Fragen: Likelihood -- Decoding -- Learning

Quelle: section/cs229-hmm.pdf (Daniel Ramage, CS229 Section Notes)


1 Markov-Modell

Zwei Annahmen: **Limited Horizon**
 $P(z_t | z_{t-1}, \dots, z_1) = P(z_t | z_{t-1})$ und
Stationarität. Übergangsmatrix
 $A_{ij} = P(z_t = s_j | z_{t-1} = s_i)$;
 Sequenzwahrscheinlichkeit
 $P(\vec{z}) = \prod_t A_{z_{t-1} z_t}$.

2 Hidden Markov Model

Zustände z_t unbeobachtet, sichtbar ist
 $x_t \in V$ mit **Emissionsmatrix**
 $B_{jk} = P(x_t = v_k | z_t = s_j)$ (Output
 Independence). Beispiel: Wetter
 (versteckt) $\rightarrow$ Eiscreme-Konsum
 (sichtbar).

3 Skizze: Kette



4 Forward-Prozedur (Frage 1)

(π_i Startwahrscheinlichkeit von Zustand i , A_{ij} Übergang, $B_{j,x}$ Emission, T Länge, $|S|$ Zustandszahl.) $\alpha_i(t) = P(x_1..x_t, z_t = s_i)$;
 statt $|S|^T$ Pfade nur $O(|S|^2 T)$:

```

(</> Forward
 $\alpha_i(1) \leftarrow \pi_i B_{i,x_1}$ 
for  $t = 2..T$ , for  $j$ :
   $\alpha_j(t) \leftarrow (\sum_i \alpha_i(t-1) A_{ij}) B_{j,x_t}$ 
return  $P(\vec{x}) = \sum_i \alpha_i(T)$ 

```

Analog: Backward-Prozedur $\beta_i(t)$.

5 Viterbi (Frage 2)

Wie Forward, aber Maximum statt Summe; Vorgänger merken:

```

(</> Viterbi
 $\delta_i(1) \leftarrow \pi_i B_{i,x_1}$ 
for  $t = 2..T$ , for  $j$ :
   $\delta_j(t) \leftarrow \max_i \delta_i(t-1) A_{ij} \cdot B_{j,x_t}$ 
   $\psi_j(t) \leftarrow \arg \max_i \delta_i(t-1) A_{ij}$ 
 $z_T \leftarrow \arg \max_j \delta_j(T)$ 
for  $t = T-1..1$ :  $z_t \leftarrow \psi_{z_{t+1}}(t+1)$  # Backtracking

```

6 Baum-Welch (Frage 3)

Lernen von A, B ist EM (nichtkonvex, mehrere Starts, Smoothing gegen Nullen).

```

(</> Baum-Welch
repeat bis Konvergenz:
  # E: Forward + Backward
   $\gamma_t(i, j) \propto \alpha_i(t) A_{ij} B_{j,x_{t+1}} \beta_j(t+1)$ 
  # M: erwartete Häufigkeiten
   $A_{ij} \leftarrow \frac{\sum_t \gamma_t(i, j)}{\sum_j \sum_t \gamma_t(i, j)}$ 
   $B_{jk} \leftarrow \frac{\sum_i \sum_{t: x_t = v_k} \gamma_t(i, j)}{\sum_i \sum_t \gamma_t(i, j)}$ 

```

Beispiel: Heiß/Kalt, $x = (3, 1)$ Eisportionen

$\pi = (0.5, 0.5)$, $A = \begin{pmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{pmatrix}$; $B_H(1, 2, 3) = (0.2, 0.4, 0.4)$,
 $B_C = (0.5, 0.4, 0.1)$.

Lösung Forward: $\alpha_H(1) = 0.2$, $\alpha_C(1) = 0.05$.

$\alpha_H(2) = (0.2 \cdot 0.7 + 0.05 \cdot 0.4) \cdot 0.2 = 0.032$,

$\alpha_C(2) = (0.2 \cdot 0.3 + 0.05 \cdot 0.6) \cdot 0.5 = 0.045$

$P(x) = 0.032 + 0.045 = \mathbf{0.077}$.

Viterbi: $\delta_C(2) = \max(0.2 \cdot 0.3, 0.05 \cdot 0.6) \cdot 0.5 = 0.03$ (Vorgänger H) $\Rightarrow$ Pfad **(H,C)**.

7 Anwendungen

- Spracherkennung
- Part-of-Speech-Tagging
- Bioinformatik (Gene, Proteine)

8 Grenzen

- × Markov-Annahme (Gedächtnis 1)
- × lokale Optima bei EM
- × diskrete Zustände

9 Key Takeaways

- ✓ Forward: Likelihood, $O(|S|^2 T)$
- ✓ Viterbi: bester Pfad
- ✓ Baum-Welch: EM für A, B

? Selbsttest: kannst du das erklären?

F1 Was leistet die Forward-Prozedur?

A: $P(\vec{x})$ in $O(|S|^2 T)$ statt $|S|^T$ Pfaden.

F2 Viterbi vs. Forward?

A: Maximum statt Summe + Backtracking: wahrscheinlichste Zustandsfolge.

F3 Wie lernt man A, B ?

A: Baum-Welch (EM): erwartete Übergangs-/Emissionshäufigkeiten.

„Aus dem, was du siehst, schließt du auf das, was verborgen bleibt.“

Hauptkomponentenanalyse (PCA)

Dimensionsreduktion durch Eigenvektoren

Finde die Richtungen größter Varianz und projiziere die Daten darauf. ❤️

Merke:
PCA = Eigenvektoren der Kovarianzmatrix

Quelle: main_notes.pdf (PCA), notes/cs229-notes10.pdf

1 Idee

Daten $x \in \mathbb{R}^n$ liegen ungefähr in einem k -dimensionalen Unterraum ($k \ll n$). PCA findet ihn direkt – ohne Iteration, nur mit einer **Eigenwertzerlegung**. Nutzen: Kompression, Visualisierung, Rauschunterdrückung.


2 Optimierungsproblem

Wähle orthonormale Richtungen $U = [u_1 \dots u_k]$, die die projizierte Varianz maximieren:

$$\max_{U^T U = I_k} \text{tr}(U^T \hat{\Sigma} U)$$

Lösung: die k Eigenvektoren von $\hat{\Sigma}$ zu den größten Eigenwerten. ($\hat{\Sigma}$ Kovarianzmatrix, u_j Richtungen, tr Spur, I_k Einheitsmatrix.)

3 Skizze: Hauptachsen



4 Algorithmus

```
</> PCA
x̄ ← 1/n ∑ x_i; x_i ← x_i - x̄ # zentrieren
Σ̂ ← 1/n X^T X
(λ_j, u_j) ← Eigenpaare von Σ̂ (oder SVD von X)
U_k ← [u_1 ... u_k] zu den k größten λ_j
z_i ← U_k^T x_i ∈ ℝ^k # Projektion
x̃_i ← U_k z_i + x̄ # Rekonstruktion
```

5 Wie viele Komponenten?

Anteil erklärter Varianz (λ_j Eigenwert = Varianz entlang u_j , n Dimensionen, k behaltene Komponenten):

$$\frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^n \lambda_j}$$

Wähle k so, dass z. B. 90–99% erklärt sind (Scree-Plot).

Vorher skalieren, wenn Features verschiedene Einheiten haben (sonst dominiert die größte Skala).

Beispiel: 4 Punkte in 2D

Zentrierte Punkte $(2, 0), (-2, 0), (0, 1), (0, -1)$.

Lösung $\hat{\Sigma} = \frac{1}{4} \sum x x^T = \begin{pmatrix} 2 & 0 \\ 0 & 0.5 \end{pmatrix}$, Eigenwerte $\lambda_1 = 2, \lambda_2 = 0.5$, $u_1 = (1, 0)$.

Erklärte Varianz von u_1 : $\frac{2}{2.5} = 80\%$.

Projektion auf u_1 : $(2, 0) \rightarrow 2, (0, 1) \rightarrow 0$ – aus 2D wird 1D, ein Fünftel der Varianz geht verloren.

6 Bezüge

- **Faktorenanalyse**: probabilistische Variante (mit Rauschen Ψ); PCA ist der Grenzfall $\Psi = \sigma^2 I \rightarrow 0$.
- **SVD**: $X = U \Sigma V^T$; die Spalten von V sind die Hauptachsen.
- **ICA**: sucht statt maximaler Varianz Unabhängigkeit.

7 Vorteile

- ✓ geschlossene Lösung
- ✓ unüberwacht, schnell
- ✓ nützlich vor anderen Verfahren

8 Grenzen

- ✗ nur lineare Struktur
- ✗ Varianz $\neq$ Relevanz für die Aufgabe
- ✗ skalenempfindlich

9 Key Takeaways

- ✓ zentrieren, Kovarianz, Eigenvektoren
- ✓ Projektion $z = U_k^T x$
- ✓ Varianzanteil wählt k

* PCA in Formeln & Praxis (aus den ML Notes)

Schritte: $Z = \frac{X - \mu}{\sigma}$ (standardisieren), $C = \frac{1}{n-1} Z^T Z$, Eigenzerlegung $C v_i = \lambda_i v_i$, sortieren, $V_k = [v_1 \dots v_k]$, $Z_k = Z V_k$. Erklärte Varianz: $\text{EVR}_i = \frac{\lambda_i}{\sum_j \lambda_j}$, kumulativ $\text{CEV}_k = \sum_{i \leq k} \text{EVR}_i$ (Scree-Plot: k am Ellenbogen). Vorteile: weniger Dimensionen, entfernt Multikollinearität, beschleunigt Modelle, Visualisierung (2D/3D). Grenzen: Komponenten schwer interpretierbar, nur linear, skalenempfindlich. Code: Vertiefungsseite.

? Selbsttest: kannst du das erklären?

F1 Was maximiert PCA?

A: Projizierte Varianz $\text{tr}(U^T \hat{\Sigma} U)$ mit $U^T U = I$.

F2 Wie viele Komponenten?

A: So viele, dass z. B. 90–99% der Varianz erklärt sind.

F3 Warum vorher skalieren?

A: Sonst dominiert das Feature mit der größten Skala.

„Behalte die Richtungen, in denen die Daten etwas zu erzählen haben.“

Cocktailparty: aus Mischungen die ursprünglichen Sprecher zurückgewinnen. ❤️

Independent Component Analysis

Blind Source Separation

Merke:
Quellen dürfen nicht gaußverteilt sein!

Quelle: main_notes.pdf (ICA), notes/cs229-notes11.pdf


1 Problem

n Sprecher (Quellen $s \in \mathbb{R}^n$), n Mikrofone messen Mischungen $x = As$.
Gesucht: Entmischungsmatrix $W = A^{-1}$, sodass $s = Wx$ – ganz ohne Kenntnis von A oder s .

2 Ambiguitäten

- **Skalierung:** $A \text{diag}(c) \cdot \text{diag}(1/c) s$ erzeugt dasselbe x
- **Permutation:** Reihenfolge der Quellen unbestimmt
- **Gauß:** gaußsche Quellen sind nie identifizierbar (rotationssymmetrisch)

3 Skizze: Mischen & Entmischen



4 Likelihood & Regel

Mit unabhängigen Quellen $p(s) = \prod_j p_s(s_j)$ (w_j j -te Zeile von W , $|W|$ Determinante) gilt

$$p_x(x) = \prod_{j=1}^n p_s(w_j^T x) \cdot |W|$$

Wähle p_s mit CDF $g(s) = 1/(1 + e^{-s})$ (super-gaußsch).
Stochastischer Gradient-Aufstieg auf $\log p_x$ (α Lernrate):

$$W \leftarrow W + \alpha \left((1 - 2g(Wx)) x^T + (W^T)^{-1} \right)$$

5 Algorithmus

```

</> ICA (Gradient-Aufstieg)
W ← I (oder zufällig)
repeat bis Konvergenz:
  for Beispiel  $x_i$  in zufälliger Reihenfolge:
    W ← W +  $\alpha((1 - 2g(Wx_i))x_i^T + (W^T)^{-1})$ 
   $\hat{s}_i \leftarrow Wx_i$  # geschätzte Quellen
  
```

Beispiel: Mischen und Entmischen

$A = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix}$, Quellen $s = (1, -1)$.

Lösung $x = As = (1 - 0.5, 0.5 - 1) = (0.5, -0.5)$.

$\det A = 0.75$, $W = A^{-1} = \frac{1}{0.75} \begin{pmatrix} 1 & -0.5 \\ -0.5 & 1 \end{pmatrix}$.

$Wx = \frac{1}{0.75} (0.5 + 0.25, -0.25 - 0.5) = (1, -1) = s$

Quellen zurückgewonnen.

6 Warum nicht gaußsch?

Bei gaußschen Quellen ist $p(x)$ rotationssymmetrisch: jede Drehung von W erklärt die Daten gleich gut $\Rightarrow$ keine eindeutige Lösung. Nur nicht-gaußsche Unabhängigkeit liefert Information.

PCA vs. ICA: PCA dekorreliert (2. Momente), ICA macht unabhängig (höhere Momente).

7 Anwendungen

- Audio: Cocktailparty
- EEG/MEG: Artefakte entfernen
- Bild-/Signalanalyse

8 Grenzen

- × Skalierung/Reihenfolge unbestimmt
- × Quellen nicht gaußsch nötig
- × Anzahl Mikrofone $\geq$ Quellen

9 Key Takeaways

- ✓ $x = As$, gesucht $W = A^{-1}$
- ✓ Unabhängigkeit + Nicht-Gauß
- ✓ SGD auf Log-Likelihood

? Selbsttest: kannst du das erklären?

F1 Was ist gesucht?

A: $W = A^{-1}$, sodass $s = Wx$ aus $x = As$.

F2 Warum keine Gauß-Quellen?

A: Rotationssymmetrie: jede Drehung erklärt die Daten gleich gut.

F3 Welche Ambiguitäten bleiben?

A: Skalierung und Permutation der Quellen.

„Aus dem Stimmengewirr die einzelne Stimme herausfiltern.“

PCA & ICA: Vertiefung

Herleitung und Code

PCA als Eigenwertproblem
und ICA-Dichte per Variablen-
wechsel -- mit PCA-Code. ❤️

Merke:
Lagrange mit $u^T u = 1$ führt
auf $\hat{\Sigma} u = \lambda u$

Quelle: main_notes.pdf Kap. 12--13 (PCA, ICA), notes/cs229-notes10.pdf, cs229-notes11.pdf; hand-notes/ML Notes.pdf (PCA); Schritte ergänzt; Code: code/sk_pca.py (real ausgeführt)

1 PCA: Varianz maximieren

Legende: x_i zentrierter Datenpunkt, u Richtung (Länge 1), $\hat{\Sigma} = \frac{1}{n} \sum x_i x_i^T$ Kovarianzmatrix, λ Lagrange-Multiplikator und zugleich Eigenwert.

Erste Hauptkomponente: $\max_u \frac{1}{n} \sum (u^T x_i)^2 = u^T \hat{\Sigma} u$ s.t. $u^T u = 1$.

$$\mathcal{L} = u^T \hat{\Sigma} u - \lambda(u^T u - 1)$$

$$\nabla_u \mathcal{L} = 2\hat{\Sigma} u - 2\lambda u = 0 \Rightarrow \hat{\Sigma} u = \lambda u$$

u ist Eigenvektor; Zielwert $u^T \hat{\Sigma} u = \lambda \Rightarrow$ wähle den größten Eigenwert. Weitere Komponenten: orthogonal dazu (nächste Eigenvektoren).

In Worten: Gesucht ist die Richtung, in der die projizierten Daten am stärksten streuen. Die Streuung entlang u ist $u^T \hat{\Sigma} u$; das Maximum liefert der Eigenvektor zum größten Eigenwert.

2 ICA: Dichte unter $s = Wx$

Legende: s unabhängige Quellen, $x = As$ beobachtete Mischung, A Mischmatrix, $W = A^{-1}$ Entmischmatrix, w_j j -te Zeile von W , g Sigmoid als angenommene Quellen-Verteilungsfunktion, α Lernrate.

Quellen unabhängig, $p_s(s) = \prod_j p_s(s_j)$, $x = As$, $W = A^{-1}$.
Variablenwechsel (Jacobi-Determinante):

$$p_x(x) = p_s(Wx) |\det W| = \left(\prod_j p_s(w_j^T x) \right) |W|$$

Log-Likelihood: $\sum_i [\sum_j \log g'(w_j^T x_i) + \log |W|]$ mit
 $\nabla_W \log |W| = (W^T)^{-1} \Rightarrow$ Update
 $W \leftarrow W + \alpha((1 - 2g(Wx))x^T + (W^T)^{-1})$.

In Worten: Aus der Dichte der unabhängigen Quellen folgt die Dichte der Mischung; $|\det W|$ korrigiert, wie W Volumen streckt. Dann Gradientenanstieg auf der Log-Likelihood.

(/) PCA mit Standardisierung: erklärte Varianz

```
from sklearn.datasets import load_digits
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler
X, _ = load_digits(return_X_y=True)
Z = StandardScaler().fit_transform(X)
pca = PCA().fit(Z)
cev = pca.explained_variance_ratio_.cumsum()
print("Komponenten fuer 90% Varianz:", int((cev < 0.90).sum() + 1), "von", X.shape[1])
print("erste 3 EVR:", pca.explained_variance_ratio_[:3].round(3))
```

Ausgabe (real ausgeführt)

Komponenten fuer 90% Varianz: 31 von 64
erste 3 EVR: [0.12 0.096 0.084]

? Selbsttest: kannst du das herleiten?

F1 Warum führt PCA auf ein Eigenwertproblem?

A: Lagrange mit $u^T u = 1$: $\hat{\Sigma} u = \lambda u$; die Varianz ist λ .

F2 Woher kommt $|\det W|$ in der ICA-Dichte?

A: Variablenwechsel $s = Wx$: die Jacobi-Determinante korrigiert das Volumen.

F3 Warum vor PCA skalieren?

A: Sonst dominiert das Feature mit der größten Skala die Varianz.

„Behalte die Richtungen, in denen die Daten etwas zu erzählen haben.“

Neue Daten erzeugen: latente Variablen mit neuronalen Netzen – VAE, GAN und Diffusion. ❤️

Generative Modelle: VAE, GAN & Co.

Von EM zu modernen generativen Netzen

Merke:
VAE = EM mit neuronalen Netzen und Reparametrisierung

Quelle: main_notes.pdf Kap. 11.5 (Variational Auto-Encoder); GAN und Diffusion als Web-Zusatz (markiert); Code: Vertiefungsseite


1 Idee

Diskriminative Modelle lernen $p(y|x)$; **generative** lernen $p(x)$ und können neue Beispiele sampeln. Latente Variable z (niedrigdimensional) erklärt die Daten: $z \rightarrow x$ (Decoder). Der VAE erweitert EM auf kontinuierliche z und neuronale Netze.

2 VAE-Modell (Notes)

$z \sim \mathcal{N}(0, I_k)$
 $x|z \sim \mathcal{N}(g(z; \theta), \sigma^2 I)$ (Decoder)
 $Q_i = \mathcal{N}(q(x^{(i)}; \phi), \text{diag}(v(x^{(i)}; \psi))^2)$
 Encoder q, v (Mittel und Streuung, Parameter ϕ, ψ) approximieren den intractablen Posterior $p(z|x)$; θ sind die Decoder-Parameter.

3 Skizze: Autoencoder



4 ELBO und Reparametrisierung

$$\text{ELBO} = \underbrace{\mathbb{E}_Q[\log p(x|z)]}_{\text{Rekonstruktion}} - \underbrace{\text{KL}(Q(z|x) \| p(z))}_{\text{Regularisierer}}$$

Gradient nach ϕ, ψ ist knifflig (Sampling hängt von ihnen ab) $\Rightarrow$

Reparametrisierungs-Trick: $z = q(x; \phi) + v(x; \psi) \odot \xi$ mit

$\xi \sim \mathcal{N}(0, I)$. Für Gauß: $\text{KL} = \frac{1}{2} \sum_j (\mu_j^2 + \sigma_j^2 - 1 - \log \sigma_j^2)$.

5 VAE-Training

```
</> VAE-Schritt
(μ, log σ²) ← Encoder(x)
ξ ~ N(0, I); z ← μ + σ ⊙ ξ
x̂ ← Decoder(z)
L ← ||x - x̂||² + KL(N(μ, σ²) || N(0, I))
Gradient über L (Backprop), Update von φ, ψ, θ
```

Sampling neuer Daten: $z \sim \mathcal{N}(0, I)$, dann Decoder.

Beispiel: KL-Term in 1D

Encoder liefert $\mu = 0.5, \sigma = 0.8$.

Lösung $\text{KL} = \frac{1}{2} (\mu^2 + \sigma^2 - 1 - \ln \sigma^2) = \frac{1}{2} (0.25 + 0.64 - 1 - \ln 0.64) = \frac{1}{2} (-0.11 + 0.446) = \mathbf{0.168}$ – klein, weil $\mathcal{N}(0.5, 0.8^2)$ nahe an $\mathcal{N}(0, 1)$ liegt. $\mu = 0, \sigma = 1$ ergäbe $\text{KL} = 0$.

Ausgabe des Code-Snippets (Vertiefungsseite): Rekonstruktion sinkt, KL steigt leicht – der klassische Kompromiss.

6 GAN: Spiel Generator vs. Diskriminator (Web)

$$\min_G \max_D \mathbb{E}_x \log D(x) + \mathbb{E}_z \log(1 - D(G(z)))$$

D unterscheidet echt/fake, G soll D täuschen. Abwechselnd:
 (1) D auf echten und erzeugten Daten trainieren, (2) G so ändern, dass $D(G(z))$ steigt (non-saturating: $-\log D(G(z))$).
 Probleme: instabil, Mode Collapse.

7 Diffusionsmodelle (Web)

Vorwärts (x_0 Originalbild, $\bar{\alpha}_t$ Rauschplan, ε Rauschen): nach und nach Rauschen hinzufügen, $x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \varepsilon$.
 Rückwärts: ein Netz $\varepsilon_\theta(x_t, t)$ lernt, das Rauschen vorherzusagen (Verlust $\|\varepsilon - \varepsilon_\theta\|^2$). Sampling: aus reinem Rauschen schrittweise entrauschen. Heute Stand der Technik bei Bildern.

8 Vergleich

	VAE	GAN	Diffusion
Ziel	ELBO	Minimax	Rauschvorhersage
Training	stabil	instabil	stabil
Samples	eher unscharf	scharf	sehr gut
Sampling	schnell	schnell	langsam

9 Key Takeaways

- ✓ VAE: ELBO = Rekonstruktion – KL; Encoder = approximativer Posterior; Reparametrisierung ermöglicht Backprop durch das Sampling
- ✓ GAN: adversariales Spiel; Diffusion: iteratives Entauschen

? Selbsttest: kannst du das erklären?

F1 Warum der

Reparametrisierungs-Trick?

A: Damit der Gradient durch das Sampling fließt: Zufall steckt nur in ξ , nicht in ϕ, ψ .

F2 Was bewirkt der KL-Term?

A: Hält den Posterior nahe an $\mathcal{N}(0, I)$: glatter, samplebarer latenter Raum.

F3 Was ist Mode Collapse?

A: Der GAN-Generator erzeugt nur wenige Varianten der Daten.

„Wer die Daten erzeugen kann, hat sie verstanden.“

VAE & GAN: Vertiefung

Herleitung und Code

KL-Term und Reparametrisierung hergeleitet – plus VAE- und GAN-Training in PyTorch. ❤️

Merke:
Zufall steckt nur in ξ , nicht in μ, σ

Quelle: main_notes.pdf Kap. 11.5 (Variational Auto-Encoder); GAN als Web-Zusatz (markiert); Herleitungen ausformuliert; Code: code/torch_vae.py, torch_gan.py (real ausgeführt)

1 KL-Term in geschlossener Form

$Q = \mathcal{N}(\mu, \sigma^2)$, $P = \mathcal{N}(0, 1)$, $z \sim Q$:

Legende: Q Encoder-Verteilung des latenten Codes z , P Prior, μ, σ Mittel und Streuung von Q , KL Abstand zweier Verteilungen, $\mathbb{E}_Q$ Erwartung über $z \sim Q$.

$$\begin{aligned} \text{KL}(Q||P) &= \mathbb{E}_Q [\log Q(z) - \log P(z)] \\ &= \mathbb{E} \left[-\frac{1}{2} \log \sigma^2 - \frac{(z-\mu)^2}{2\sigma^2} + \frac{z^2}{2} \right] \quad \log 2\pi \text{ kürzt sich} \\ &= -\frac{1}{2} \log \sigma^2 - \frac{1}{2} + \frac{1}{2} (\mu^2 + \sigma^2) \quad \mathbb{E}(z-\mu)^2 = \sigma^2, \mathbb{E}z^2 = \mu^2 + \sigma^2 \\ &= \frac{1}{2} (\mu^2 + \sigma^2 - 1 - \log \sigma^2), \text{ im Vektorfall summiert über die Dimensionen.} \end{aligned}$$

In Worten: Der KL-Term hält den Encoder nah am Prior $\mathcal{N}(0, 1)$: null genau für $\mu = 0, \sigma = 1$.

2 Warum die Reparametrisierung funktioniert

Legende: f beliebige Funktion des Codes (z. B. Rekonstruktionsverlust), ξ Zufallszahl aus $\mathcal{N}(0, 1)$, $\nabla_\mu, \nabla_\sigma$ Ableitungen des Erwartungswerts.

$\mathbb{E}_{z \sim \mathcal{N}(\mu, \sigma^2)} [f(z)] = \mathbb{E}_{\xi \sim \mathcal{N}(0, 1)} [f(\mu + \sigma\xi)]$, denn $z = \mu + \sigma\xi$. Jetzt hängt die Verteilung nicht mehr von μ, σ ab, nur die Funktion:

$$\nabla_\mu = \mathbb{E}_\xi [f'(\mu + \sigma\xi)], \quad \nabla_\sigma = \mathbb{E}_\xi [f'(\mu + \sigma\xi) \xi]$$

Check $f(z) = z^2$: $\mathbb{E}f = \mu^2 + \sigma^2$, also $\nabla_\mu = 2\mu$ und $\nabla_\sigma = 2\sigma$; rechts: $\mathbb{E}[2(\mu + \sigma\xi)] = 2\mu$, $\mathbb{E}[2(\mu + \sigma\xi)\xi] = 2\sigma$ **stimmt**. Der Gradient darf so in den Erwartungswert (Backprop durch das Sampling).

In Worten: Der Zufall wird in ξ ausgelagert; μ und σ stehen nur noch in einer gewöhnlichen Funktion, durch die Backprop laufen kann.

(/) Variational Autoencoder: Reparametrisierung, Rekonstruktion + KL

```
import torch, torch.nn as nn
torch.manual_seed(0)
X = torch.randn(512, 4) @ torch.randn(4, 8) * 0.5 # Daten in 4D-Unterraum
enc = nn.Linear(8, 2 * 2) # -> (mu, log sigma^2), k=2
dec = nn.Sequential(nn.Linear(2, 16), nn.ReLU(), nn.Linear(16, 8))
opt = torch.optim.Adam([*enc.parameters(), *dec.parameters()], lr=1e-2)
for step in range(301):
    mu, logvar = enc(X).chunk(2, dim=1)
    z = mu + torch.exp(0.5 * logvar) * torch.randn_like(mu) # Reparametrisierungs-Trick
    rec = ((dec(z) - X) ** 2).sum(1).mean() # -log p(x|z) (Gauss)
    kl = (-0.5 * (1 + logvar - mu ** 2 - logvar.exp()).sum(1)).mean() # KL(Q||N(0, I))
    loss = rec + kl # = -ELBO
    opt.zero_grad(); loss.backward(); opt.step()
    if step % 100 == 0: print(f"step {step:3d} rec {rec.item():.3f} KL {kl.item():.3f}")
```

Ausgabe (real ausgeführt)

step	0	rec	9.845	KL	0.605
step	100	rec	3.016	KL	1.304
step	200	rec	2.458	KL	1.506
step	300	rec	2.308	KL	1.598

(/) GAN: Generator gegen Diskriminator auf 1D-Daten

```
import torch, torch.nn as nn
torch.manual_seed(0)
G = nn.Sequential(nn.Linear(4, 16), nn.ReLU(), nn.Linear(16, 1)) # Generator
D = nn.Sequential(nn.Linear(1, 16), nn.ReLU(), nn.Linear(16, 1)) # Diskriminator
og, od = torch.optim.Adam(G.parameters(), 1e-3), torch.optim.Adam(D.parameters(), 1e-3)
bce = nn.BCEWithLogitsLoss()
for step in range(3001):
    real = torch.randn(128, 1) * 0.5 + 3.0 # Ziel: N(3, 0.5^2)
    fake = G(torch.randn(128, 4))
    ld = bce(D(real), torch.ones(128, 1)) + bce(D(fake.detach()), torch.zeros(128, 1))
    od.zero_grad(); ld.backward(); od.step() # D: echt vs. fake
    lg = bce(D(fake), torch.ones(128, 1))
    og.zero_grad(); lg.backward(); og.step() # G: D tauschen
    if step % 1000 == 0:
        s = G(torch.randn(1000, 4)).detach()
        print(f"step {step:4d} Mittel {s.mean():.2f} Std {s.std():.2f}")
```

Ausgabe (real ausgeführt)

step	0	Mittel	0.03	Std	0.20
step	1000	Mittel	2.86	Std	0.66
step	2000	Mittel	3.01	Std	0.68
step	3000	Mittel	3.02	Std	0.68

3 Lesart der Ausgaben

VAE: die Rekonstruktion fällt von 9.8 auf 2.3, der KL-Term steigt von 0.6 auf 1.6 – der latente Code trägt zunehmend Information (Kompromiss der ELBO). **GAN:** der Generator lernt die Zielverteilung $\mathcal{N}(3, 0.5^2)$: Mittel 3.02 passt, die Standardabweichung 0.68 ist noch zu breit (nach 3000 Schritten, kurzes Training). Ein GAN hat keinen monoton fallenden Verlust – die Qualität prüft man an den Samples.

? Selbsttest: kannst du das herleiten?

F1 Wie lautet der KL-Term für zwei Gauß-Verteilungen?

A: $\frac{1}{2}(\mu^2 + \sigma^2 - 1 - \log \sigma^2)$ gegen $\mathcal{N}(0, 1)$.

F2 Warum braucht man die Reparametrisierung?

A: Damit der Gradient durch das Sampling fließt: $z = \mu + \sigma\xi$.

F3 Was ist Mode Collapse?

A: Der GAN-Generator erzeugt nur wenige Varianten der Daten.

„Wer die Daten erzeugen kann, hat sie verstanden.“

Leistungsfähig heißt nicht vertrauenswürdig: fünf Kritikpunkte an ML. ❤️

Kritische Perspektiven

Adversarial Examples, Interpretierbarkeit, Kosten & Ethik

Merke:
FGSM:
 $x_{adv} = x + \epsilon \text{sign}(\nabla_x J)$

Quelle: materials/critiques-ml-aut19.pdf (C. Chute, T. Ding, A. Kurenkov, 2019) und materials/critiques-ml.pdf (2018)

1 Fünf Themen

1. Adversarial Examples
2. Interpretierbarkeit
3. Kosten: Daten & Rechenleistung
4. Schwächen der Community
5. Ethische Fragen (Fairness, Bias)

2 Adversarial Examples

Winzige, für Menschen kaum sichtbare Störungen erzwingen falsche Vorhersagen (+ ϵ -Rauschen: Panda $\rightarrow$ Gibbon). Sie übertragen sich auf andere Architekturen und Datensätze und lassen sich physisch bauen (z. B. Verkehrsschilder).

3 Skizze: Bild + Rauschen

Bild $x + \epsilon \text{sign}(\nabla_x J)$

„Panda“

x_{adv}

„Gibbon“

4 FGSM & Verteidigungen

Fast Gradient Sign Method: gehe in Richtung steigenden Verlusts.

`</> FGSM`

input: x, y , Modell θ , Schrittgröße ϵ # J : Verlust, x_{adv} : gestörtes Bild
 $g \leftarrow \nabla_x J(\theta, x, y)$
 $x_{adv} \leftarrow x + \epsilon \cdot \text{sign}(g)$

Abwehr: adversariales Training (saubere + gestörte Beispiele), Distillation mit Temperatur-Softmax. Weiterhin ein Wettrennen / offenes Problem.

5 Interpretierbarkeit (Lipton)

Zwei Bedeutungen: **algorithmische Transparenz** (Modell selbst verständlich: lineare Modelle, kleine Bäume) vs. **Post-hoc-Erklärung** (Saliency Maps, Grad-CAM, Attention, t-SNE). Fallacy: "lineare Modelle interpretierbar, neuronale Netze Blackbox" verwechselt beides.
Fünf Fragen: Vertrauen, Kausalität, Übertragbarkeit, Informativität, Fairness – Metriken wie Accuracy/AUROC erfassen sie nicht (Vertiefung: Kapitel SHAP und Fairness).

Beispiel: warum lineare Modelle anfällig sind

$f(x) = w^\top x$, $x \in \mathbb{R}^{1000}$, $|w_i| = 0.01$. Störung $\eta = \epsilon \text{sign}(w)$ mit $\epsilon = 0.1$ pro Feature.

Lösung $w^\top \hat{x} = w^\top x + w^\top \eta$ mit

$w^\top \eta = \epsilon \|w\|_1 = 0.1 \cdot 1000 \cdot 0.01 = 1.0$.

Jedes Feature ändert sich nur um 0.1, die Ausgabe aber um 1.0 $\Rightarrow$ in hohen Dimensionen summieren sich kleine Störungen (Goodfellow).

6 Kosten & Gesellschaft

- **Daten & Compute:** moderne Modelle brauchen riesige Datenmengen und Rechenleistung – Zugang und Umwelt.
- **Bias in Daten** $\Rightarrow$ ungerechte Entscheidungen gegenüber unterrepräsentierten Gruppen.
- **Verantwortung:** Evaluation über reine Testfehler hinaus.

7 Was tun?

- Robustheit testen
- Erklärungen bereitstellen
- Fairness-Metriken prüfen

8 Offene Probleme

- × robuste Verteidigung
- × Kausalität statt Korrelation
- × Übertragung auf neue Verteilungen

9 Key Takeaways

- ✓ FGSM: $x + \epsilon \text{sign}(\nabla_x J)$
- ✓ Zwei Arten von Interpretierbarkeit
- ✓ Genauigkeit $\neq$ Vertrauen

? Selbsttest: kannst du das erklären?

F1 Was ist FGSM?

A: $x_{adv} = x + \epsilon \text{sign}(\nabla_x J)$: Schritt in Richtung steigenden Verlusts.

F2 Zwei Arten von Interpretierbarkeit?

A: Algorithmische Transparenz vs. Post-hoc-Erklärung.

F3 Warum sind lineare Modelle anfällig?

A: $w^\top \eta = \epsilon \|w\|_1$ wächst mit der Dimension.

„Ein Modell ist erst dann gut, wenn man ihm auch dann vertrauen kann, wenn niemand hinsieht.“

Bestärkendes Lernen (MDPs)

Markov-Entscheidungsprozesse, Value & Policy Iteration

Merke:
Bellman: $V^*(s) = \max_a [R + \gamma \sum P V^*]$

Quelle: main_notes.pdf (Reinforcement Learning), notes/cs229-notes12.pdf

1 MDP-Tupel


$(S, A, \{P_{sa}\}, R, \gamma)$:
 S Zustände, A Aktionen,
 $P_{sa}(s') = P(s'|s, a)$ Übergänge, $R(s, a)$
 Belohnung, $\gamma \in [0, 1)$ Diskontierung.
 $(s'$ Folgezustand, V Wert eines
 Zustands.) Ziel: **Policy** $\pi: S \rightarrow A$ mit
 maximalem erwarteten Ertrag.

2 Wertfunktion

$$V^\pi(s) = \mathbb{E} \left[\sum_{t \geq 0} \gamma^t R(s_t, a_t) \mid s_0 = s, \pi \right]$$

γ nahe 1: weitsichtig; nahe 0: kurzfristig. Optimal:
 $V^*(s) = \max_\pi V^\pi(s)$.

3 Skizze: Agent-Umwelt



4 Bellman-Gleichungen

$$V^\pi(s) = R(s) + \gamma \sum_{s'} P_{s\pi(s)}(s') V^\pi(s')$$

$$V^*(s) = \max_a [R(s, a) + \gamma \sum_{s'} P_{sa}(s') V^*(s')]$$

$$\pi^*(s) = \arg \max_a [R(s, a) + \gamma \sum_{s'} P_{sa}(s') V^*(s')]$$

5 Value Iteration

```

(</> Value Iteration
V(s) ← 0 für alle s
repeat bis Konvergenz:
  for jedes s:
    V(s) ← max_a [R(s, a) + γ ∑_{s'} P_{sa}(s') V(s')]
return π(s) = arg max_a [⋯]
  
```

6 Policy Iteration

```

(</> Policy Iteration
π ← beliebig
repeat bis π stabil:
  # Evaluation: lineares System
  löse (I - γP^π)V^π = R^π
  # Verbesserung
  π(s) ← arg max_a [R + γ ∑ P_{sa} V^π]
  
```

Konvergiert in endlich vielen Schritten.

Beispiel: 2 Zustände, $\gamma = 0.9$

$R(s_1) = 0, R(s_2) = 1$. Aktionen deterministisch: bleiben oder wechseln.
Lösung Bester Plan: in s_2 bleiben $\Rightarrow V^*(s_2) = \frac{1}{1-0.9} = 10$; von s_1 nach s_2 wechseln: $V^*(s_1) = 0 + 0.9 \cdot 10 = 9$.
 Value Iteration: $V_0 = (0, 0), V_1 = (0, 1), V_2 = (0.9, 1.9), \dots \rightarrow (9, 10)$.

7 Kontinuierliche Zustände & unbekannte Dynamik

Approximiere $V(s) \approx \theta^\top \phi(s)$ und iteriere (Fitted Value Iteration):

$$y^{(i)} = R + \gamma \max_a \sum_{s'} P_{s(i)a}(s') V(s'), \quad \theta \leftarrow \arg \min_i \sum_i (\theta^\top \phi(s^{(i)}) - y^{(i)})^2$$

Unbekannte Dynamik: $\hat{P}_{sa}(s') = \frac{\#(s, a \rightarrow s')}{\#(s, a)}$ aus Daten schätzen.

8 Vorteile

- ✓ exakte Optimalität (diskret)
- ✓ Bellman: klare Rekursion
- ✓ Policy Iteration: endlich

9 Grenzen

- ✗ Fluch der Dimensionalität
- ✗ Kenntnis von P nötig (oder Schätzung)
- ✗ Diskretisierung bei kontinuierlichem S

10 Key Takeaways

- ✓ MDP (S, A, P, R, γ)
- ✓ Bellman-Optimalität
- ✓ VI: max-Update; PI: Evaluation + Verbesserung

? Selbsttest: kannst du das erklären?

F1 Bellman-Optimalität?

A: $V^*(s) = \max_a [R + \gamma \sum P_{sa} V^*]$.

F2 Value vs. Policy Iteration?

A: VI: max-Update bis Konvergenz; PI: Evaluation (lin. System) + Verbesserung.

F3 Rolle von γ ?

A: Nahe 1 weitsichtig, nahe 0 kurzfristig.

„Entscheide heute so, dass die Summe aller morgigen Belohnungen maximal wird.“

LQR, DDP & LQG

Lineare Dynamik plus quadratische Kosten ergibt eine exakte, analytische Lösung.



Regelung kontinuierlicher Systeme

Merke:
Die optimale Regel ist linear:
 $u_t = -K_t x_t$

Quelle: main_notes.pdf (LQR, DDP, LQG), notes/cs229-notes13.pdf (D. Boneh & A. Ng)

1 LQR-Setup

$$x_{t+1} = Ax_t + Bu_t + w_t$$

$$c_t = x_t^\top Q x_t + u_t^\top R u_t$$

Lineare Dynamik, quadratische Kosten ($Q \succeq 0, R \succ 0$), Rauschen

$w_t \sim \mathcal{N}(0, \Sigma_w)$. Ziel: Zustand nahe 0 mit wenig Stellenergie.

2 Riccati-Rekursion

Wertfunktion quadratisch:

$$V_t(x) = x^\top P_t x + q_t.$$

Legende: x_t Zustand, u_t Steuerung, A, B Dynamikmatrizen, Q, R Kostenmatrizen, P_t Kostenmatrix der Wertfunktion, K_t Reglerverstärkung, T Horizont.


$$P_T = Q$$

$$P_t = Q + A^\top P_{t+1} A$$

$$- A^\top P_{t+1} B K_t$$

$$K_t = (R + B^\top P_{t+1} B)^{-1} B^\top P_{t+1} A$$

3 Skizze: Regelkreis



4 LQR-Algorithmus

Finite-Horizon LQR

$P_T \leftarrow Q$

for $t = T-1:0$: # rückwärts

$$K_t \leftarrow (R + B^\top P_{t+1} B)^{-1} B^\top P_{t+1} A$$

$$P_t \leftarrow Q + A^\top P_{t+1} A - A^\top P_{t+1} B K_t$$

for $t = 0:T-1$: # vorwärts

$$u_t \leftarrow -K_t x_t; \quad x_{t+1} \leftarrow A x_t + B u_t$$

5 DDP: nichtlineare Systeme

$x_{t+1} = f(x_t, u_t)$: linearisiere um eine Referenztrajektorie $(\bar{x}_t, \bar{u}_t)$:

$$f(x, u) \approx f(\bar{x}, \bar{u}) + F_x(x - \bar{x}) + F_u(u - \bar{u})$$

DDP / iterative LQR

repeat bis Konvergenz:

linearisiere f , quadrtisiere Kosten

Backward: LQR $\rightarrow K_t$

Forward: Politik anwenden $\rightarrow$ neue Trajektorie

Beispiel: skalarer LQR

$$x_{t+1} = x_t + u_t, \quad Q = R = 1, \quad P_T = 1.$$

Lösung $K = \frac{P}{1+P}$: $P_T = 1 \Rightarrow K = 0.5$; $P = 1 + 1 - \frac{1}{2} = 1.5$;

dann $K = 0.6, P = 1.6...$

Fixpunkt: $P^2 - P - 1 = 0 \Rightarrow P^* = 1.618, K^* = 0.618$.

Start $x_0 = 1$: $u_0 = -0.618, x_1 = 0.382$ Zustand schrumpft.

6 LQG: nicht beobachtbarer Zustand

Messung $y_t = Cx_t + v_t, v_t \sim \mathcal{N}(0, \Sigma_v)$. Separationsprinzip: Kalman-Filter und LQR-Regler unabhängig entwerfen.

LQG

for jeden Schritt:

$$\hat{x}_t \leftarrow \text{Kalman-Filter}(y_{1:t})$$

$$u_t \leftarrow -K_t \hat{x}_t \quad \# \text{ LQR mit Schätzung}$$

7 Vorteile

- ✓ analytisch, effizient
- ✓ lineare optimale Regel
- ✓ DDP: nichtlinear nutzbar

8 Grenzen

- ✗ nur lineare/lokal linearisierte Dynamik
- ✗ quadratische Kosten
- ✗ DDP: lokale Lösung

9 Key Takeaways

- ✓ Riccati rückwärts, Regelung vorwärts
- ✓ $u_t = -K_t x_t$
- ✓ LQG: Kalman + LQR

? Selbsttest: kannst du das erklären?

F1 Form der optimalen Policy?

A: $u_t = -K_t x_t$ (linear im Zustand).

F2 Was liefert die Riccati-Rekursion?

A: P_t rückwärts (quadratische Wertfunktion) und damit K_t .

F3 Separationsprinzip?

A: Kalman-Filter und LQR unabhängig entwerfen; $\hat{x}$ statt x nutzen.

„Wenn die Welt linear ist und die Kosten quadratisch, gibt es eine Formel statt einer Suche.“

Policy Gradient

Statt einer Wertfunktion: die Policy direkt optimieren. ❤️

REINFORCE, Baselines & Actor-Critic

Merke:
 $\nabla J = \mathbb{E} \left[\sum_t \nabla \log \pi_{\theta}(a_t | s_t) G_t \right]$

Quelle: main_notes.pdf (Policy Gradient / REINFORCE)

1 Direkte Parametrisierung

Policy $\pi_{\theta}(a|s)$ (z. B. Softmax oder Gauß).
 Ziel:


$$J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^T \gamma^t r_t \right]$$

(τ Episode, r_t Belohnung zur Zeit t , γ Diskontfaktor, θ Policy-Parameter.)
 Gradienten-Aufstieg auf J ; funktioniert auch bei kontinuierlichen Aktionen.

2 Log-Trick

$\nabla_{\theta} \pi_{\theta} = \pi_{\theta} \nabla_{\theta} \log \pi_{\theta}$. Damit wird der Gradient zu einem Erwartungswert, der sich per **Sampling** schätzen lässt – ohne Modell der Umwelt.

3 Skizze: Gute Aktionen verstärken



4 Policy-Gradient-Theorem

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau} \left[\sum_{t=0}^T \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot G_t \right]$$

mit dem zukünftigen Ertrag $G_t = \sum_{t'=t}^T \gamma^{t'-t} r_{t'}$. Intuition: Aktionen mit hohem Ertrag werden wahrscheinlicher, solche mit niedrigem unwahrscheinlicher.

5 REINFORCE

REINFORCE

repeat:

Episode $\tau = (s_0, a_0, r_0, \dots)$ unter π_{θ} ziehen

for t : $G_t \leftarrow \sum_{t' \geq t} \gamma^{t'-t} r_{t'}$

$g \leftarrow \sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) (G_t - b(s_t))$

$\theta \leftarrow \theta + \alpha g$

Mit $b \equiv 0$: reines REINFORCE.

6 Varianzreduktion

REINFORCE hat hohe Varianz. Eine **Baseline** $b(s_t)$ senkt sie, ohne den Erwartungswert zu verzerren:

$g = \sum_t \nabla \log \pi(G_t - b(s_t))$. Typisch $b = V^{\pi}(s_t)$;

$A(s, a) = Q(s, a) - V(s)$ heißt Advantage und führt zu

Actor-Critic: Actor = Policy, Critic = Wertfunktion.

Beispiel: 2-armiger Bandit

$\pi(a_1) = \sigma(\theta)$, $\theta = 0 \Rightarrow \pi(a_1) = 0.5$. Belohnung: $a_1 \rightarrow 1$, $a_2 \rightarrow 0$.

Gezogen: a_1 , $G = 1$, $\alpha = 0.5$.

Lösung $\nabla_{\theta} \log \sigma(\theta) = 1 - \sigma(\theta) = 0.5$.

Ohne Baseline:

$\theta \leftarrow 0 + 0.5 \cdot 0.5 \cdot 1 = 0.25 \Rightarrow \pi(a_1) = \sigma(0.25) = \mathbf{0.56}$.

Mit $b = 0.5$: $\Delta\theta = 0.5 \cdot 0.5 \cdot (1 - 0.5) = 0.125$ (kleinerer, stabilerer Schritt).

7 Policy Gradient vs. Wertmethoden

	Wert-basiert	Policy Gradient
Lernt	V, Q	π_{θ} direkt
Aktionen	diskret	auch kontinuierlich
Varianz	niedrig	hoch
Modell	oft P nötig	modellfrei

8 Vorteile

- ✓ kontinuierliche Aktionen
- ✓ modellfrei, flexibel
- ✓ stochastische Policies

9 Grenzen

- ✗ hohe Varianz
- ✗ stichproben-ineffizient
- ✗ lokale Optima

10 Key Takeaways

- ✓ $\nabla J = \mathbb{E}[\sum \nabla \log \pi G_t]$
- ✓ Baseline gegen Varianz
- ✓ Actor-Critic kombiniert beides

? Selbsttest: kannst du das erklären?

F1 Policy-Gradient-Theorem?

A: $\nabla J = \mathbb{E}[\sum_t \nabla \log \pi(a_t | s_t) G_t]$.

F2 Wozu eine Baseline?

A: Senkt die Varianz, ohne den Erwartungswert zu verzerren.

F3 Vorteil ggü. Wertmethoden?

A: Kontinuierliche Aktionen, modellfrei; Nachteil: hohe Varianz.

„Verstärke, was funktioniert hat -- und probiere trotzdem Neues.“

Bestärkendes Lernen: Vertiefung

Bellman, Value Iteration, Policy Gradient

Merke:
Der Log-Trick macht aus dem Gradienten einen Erwartungswert

Quelle: main_notes.pdf Kap. 15--17 (MDPs, Value/Policy Iteration, LQR, Policy Gradient), notes/cs229-notes12.pdf, cs229-notes13.pdf; Schritte ergänzt

1 Bellman-Gleichung

Legende: s Zustand, a Aktion, $R(s)$ Belohnung, $\gamma \in [0, 1)$ Diskontfaktor, π Policy (Strategie), $V^\pi(s)$ erwartete Gesamtbelohnung ab s , $P_{sa}(s')$ Übergangswahrscheinlichkeit.

$V^\pi(s) = \mathbb{E}[R(s_0) + \gamma R(s_1) + \gamma^2 R(s_2) + \dots \mid s_0 = s, \pi]$. Ersten Term abspalten:

$$\begin{aligned} V^\pi(s) &= R(s) + \gamma \mathbb{E}[R(s_1) + \gamma R(s_2) + \dots \mid s_0 = s] \\ &= R(s) + \gamma \sum_{s'} P_{s\pi(s)}(s') V^\pi(s') \end{aligned} \quad \text{Markov}$$

Lineares Gleichungssystem:

$$V^\pi = R + \gamma P^\pi V^\pi \Rightarrow V^\pi = (I - \gamma P^\pi)^{-1} R \text{ (Policy Evaluation).}$$

In Worten: Der Wert eines Zustands ist die sofortige Belohnung plus der abgezinste erwartete Wert des Nachfolgezustands.

2 Value Iteration konvergiert

Legende: B Bellman-Operator (ein Value-Iteration-Schritt), V, V' zwei Wertfunktionen, $\|\cdot\|_\infty$ größter Betrag über alle Zustände, V^* optimaler Wert, V_k Wert nach k Schritten.

$$\text{Operator } (BV)(s) = \max_a [R(s, a) + \gamma \sum_{s'} P_{sa}(s') V(s')].$$

$$\|BV - BV'\|_\infty \leq \gamma \|V - V'\|_\infty \quad \text{max 1-Lipschitz}$$

B ist eine γ -Kontraktion $\Rightarrow$ (Banach) genau ein Fixpunkt V^* und $\|V_k - V^*\|_\infty \leq \gamma^k \|V_0 - V^*\|_\infty$: geometrische Konvergenz.

In Worten: Jeder Schritt bringt zwei beliebige Wertfunktionen um mindestens den Faktor γ näher zusammen; sie laufen also auf einen gemeinsamen Punkt zu.

3 Policy-Gradient-Theorem

Legende: $\tau = (s_0, a_0, s_1, \dots)$ Trajektorie, $R(\tau)$ deren Gesamtbelohnung, $\pi_\theta(a|s)$ Policy mit Parametern θ , $J(\theta)$ erwarteter Ertrag, G_t Belohnung ab Zeit t .

$$\begin{aligned} J(\theta) &= \sum_{\tau} P(\tau; \theta) R(\tau), \\ P(\tau) &= \mu(s_0) \prod_t \pi_\theta(a_t | s_t) P(s_{t+1} | s_t, a_t). \\ \nabla J &= \sum_{\tau} \nabla P(\tau) R(\tau) \\ &= \sum_{\tau} P(\tau) \nabla \log P(\tau) R(\tau) \quad \nabla P = P \nabla \log P \\ \nabla \log P(\tau) &= \sum_t \nabla \log \pi_\theta(a_t | s_t) \quad P(s' | s, a) \text{ ohne } \theta \\ \nabla J &= \mathbb{E}_{\tau} \left[\sum_t \nabla \log \pi_\theta(a_t | s_t) R(\tau) \right] \end{aligned}$$

Kausalität: Aktion a_t beeinflusst nur spätere Belohnungen $\Rightarrow R(\tau) \rightarrow G_t$.

In Worten: Aktionen, die zu hoher Belohnung führten, bekommen mehr Wahrscheinlichkeit: $\nabla \log \pi$ zeigt, wie man π erhöht, R gewichtet.

4 Baseline verzerrt nicht

$b(s)$ hängt nicht von a ab (b : Baseline, ein Vergleichswert):

$$\begin{aligned} \mathbb{E}_{a \sim \pi} [\nabla \log \pi(a|s) b(s)] &= b(s) \sum_a \pi(a|s) \frac{\nabla \pi(a|s)}{\pi(a|s)} \\ &= b(s) \nabla \sum_a \pi(a|s) = b(s) \nabla 1 = 0 \end{aligned}$$

Also darf man $b(s_t)$ subtrahieren: gleicher Erwartungswert, aber kleinere Varianz (typisch $b = V^\pi$).

Regelung mit quadratischen Kosten in geschlossener Form – plus Rechenbeispiel und Ableitungs-Tricks. ❤️

RL: Vertiefung 2

LQR-Riccati, Beispiel und Tricks

Merke:
Quadratisch bleibt quadratisch: der Regler ist linear

Quelle: main_notes.pdf Kap. 15--17 (MDPs, Value/Policy Iteration, LQR, Policy Gradient), notes/cs229-notes12.pdf, cs229-notes13.pdf; Schritte ergänzt

5 LQR: Riccati-Rekursion

Legende: x Zustand, u Steuerung, A, B lineare Dynamik $x' = Ax + Bu$, Q, R Kostenmatrizen (Zustand, Steuerung; hier nicht die Belohnung), P_t Kostenmatrix von V_t , K_t Reglerverstärkung, T Endzeitpunkt.

$V_{t+1}(x) = x^\top P_{t+1} x$ (Induktion, $V_T = x^\top Q x$). Bellman rückwärts:

$$V_t(x) = \min_u [x^\top Q x + u^\top R u + (Ax + Bu)^\top P_{t+1} (Ax + Bu)]$$

$$0 = 2Ru + 2B^\top P_{t+1} (Ax + Bu) \Rightarrow u^* = -K_t x$$

$$K_t = (R + B^\top P_{t+1} B)^{-1} B^\top P_{t+1} A$$

Einsetzen: $P_t = Q + A^\top P_{t+1} A - A^\top P_{t+1} B K_t$. Die Wertfunktion bleibt quadratisch $\Rightarrow$ Regler linear im Zustand.

In Worten: Rückwärts in der Zeit: Die beste Steuerung minimiert Kosten jetzt plus Kosten danach. Weil alles quadratisch ist, ergibt sich $u = -Kx$ in geschlossener Form.

Beispiel: Bandit-Policy-Gradient

Softmax-Policy mit Logits $\theta = (0, 0)$, also $\pi = (0.5, 0.5)$.

Lösung $\nabla_\theta \log \pi(a=1) = e_1 - \pi = (1, 0) - (0.5, 0.5) = (0.5, -0.5)$.

Zieht man $a = 1$ mit Ertrag $G = 1$: $\theta \leftarrow \theta + \alpha G (0.5, -0.5)$ – Logit von a_1 steigt, der von a_2 sinkt. Mit Baseline $b = 0.5$: Schritt nur halb so groß.

VI-Kontraktion im MDP-Beispiel ($\gamma = 0.9$): Fehler schrumpft je Iteration um den Faktor 0.9.

6 Ableitungs-Tricks

- $\nabla f = f \nabla \log f$ (Log-Trick, überall wo Sampling steckt)
- Erwartungswert aus Summe: Gradient in Erwartung hineinziehen
- Rekursion + Induktion: quadratische Form bleibt quadratisch (LQR)
- Kontraktion $\Rightarrow$ Fixpunkt + Konvergenzrate

? Selbsttest: kannst du das herleiten?

F1 Warum darf ∇ im Policy-Gradient nur auf π_θ wirken?

A: Übergangsdynamik $P(s'|s, a)$ hängt nicht von θ ab und fällt beim Ableiten von $\log P(\tau)$ weg.

F2 Warum ist die Baseline unverzerrt?

A: $\sum_a \nabla \pi(a|s) = \nabla 1 = 0$.

F3 Warum konvergiert Value Iteration?

A: B ist eine γ -Kontraktion in der Max-Norm.

„Rekursion für Werte, Log-Trick für Policies – die zwei Werkzeuge des RL.“

Welcher Algorithmus passt wann? Alle Methoden der Vorlesung im Vergleich. 

Algorithmen-Spickzettel

Aufgabe, Idee, Lösungsverfahren, Stärken & Grenzen

Merke:
Frage dich immer: Modell?
Verlust? Optimierung?

A Vergleichstabelle

Methode	Aufgabe	Schlüsselidee	Lösung	Stärke	Grenze
Lineare Regression	Regression	Least Squares, $\theta^\top x$	Normalgl., (S)GD	einfach, interpretierbar	nur linear, Ausreißer
Logistische Regr.	Klassifikation	Sigmoid + MLE	GD, Newton	Wahrscheinlichkeiten, konvex	nur lineare Grenze
GLM	beides	ExpFamilie, $\eta = \theta^\top x$	GD, Newton	einheitliche Theorie	Verteilungsannahme
GDA	Klassifikation	Gauß $p(x y)$ + Bayes	geschl. MLE	wenig Daten	starke Annahme
Naive Bayes	Klassifikation	Unabhängigkeit + Laplace	Zählen	schnell, skalierbar	„naive“ Annahme
SVM	Klassifikation	max. Margin + Kernel	QP, SMO	Kernel, sparse	teuer bei großem n
Perceptron	Klassifikation	Update bei Fehler	online	Schranke $(D/\gamma)^2$	nur trennbar
k-NN	beides	Mehrheit/Mittel der k Nachbarn	kein Training	einfach, nichtlinear	langsam, Fluch der Dimension
Decision Tree	beides	rekursive Splits	greedy, Pruning	interpretierbar	hohe Varianz
Random Forest	beides	Bagging + Feature-Zufall	Bäume mitteln	robust, wenig Tuning	schwer interpretierbar
Boosting	beides	sequentielle schwache Lerner	forward stagewise	senkt Bias	Overfitting bei großem M
Gaussian Process	Regression	Prior über Funktionen	Konditionierung	Unsicherheit	$O(n^3)$
CNN / RNN-LSTM	Bild / Sequenz	Faltung+Sharing / Gates	Backprop + Adam	nutzt Datenstruktur	datenhungrig
Neuronales Netz	beides	tiefe Nichtlinearität	Backprop + SGD	universell	datenhungrig, nichtkonvex
K-Means	Clustering	Zentroide	alternieren	einfach, schnell	lokale Optima, K nötig
Hierarchisches Clustering	Clustering	Baum aus Verschmelzungen	Linkage, Dendrogramm	kein K nötig	$O(n^2)$, nicht umkehrbar
EM / Gauß-Gemisch	Dichte, Cluster	latente Variable, ELBO	E/M-Schritt	weiche Zuordnung	lokale Optima
Faktorenanalyse	Dim.-Reduktion	latente Faktoren	EM	funktioniert bei $n \gg m$	Rotation nicht eindeutig
PCA	Dim.-Reduktion	max. Varianz	Eigenvektoren	geschlossen, schnell	nur linear
ICA	Quellentrennung	Unabhängigkeit, Nicht-Gauß	SGD auf Likelihood	Cocktailparty	Skalierung/Permutation
HMM	Sequenzen	latente Zustandskette	Forward, Viterbi, Baum-Welch	Zeitreihen	Markov-Annahme
VAE / GAN / Diffusion	Generieren	latente Variable, Minimax, Entrauschen	ELBO-SGD, adversarial	neue Samples	instabil / teuer
Transformer / SSL	Repräsentation	Self-Attention, Next-Token	SGD	skaliert mit Daten	sehr teuer
Value / Policy Iteration	RL (diskret)	Bellman-Gleichung	dyn. Programmierung	exakt	Fluch der Dimension
LQR / DDP / LQG	Regelung	lin. Dynamik, quadr. Kosten	Riccati	analytisch	Linearität nötig
REINFORCE	RL (allgemein)	Policy Gradient	Sampling + GD	flexibel	hohe Varianz

B Faustregeln zur Wahl

- Wenig Daten, Gauß-artig → GDA / regularisiert linear
- Tabellarische Daten, viel Rauschen → Random Forest / Boosting
- Bilder, Text, Audio → neuronale Netze
- Unsicherheit wichtig, kleines n → Gaussian Process
- Struktur ohne Labels → Clustering / PCA

C Farblegende

überwacht Deep Learning unüberwacht bestärkend

Lesetipp: für jede Zeile die drei Fragen beantworten – Modell (Hypothese), Verlust (Ziel), Optimierung (Verfahren).

„Kein Algorithmus gewinnt immer -- gute Praxis heißt, die Annahmen zu kennen.“

Formel-Spickzettel

Kompakte Sammlung für die Klausurvorbereitung

Merke:
Formeln verstehen, nicht nur auswendig lernen!

1 Lineare Regression

$$\hat{\theta} = (X^T X)^{-1} X^T y$$

$$\theta \leftarrow \theta + \alpha(y - h_{\theta}(x))x$$

$$\text{LWLR: } w^{(i)} = e^{-\|x^{(i)} - x\|^2 / 2\tau^2}$$

2 Logistisch / Softmax

$$h = \frac{1}{1 + e^{-\theta^T x}}, \quad \theta \leftarrow \theta + \alpha(y - h)x$$

$$P(k|x) = \frac{e^{\theta_k^T x}}{\sum_j e^{\theta_j^T x}}$$

$$\text{Newton: } \theta \leftarrow \theta - H^{-1} \nabla \ell$$

3 GLM

$$p(y; \eta) = b(y) e^{\eta^T T(y) - a(\eta)}$$

$$h(x) = \mathbb{E}[T(y)|x], \quad \eta = \theta^T x$$

$$\text{Bernoulli: } \phi = \frac{1}{1 + e^{-\eta}}; \text{ Poisson: } \lambda = e^{\eta}$$

4 Generativ

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)}$$

$$\text{GDA: } x|y \sim \mathcal{N}(\mu_y, \Sigma)$$

$$\text{NB: } p(x|y) = \prod_j p(x_j|y), \quad \hat{\phi} = \frac{1 + \#}{2 + \#}$$

5 SVM & Kernel

$$\min \frac{1}{2} \|w\|^2 \text{ s.t. } y_i(w^T x_i + b) \geq 1$$

$$f(x) = \sum_i \alpha_i y_i K(x_i, x) + b, \quad 0 \leq \alpha_i \leq C$$

$$K = \phi^T \phi \Leftrightarrow \text{Gram PSD}; \quad \theta = \sum \alpha_i x_i$$

6 Verluste (Margin z)

$$\phi_{\log} = \log(1 + e^{-z})$$

$$\phi_{\text{hinge}} = \max(1 - z, 0)$$

$$\phi_{\text{exp}} = e^{-z}, \quad \phi_{01} = \mathbf{1}\{z \leq 0\}$$

7 Bias-Varianz & Ensemble

$$\text{MSE} = \sigma^2 + \text{Bias}^2 + \text{Var}$$

$$\text{Var}(\bar{X}) = \rho \sigma^2 + \frac{1 - \rho}{n} \sigma^2$$

$$\text{AdaBoost: } \alpha_m = \log \frac{1 - \text{err}_m}{\text{err}_m}$$

8 Lerntheorie

$$P(|\bar{Z} - \mathbb{E}\bar{Z}| \geq t) \leq 2e^{-2nt^2/(b-a)^2}$$

$$n \geq \frac{1}{2\gamma^2} \log \frac{2k}{\delta}, \quad \text{VC}_{\text{lin}} = d + 1$$

$$\text{Perceptron: Fehler} \leq (D/\gamma)^2$$

9 Regularisierung

$$J_{\lambda} = J + \frac{\lambda}{2} \|\theta\|_2^2 \quad / \quad J + \lambda \|\theta\|_1$$

$$\text{MAP: } \arg \max [\log p(y|\theta) + \log p(\theta)]$$

$$\text{Ridge: } (X^T X + \lambda I)^{-1} X^T y$$

10 Netze & Backprop

$$z^{[\ell]} = W^{[\ell]} a^{[\ell-1]} + b^{[\ell]}, \quad a = \sigma(z)$$

$$\delta_{\ell-1} = (W_{\ell}^T \delta_{\ell}) \odot \sigma'(z_{\ell-1})$$

$$\theta \leftarrow \theta - \alpha \frac{1}{B} \sum_{i \in B} \nabla J^{(i)}$$

11 EM & Gemische

$$\text{E: } Q_i(z) = p(z|x_i; \theta)$$

$$\gamma_{ik} = \frac{\phi_k \mathcal{N}(x_i; \mu_k, \Sigma_k)}{\sum_j \phi_j \mathcal{N}(x_i; \mu_j, \Sigma_j)}$$

$$\mu_k = \frac{\sum_i \gamma_{ik} x_i}{\sum_i \gamma_{ik}}$$

12 PCA / FA / ICA

$$\text{PCA: } \max_{U^T U = I} \text{tr}(U^T \hat{\Sigma} U)$$

$$\text{FA: } x \sim \mathcal{N}(\mu, \Lambda \Lambda^T + \Psi)$$

$$\text{ICA:}$$

$$W \leftarrow W + \alpha((1 - 2g(Wx))x^T + (W^T)^{-1})$$

13 HMM & GP

$$\text{HMM: } \alpha_j(t) = (\sum_i \alpha_i(t-1) A_{ij}) B_{j, x_t}$$

$$\text{GP: } \mu_* = K_*(K + \sigma^2 I)^{-1} y$$

$$\Sigma_* = K_{**} - K_*(K + \sigma^2 I)^{-1} K_*^T$$

14 Metriken

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}$$

$$F_1 = \frac{2PR}{P+R}, \quad \text{Acc} = \frac{TP + TN}{n}$$

$$\text{Brier: } \frac{1}{n} \sum (\hat{p}_i - y_i)^2$$

15 Bestärkendes Lernen

$$V^*(s) = \max_a [R + \gamma \sum_{s'} P_{sa}(s') V^*(s')]$$

$$\text{LQR: } u_t = -K_t x_t, \quad \text{Riccati rückwärts}$$

$$\nabla J = \mathbb{E}[\sum_t \nabla \log \pi(G_t - b)]$$

16 Optimierer & Normalisierung

$$v \leftarrow \beta v + g, \quad \theta \leftarrow \theta - \alpha v$$

$$\text{Adam: } \theta \leftarrow \theta - \alpha \frac{\hat{m}}{\sqrt{\hat{v} + \epsilon}}$$

$$\text{BN}(z) = \gamma \frac{z - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} + \beta$$

17 VAE / Faltung

$$\text{ELBO} = \mathbb{E}_Q \log p(x|z) - \text{KL}(Q||p(z))$$

$$z = \mu + \sigma \odot \xi,$$

$$\text{KL} = \frac{1}{2} \sum (\mu^2 + \sigma^2 - 1 - \log \sigma^2)$$

$$\text{Conv-Größe} \lfloor \frac{n+2p-k}{s} \rfloor + 1$$

18 Regressionsmetriken

$$\text{MAE} = \frac{1}{n} \sum |e_i|, \quad \text{MSE} = \frac{1}{n} \sum e_i^2$$

$$R^2 = 1 - \frac{\text{SSE}}{\text{SST}}$$

$$R_{\text{adj}}^2 = 1 - (1 - R^2) \frac{n-1}{n-p-1}$$

„Wer die Formeln herleiten kann, muss sie nicht auswendig lernen.“